Documentación de la estructura del proyecto de análisis de datos

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Proyecto: Análisis Exploratorio de Datos provincial en España
Autores del proyecto: Luis Molina Villar, Rubén Sánchez Munuera y Pablo Gallart Carbonell
Universitat de València | Fecha: 8 de noviembre de 2026

Documento generado a partir de los archivos locales del proyecto, con revisión de estructura, código y resultados documentados.

Contenido

Resumen ejecutivo
Inventario de archivos
Archivos principales
Estructura de carpetas
Fuentes de datos y dimensiones
Dimensiones conceptuales
Arquitectura del flujo de datos
Etapa 1: configuración y catálogo territorial
Etapa 2: descarga y lectura
Etapa 3: normalización y claves
Etapa 4: agregación de fuentes
Etapa 5: paneles y persistencia
Análisis exploratorio
Datos perdidos
Análisis univariante
Análisis bivariante y multivariante
Controles de calidad
Productos generados por el proyecto
Reproducción recomendada
Limitaciones documentadas
Cierre

Resumen ejecutivo

El proyecto realiza un Análisis Exploratorio de Datos (AED) sobre las 50 provincias españolas peninsulares e insulares, excluyendo Ceuta y Melilla. El objetivo es estudiar si la estructura productiva provincial se relaciona de forma homogénea o heterogénea con la renta, la vivienda, la demografía y la migración.

El flujo completo es:

fuentes INE/MIVAU lectura española normalización unión por provincia-año imputación análisis 2019 correlaciones y clustering

La unidad final de observación es una provincia en un año. El panel socioeconómico común cubre 2015--2021 y el análisis principal selecciona 2019, año anterior a la pandemia de COVID-19 y con disponibilidad común de todas las fuentes.

Inventario de archivos

Archivos principales

Archivo	Tipo	Responsabilidad
ProyectoAED.Rmd	R Markdown	Informe reproducible: planteamiento, preparación, EDA, correlaciones, clustering y conclusiones.
Utilidades.Rmd	R Markdown	Funciones auxiliares, catálogos de provincias, lectura, validación, imputación y gráficos.
codigo_extraido.R	R	Versión ejecutable del código de Utilidades.Rmd, creada con knitr::purl().
instalar_paquetes.R	R	Script auxiliar de instalación/configuración disponible en el proyecto.
ProyectoAED.tex	LaTeX	Fuente LaTeX del informe principal.
Proyecto_AED.pdf	PDF	Informe final original, de 10 páginas.
ProyectoAED.Rproj	RStudio	Configuración del proyecto RStudio.
README.txt	Texto	Nota de uso y contexto del repositorio.
EnlaceRepo.txt	Texto	Referencia al repositorio del proyecto.

Estructura de carpetas

```
Entrega_ProyectoAED/
|-- ProyectoAED.Rmd              # informe reproducible
|-- Utilidades.Rmd               # funciones auxiliares
|-- codigo_extraido.R            # utilidades extraidas
|-- Proyecto_AED.pdf             # informe renderizado
|-- ProyectoAED.tex              # fuente LaTeX del informe
|-- data/
|   |-- raw/                     # ocho fuentes CSV originales
|   |-- Datos_SocioEcon.csv      # panel socioeconómico procesado
|   |-- Datos_SocioEcon.Rdata    # mismo panel en formato R
|   |-- Datos_Laborales.csv      # panel laboral procesado
|   `-- Datos_Laborales.Rdata    # mismo panel en formato R
|-- ProyectoAED_files/figure-latex/ # figuras del informe
|-- Definitions/                 # clase MDPI, bibliografía y logos
`-- output/pdf/                  # documentación generada
```

Fuentes de datos y dimensiones

Se emplean ocho ficheros CSV de INE y MIVAU. Los ficheros están delimitados de forma distinta; por ello la lectura no se puede resolver con una única llamada genérica sin parámetros.

Fuente local	Origen	Filas aprox.	Contenido y tratamiento
coste_vivienda.csv	MIVAU	13.711	Precio por m^2, trimestre y régimen; se conserva vivienda libre y se promedia por provincia-año.
distribucion_poblacional.csv	INE	4.134	Habitantes por provincia, periodo y sexo; se conserva Sexo == "Total".
edad_maternidad.csv	INE	13.250	Edad media; se conserva Orden de nacimiento == "Todos".
migracion_interior.csv	INE	200.928	Saldo por edad y sexo; se conserva ambos sexos y edades 19--35, sumando por provincia-año.
Ocupados_Sector_Provincia.csv	INE	19.875	Ocupación por ramas; construcción e industria se agrupan en secundario.
pib_per_capita.csv	INE	4.914	PIB por magnitud y territorio; se eliminan totales y se resuelven CCAA uniprovinciales.
renta_bruta_media.csv	INE	4.920	Renta bruta media por persona; se filtra el indicador exacto y se normalizan nombres.
valor_bruto_sector.csv	INE	12.480	VAB por rama; se agregan ramas en primario, secundario y terciario.

Dimensiones conceptuales

- Renta y riqueza: PIB_per_capita, Renta_bruta_media.
- Mercado inmobiliario: Precio_m2.
- Demografía y ciclo vital: Habitantes, Edad_Media_Maternidad, Migracion_Interior.
- Estructura productiva: ocupación y VAB de los sectores primario, secundario y terciario.

Arquitectura del flujo de datos

Etapa 1: configuración y catálogo territorial

El bloque de configuración carga los paquetes requeridos y establece opciones globales de knitr: código visible, advertencias y mensajes ocultos, figuras centradas, tamaño de 6 por 4 pulgadas y ancho máximo del texto del PDF. Utilidades.Rmd construye además ine_provincias, una tabla de 50 códigos INE y nombres oficiales, y ine_provincias_join, que añade una clave normalizada para unir fuentes con tildes, barras y nombres alternativos.

Etapa 2: descarga y lectura

comprobacion_descarga_datos() crea data/raw si es necesario, comprueba la existencia de los ocho archivos y descarga únicamente los que no existen o tienen tamaño cero. leer_archivo_ine() aplica el delimitador, la configuración decimal/millar y las etiquetas de ausentes "", "NA", "null" y "..". leer_datos() carga cada fuente en un objeto con sufijo _raw.

Etapa 3: normalización y claves

Cada tabla se lleva a formato tidy. Se separa el texto "código provincia nombre", se rellenan códigos a dos dígitos y se genera: id = año_provincia, por ejemplo, 2019_28. La clave es común a todas las tablas socioeconómicas; para los datos laborales se utiliza (id, Sector).

Etapa 4: agregación de fuentes

1. Vivienda: se corrigen nombres de columnas, se recuperan las comunidades uniprovinciales, se filtra Regimen == "Libre" y se calcula la media trimestral.
2. Población: se conserva el total de ambos sexos y se renombra Total como Habitantes.
3. Maternidad: se conserva el total de órdenes de nacimiento y se convierte el indicador numérico con configuración española.
4. Migración: se conserva Ambos sexos, edades 19--35 y se suman los saldos de esas edades.
5. Ocupación: se pasa a columnas, se calcula Secundario = Industria + Construccion y se vuelve a formato largo.
6. PIB y renta: se filtran indicadores, se corrigen nombres y se resuelven duplicidades entre provincia y comunidad autónoma uniprovincial.
7. VAB: se excluyen impuestos y PIB a precios de mercado; las ramas se suman por sector.

Etapa 5: paneles y persistencia

El panel socioeconómico se forma con seis inner_join() por id. El panel laboral se forma con un cruce por id y Sector. Después los sectores se pasan a columnas, se unen ambos bloques y se separa la clave en Periodo e id_prov. El panel final se guarda en CSV delimitado por punto y coma y en formato binario RData.

Análisis exploratorio

Datos perdidos

Se restringe el panel a 2015--2021. Se contabilizan ausentes por variable y se listan las filas con ausentes. La imputación solo se aplica a Renta_bruta_media y Personas_Ocupadas_Primario, por provincia y en orden temporal: media entre el primer valor válido anterior y posterior; en los extremos se usa el único vecino disponible.

Análisis univariante

Para 2019 se calculan participaciones nacionales de ocupación y VAB. Se muestran histogramas con media, mediana, desviación típica, curtosis y atípicos a más de tres desviaciones. Los boxplots usan la regla 1.5 IQR, con transformaciones visuales para población y migración, pero calculando atípicos sobre la escala original.

Análisis bivariante y multivariante

Se derivan cuatro indicadores: densidad, esfuerzo de vivienda, migración joven por 1.000 habitantes y brecha renta/PIB. La matriz global usa Spearman y ordenamiento jerárquico por 1-|.|. Para explorar heterogeneidad, se estandarizan 11 variables, se calcula distancia euclídea, se aplica hclust(method = "ward.D2") y se cortan cuatro grupos. Finalmente se cartografían las provincias con mapSpain y se calculan matrices de correlación por cluster.

Controles de calidad

El proyecto incluye controles en puntos críticos:

- validar_clave_unica() detiene la ejecución ante duplicados de la clave esperada.
- validar_provincias_50() detecta provincias fuera del alcance y avisa si falta alguna de las 50.
- Se usan inner_join() para que el panel final solo contenga instancias comunes a todas las fuentes.
- Se eliminan explícitamente Ceuta y Melilla del análisis cartográfico y del clustering.
- Se conservan dos formatos de salida: CSV auditable y RData reproducible.

Productos generados por el proyecto

Producto	Uso
data/Datos_SocioEcon.csv/.Rdata	Variables de vivienda, población, maternidad, migración, PIB y renta por provincia-año.
data/Datos_Laborales.csv/.Rdata	Personas ocupadas y VAB por provincia-año-sector.

Producto	Uso
Proyecto_AED.pdf	Informe científico con metodología, figuras, resultados y conclusiones.
ProyectoAED_files/figure-latex/	Figuras incrustadas o auxiliares del informe.
output/pdf/	Esta documentación: estructura, referencia de R y guion oral.

Reproducción recomendada

1. Abrir el proyecto desde ProyectoAED.Rproj para conservar las rutas relativas.
2. Verificar que R y los paquetes listados en la documentación de R están disponibles.
3. Ejecutar primero Utilidades.Rmd o extraerlo con knitr::purl().
4. Ejecutar ProyectoAED.Rmd desde la raíz del proyecto, manteniendo data/raw.
5. Revisar que las validaciones no devuelvan duplicados y que el periodo común siga siendo 2015--2021.
6. Renderizar el informe y comprobar las figuras y tablas antes de entregar.

Limitaciones documentadas

El análisis es exploratorio y provincial: no prueba causalidad. Las participaciones laborales y de VAB están expresadas respecto al total nacional, por lo que el tamaño de la provincia influye. El clustering depende de las variables elegidas, la estandarización, la distancia y el método Ward.D2. Los clusters 3 y 4 tienen muy pocas provincias, de modo que sus correlaciones internas deben interpretarse con especial cautela. El año 2019 es una fotografía pre-pandemia; extender el análisis a 2015--2021 permitiría estudiar la evolución temporal.

Cierre

La estructura del proyecto separa claramente datos brutos, funciones, análisis y productos. Esa separación permite auditar el origen de cada indicador, repetir el pipeline y distinguir entre decisiones de preparación de datos y conclusiones substantivas.