Documentación completa de R del proyecto AED

Librerías, comandos, funciones y parámetros utilizados

Proyecto: Análisis Exploratorio de Datos provincial en España
Autores del proyecto: Luis Molina Villar, Rubén Sánchez Munuera y Pablo Gallart Carbonell
Universitat de València | Fecha: 8 de noviembre de 2026

Documento generado a partir de los archivos locales del proyecto, con revisión de estructura, código y resultados documentados.

Contenido

Convenciones de lectura

Paquetes y configuración

Paquetes declarados

Opciones globales de knitr

Funciones auxiliares propias

Normalización y lectura

Delimitadores efectivamente utilizados

Claves, alcance y validación

Panel e indicadores derivados

Correlaciones y gráficos multivariantes

Datos perdidos y estadísticos

Gráficos univariantes

Procesamiento fuente por fuente

Análisis estadístico final

Clustering

Mapa

Tablas y persistencia

Inventario ampliado de llamadas clave y parámetros

Advertencias y decisiones reproducibles

Referencia rápida de ejecución

Convenciones de lectura

- Código propio: funciones definidas en Utilidades.Rmd. Se documentan con su firma, propósito, argumentos y comportamiento.
- Código de paquete: funciones llamadas con prefijo, como readr::read_delim(), o mediante library() desde el informe.
- Argumento usado: cuando un parámetro no aparece en la llamada, se conserva el valor por defecto de la función; aquí solo se detallan los parámetros que el proyecto fija explícitamente o que son esenciales para entender el resultado.
- Pipelines: %>% pasa el objeto de la izquierda como primer argumento de la función siguiente. :: llama una función sin adjuntar todo el paquete al buscador.

Paquetes y configuración

Paquetes declarados

La lista paquetes_requeridos contiene: rmarkdown, rticles, knitr, tidyverse, mapSpain, sf, corrplot, scales, ggrepel, pheatmap, kableExtra, RColorBrewer y cluster. La instalación se ejecuta solo para los faltantes mediante installed.packages() y install.packages(..., repos = "https://cloud.r-project.org").

Paquete	Papel en el proyecto	Funciones o elementos usados
rmarkdown	Render y extracción de código.	knitr::purl() y flujo R Markdown.
rticles	Plantilla editorial.	mdpi_article.
knitr	Chunks, figuras y extracción.	opts_chunk(), purl().
tidyverse	Manipulación y gráficos.	dplyr, tidyr, readr, stringr, purrr, tibble y ggplot2.
mapSpain	Geometría provincial española.	esp_get_prov().
sf	Áreas y geometrías espaciales.	st_area(), st_drop_geometry(), geom_sf().
corrplot	Matriz de correlaciones.	corrplot(...).
scales	Etiquetas numéricas.	label_number().
ggrepel	Etiquetas sin solapamiento.	geom_text_repel().
pheatmap	Declarado para mapas de calor.	No aparece como llamada directa en el flujo final.
kableExtra	Tablas LaTeX.	kable_styling().
RColorBrewer	Paletas disponibles.	Declarado; el informe usa paletas hex definidas explícitamente.
cluster	Infraestructura estadística declarada.	El clustering final usa dist() y hclust() base.

Opciones globales de knitr

```
knitr::opts_chunk$set(echo = TRUE, warning = FALSE, message = FALSE,
  fig.align = "center", fig.pos = "H", fig.width = 6,
  fig.height = 4, out.width = "100%")
```

echo controla si se muestra el código; warning y message ocultan advertencias y mensajes; fig.align centra figuras; fig.pos = "H" solicita posición fija cuando LaTeX lo permite; fig.width, fig.height fijan pulgadas de salida; out.width limita el ancho final.

Funciones auxiliares propias

Normalización y lectura

Firma	Argumentos	Qué hace
normalizar_nombre_provincia(x)	x: texto o vector	Convierte a carácter; quita tildes con stri_trans_general(..., "Latin-ASCII"); pasa a minúsculas y elimina espacios con str_to_lower(str_squish()); conserva solo a-z0-9.
comprobacion_descarga_datos(ruta_base = "./data/raw")	ruta_base: carpeta	Crea carpeta recursiva; descarga 8 URL si el archivo no existe o pesa 0; comprueba faltantes y devuelve rutas invisibles.
leer_archivo_ine(fichero, separador, decimal = ",", grouping = ".")	Ruta, delimitador, marca decimal, marca de millar	Llama readr::read_delim() con locale, NA personalizados, name_repair = "minimal", show_col_types = FALSE, progress = FALSE.
leer_datos(ruta_base = "./data/raw")	Carpeta de fuentes	Ejecuta la comprobación, carga los ocho CSV con delimitadores individuales, usa list2env() en el entorno llamador y devuelve la lista invisiblemente.
leer_datos_comprobar_existencia()	Sin argumentos	Comprueba con exists() que existan los ocho objetos _raw; imprime éxito o error.

Delimitadores efectivamente utilizados

coste_vivienda_raw	";"	decimal = ".", grouping = "".
Resto de fuentes tabuladas	"\ t"	Por defecto: decimal coma, millar punto.
pib_per_capita_raw	";"	Por defecto: decimal coma, millar punto.

Claves, alcance y validación

Firma	Parámetros	Comportamiento
crear_id_provincia_anio(df, col_anyo, col_prov)	Data frame y columnas capturadas mediante evaluación no estándar	Crea id con paste0() y códigos de provincia con str_pad(width = 2, side = "left", pad = "0").
tratamiento_uniprovinciales(df, variable, uniprov = codigos_uniprov)	Data frame, columna textual y mapa de códigos	Reconstruye codigo_ccaa; reconoce Asturias, Baleares, Cantabria, Madrid, Murcia, Navarra, Rioja, Ceuta y Melilla; rellena CPRO cuando está vacío. El parámetro uniprov está en la firma, aunque el cuerpo indexa el objeto global.
filtrar_provincias_ine(df)	Data frame con id_prov	Rellena el código a 2 dígitos y conserva los 50 códigos de ine_provincias.
validar_clave_unica(df, claves, nombre = "datos")	Claves: texto o vector; nombre para error	Agrupa por claves, cuenta filas y detiene con ejemplos si hay duplicados. Devuelve df invisiblemente.
validar_provincias_50(df, nombre = "panel", periodo = NULL)	Data frame, etiqueta y periodo opcional	Busca provincias inválidas y avisa de provincias faltantes; si periodo no es nulo filtra antes de validar.

Panel e indicadores derivados

Firma	Parámetros usados	Resultado
imputar_panel_provincial(df, variables = c(...))	variables: renta y ocupación primaria	Ordena por provincia/año, agrupa por provincia, aplica imputar_valores_intermedios() con across(any_of(variables)).

Firma	Parámetros usados	Resultado
crear_panel_analisis_2019(df, periodo = 2019)	periodo = 2019	Filtra año, elimina VAB_Total, convierte ocupación/VAB a porcentaje del total nacional y valida las 50 provincias.
crear_panel_bivariante(panel_analisis_2019)	Panel anual	Descarga geometría, calcula área en km^2, y crea esfuerzo_vivienda, mig_joven_1000, Densidad y brecha_pib_renta.

Las fórmulas son:

esfuerzo vivienda &= 90 Precio_m2Renta_bruta_media, & mig. joven/1000 &= Migracion_InteriorHabitantes 1000, Densidad &= Habitantesarea_km2, & brecha PIB-renta &= Renta_bruta_mediaPIB_per_capita.

Correlaciones y gráficos multivariantes

Función	Argumentos	Parámetros críticos
calcular_matriz_correlacion(df, variables, nombres_variables)	Panel, 11 columnas, 11 etiquetas	Selecciona all_of(variables), renombra, elimina NA, calcula cor(method = "spearman"); ordena con hclust(as.dist(1 - abs(matriz)), method = "complete").
graficar_matriz_correlacion(matriz)	Matriz ordenada	corrplot(method = "color", type = "lower", order = "original", addCoef.col = "black", number.cex = 0.7, diag = FALSE); etiquetas negras a 45 grados.
preparar_correlaciones_por_cluster(df, variables, nombres_variables, orden)	Panel con Cluster, variables y orden global	Divide por cluster, calcula Spearman por grupo, reordena filas/columnas, conserva triángulo inferior y marca Contraste = abs(Correlacion) > 0.6.
graficar_correlaciones_por_cluster(df_correlaciones)	Tabla larga de correlaciones	Mapa con geom_tile(), textos con dos decimales, escala de -1 a 1, facetas en 2 columnas y etiquetas repelentes no usadas aquí.

Datos perdidos y estadísticos

Función	Parámetros	Implementación
tabla_instancias_faltantes(df)	Data frame	apply(is.na(df), MARGIN = 2, FUN = sum) y tabla kable() solo con conteos positivos.
tabla_valores_faltantes(df)	Data frame	Selecciona !complete.cases(df), cuenta NA por fila, conserva provincia/periodo/variables afectadas y ordena.
imputar_valores_intermedios(x)	Vector numérico	Usa findInterval() para vecinos válidos y rowMeans(cbind(...), na.rm = TRUE); devuelve el mismo vector si está completo o vacío.
calc_asimetria(x)	Vector	Coeficiente de Fisher sin corrección: tercer momento centrado dividido por la desviación al cubo.
calc_curtosis(x)	Vector	Exceso de curtosis: cuarto momento estandarizado menos 3.
calc_cv(x)	Vector	CV en porcentaje sd(x)/mean(x)*100; devuelve NA_real_ si hay negativos, media no positiva o vector vacío.
fmt_es(x, d = 2)	Vector y decimales	Formatea con punto de millares, coma decimal; los NA se convierten en un guion.

Gráficos univariantes

histograma_estadisticos_outliers(df, variables, eje = fmt_eje, tema = tema_graficos_univariantes) usa pivot_longer() para conservar provincia, calcula mediana, media, sd() y curtosis, marca outliers con |x-x|>3s y compone ggplot() con:

- geom_histogram(bins = 12, aes(y = after_stat(density)), fill = "grey80", colour = "white", na.rm = TRUE);
- geom_density(colour = "steelblue", linewidth = 0.7, na.rm = TRUE);
- dos geom_vline() para mediana y media, con linetypes manuales;
- geom_text_repel(..., direction = "both", segment.size = 0.4, max.overlaps = Inf) para nombres de atípicos;
- facet_wrap(..., scales = "free", ncol = 3) y etiquetas de eje con scales::label_number(big.mark = ".", decimal.mark = ",").

boxplot_estadisticos_outliers(df, variables_boxplot) calcula Q1, Q3, IQR, límites Q11.5IQR, asimetría y MADM. La población se presenta como log10(Habitantes) y la migración como sign(x)|x|^1/3 solo para visualización. El eje Y usa scale_y_log10(labels = fmt_eje, expand = expansion(mult = c(0.06,0.06))). geom_text_repel() fija seed = 123, max.overlaps = Inf, direction = "y" y force = 1.2.

boxplot_laborales(df) transforma seis variables sectoriales a largo, clasifica por magnitud y sector, calcula IQR por grupo, dibuja puntos jitter con height = 0.15, boxplots horizontales y etiquetas rojas de atípicos con seed = 123. Usa dos facetas verticales y escala X compartida.

Procesamiento fuente por fuente

Fuente	Cadena exacta de decisiones
Vivienda	Renombrar Periodo, Regimen, Comunidad_Autonoma; aplicar tratamiento_uniprovinciales(variable = "Comunidad_Autonoma"); eliminar códigos autonómicos; renombrar CPRO a id_prov; filtrar 50 provincias y Regimen == "Libre"; agrupar por id; media de Valor; seleccionar id, Precio_m2.
Población	separate(Provincias, into = c("id_prov","Provincia"), sep = " ", extra = "merge"); filtrar 50; Sexo == "Total"; renombrar Total a Habitantes.
Maternidad	Renombrar orden; filtrar "Todos"; separar provincia; convertir Total con parse_number(..., locale = locale(decimal_mark = ",", grouping_mark = ".")); renombrar.
Migración	Filtrar Sexo == "Ambos sexos"; separar provincia; Edad = parse_number(Edad); filtrar 19 Edad35; sumar Total por id.
Ocupación	Normalizar construcción; pivot_wider(names_from = sector_econ, values_from = Total); sumar industria y construcción; promedio por id; pivot_longer() de total/sectores.
PIB	Abrir magnitudes, separar provincia, rellenar códigos, detectar provincia vs CCAA uniprovincial, reemplazar código autonómico, elegir provincia con slice_max(order_by = es_provincia, n = 1, with_ties = FALSE).
Renta	Filtrar indicador exacto; eliminar columnas 1, 2 e Islas; quitar códigos iniciales con str_remove(); corregir Murcia; unir con catálogo INE; promediar duplicados por clave.
VAB	Separar provincia; filtrar dos ramas no deseadas; abrir ramas; eliminar columnas que empiezan por Valor...bruto total; sumar ramas en secundario y terciario; pasar a largo.

Análisis estadístico final

Clustering

```
datos_cluster_estandarizados <- scale(datos_cluster_2019)
distancia_provincias <- dist(datos_cluster_estandarizados,
                             method = "euclidean")
dendrograma_provincias <- hclust(distancia_provincias,
                                 method = "ward.D2")
asignacion_clusters <- cutree(dendrograma_provincias, k = 4)
```

scale() centra y escala cada variable; dist(method = "euclidean") calcula distancias; hclust(method = "ward.D2") construye el dendrograma; cutree(k = 4) asigna cuatro clusters.

Mapa

mapSpain::esp_get_prov(prov = setdiff(esp_get_prov().prov.name, c("Ceuta","Melilla"))) obtiene la geometría provincial excluyendo las dos ciudades autónomas. sf::st_area(geometry) calcula área; la división por 1e6 convierte metros cuadrados a km^2. geom_sf(aes(fill = Cluster), color = "white", size = 0.3) representa los polígonos.

Tablas y persistencia

- save(objeto, file = "...Rdata") serializa objetos R.
- write_delim(..., delim = ";") escribe CSV compatible con el formato de salida del proyecto.
- kable(format = "latex", booktabs = TRUE, longtable = FALSE, caption = ..., digits = 2) crea tablas LaTeX; kable_styling(latex_options = c("hold_position", "scale_down"), full_width = FALSE) controla posición y escala.

Inventario ampliado de llamadas clave y parámetros

Llamada	Parámetros/efecto
filter(id_prov %in% ine_provincias_prov)	Conserva solo los códigos del catálogo oficial.
separate(..., sep = " ", extra = "merge")	Divide código y nombre; extra = "merge" evita romper nombres con espacios.
pivot_wider(names_from = ..., values_from = ...)	Convierte categorías en columnas.
pivot_longer(cols = ..., names_to = ..., values_to = ...)	Convierte columnas sectoriales en filas tidy.
group_by(...); summarise(..., .groups = "drop")	Agrupa y devuelve tabla sin agrupación persistente.
mutate(across(..., mean, na.rm = TRUE))	Aplica media a varias columnas respetando NA.
left_join(..., by = ...)	Añade geometría/códigos sin perder provincias del panel izquierdo.
inner_join(..., by = ...)	Conserva solo coincidencias comunes.
drop_na()	Elimina filas incompletas antes de calcular correlación.
facet_wrap(..., ncol = 3)	Organiza paneles gráficos en tres columnas.
theme_minimal(base_size = 10)	Tema limpio con tamaño base 10.
coord_cartesian(clip = "off")	Permite etiquetas fuera del panel sin truncarlas.

Advertencias y decisiones reproducibles

1. El orden de ramas en VAB se obtiene con unique() e índices de posición; si cambia la fuente, debe revisarse el mapeo de ramas.
2. tratamiento_uniprovinciales() declara uniprov pero usa el mapa global codigos_uniprov; documentarlo evita confundir la interfaz con el comportamiento real.
3. Los porcentajes de ocupación y VAB son porcentajes del total nacional por columna y no cuotas internas de cada provincia.

4. Las correlaciones por cluster con grupos pequeños pueden ser degeneradas; el propio informe advierte que en clusters de dos elementos aparecen valores 1 o -1.
5. La imputación está acotada a dos variables y se realiza en el panel completo ordenado temporalmente; no es una interpolación estadística general para todas las columnas.

Referencia rápida de ejecución

```
knitr::purl("Utilidades.Rmd", output = "codigo_extraido.R")
source("codigo_extraido.R")
leer_datos()
panel_analisis_2019 <- crear_panel_analisis_2019(panel_provincial, 2019)
panel_bivariante_2019 <- crear_panel_bivariante(panel_analisis_2019)
correlacion_global <- calcular_matriz_correlacion(
  panel_bivariante_2019, variables_cluster, nombres_variables_cluster)
```