Informe Analítico Exhaustivo: Dataset Socioeconómico de las Provincias Españolas (`datos_socioecon_ESP`)

Análisis Exploratorio Longitudinal, Estructura Espacial, Modelización Multivariante y Datos de Panel

Análisis de Datos Socioeconómicos

2026-10-30

Contents

1. Introducción y Carga de Datos **1**

2. Control de Calidad, Integridad y Diagnóstico de Ausentes **3**
2.1. Estructura de Tipos de Datos e Identificación de Valores Faltantes . . . 3
2.2. Resumen Estadístico Descriptivo Universal . . . 5

3. Análisis Univariante de Distribuciones e Identificación de Sesgos **6**
3.1. Densidades Empíricas e Histogramas . . . 6
3.2. Detección de Valores Atípicos (Outliers) . . . 7

4. Análisis Longitudinal y Dinámica Temporal **8**
4.1. Evolución Promedio Nacional y Divergencia Interprovincial . . . 8
4.2. Trayectorias Provinciales Seleccionadas . . . 10

5. Cartografía Espacial y Coropletas (mapSpain + sf) **11**
5.1. Distribución Espacial en el Período Reciente (2026) . . . 12
5.2. Panel Multivariante Espacial Comparativo . . . 13

6. Análisis Correlacional y Bivariante **14**
6.1. Matriz de Correlación de Pearson . . . 14
6.2. Diagramas de Dispersión y Ajuste LOESS . . . 15

7. Modelización Multivariante: PCA y Clustering Provincial **16**
7.1. Análisis de Componentes Principales (PCA) . . . 16
7.2. Biplot Factorial . . . 17
7.3. Agrupamiento K-Means . . . 18

8. Modelización Econométrica de Datos de Panel (Efectos Fijos) **19**

9. Conclusiones y Sintesis **20**

1. Introducción y Carga de Datos

Este informe realiza un análisis exhaustivo del panel longitudinal `datos_socioecon_ESP`, estructurado a nivel provincial con la clave primaria `id_obs = {Periodo}_{id_prov}`.

El objetivo central es diagnosticar la estructura interna del dataset, analizar la distribución espacial de los indicadores socioeconómicos, evaluar la dinámica temporal y segmentar el territorio español mediante análisis multivariante, de conglomerados y regresión de datos de panel.

```
datos_socioecon_ESP <- read_delim(
  "./data/Datos_SocioEcon.csv",
  delim = ";",
  na = c("NA", "", "NULL"),
  col_types = cols(.default = col_character()),
  locale = locale(encoding = "UTF-8"),
  show_col_types = FALSE
)

# El CSV mezcla coma y punto como separador decimal. Leemos primero como texto
# y convertimos las columnas cuantitativas de forma explícita para no perder
# valores al cambiar de configuración regional.
names(datos_socioecon_ESP)[1:2] <- c("Periodo", "Provincia")
vars_dato <- setdiff(names(datos_socioecon_ESP), c("Periodo", "Provincia"))
datos_socioecon_ESP <- datos_socioecon_ESP %>%
  mutate(
    Periodo = as.integer(Periodo),
    across(all_of(vars_dato), ~ as.numeric(str_replace(.x, ",", ".")))
  )

# Verificación del objeto 'datos_socioecon_ESP' en el entorno global
if (!exists("datos_socioecon_ESP")) {
  stop("El objeto 'datos_socioecon_ESP' no está presente en el entorno global. Asegúrese de haber ejecu
}

# Preparación y estandarización del dataset
df_analisis <- datos_socioecon_ESP

# El CSV no incluye el código provincial; lo recuperamos desde la geometría
# oficial de mapSpain usando el nombre de la provincia como clave.
lookup_provincias <- esp_get_prov() %>%
  st_drop_geometry() %>%
  transmute(id_prov = str_pad(as.character(cpro), 2, side = "left", pad = "0"),
            Provincia = as.character(ine.prov.name))

df_analisis <- df_analisis %>%
  left_join(lookup_provincias %>% rename(id_prov = id_prov, Provincia_mapa = Provincia),
            by = c("Provincia" = "Provincia_mapa"))

if (anyNA(df_analisis$id_prov)) {
  # El nombre puede diferir solo por tildes o por la denominación bilingüe.
  normaliza_prov <- function(x) {
    x %>% stringi::stri_trans_general("Latin-ASCII") %>%
      str_to_lower() %>% str_replace_all("[^a-z0-9]", "")
  }
  lookup_flexible <- lookup_provincias %>%
    mutate(Provincia_key = normaliza_prov(Provincia))
  df_analisis <- df_analisis %>%
    mutate(Provincia_key = normaliza_prov(Provincia)) %>%
    select(-id_prov) %>%
```

```
    left_join(lookup_flexible %>% select(id_prov, Provincia_key), by = "Provincia_key") %>%
    select(-Provincia_key)
}

if (anyNA(df_analisis$id_prov)) {
  stop("No se pudo asignar el código provincial a todas las filas del CSV.")
}
df_analisis <- df_analisis %>% select(-any_of("Provincia_mapa"))

# Resumen estructural
num_obs <- nrow(df_analisis)
num_provs <- n_distinct(df_analisis$id_prov)
periodo_min <- min(df_analisis$Periodo, na.rm = TRUE)
periodo_max <- max(df_analisis$Periodo, na.rm = TRUE)
```

El panel de datos contiene un total de **2704** observaciones correspondientes a **52** unidades territoriales (provincias y ciudades autónomas), cubriendo un rango temporal de **1975** a **2026**.

---

2. Control de Calidad, Integridad y Diagnóstico de Ausentes

2.1. Estructura de Tipos de Datos e Identificación de Valores Faltantes

Antes del análisis descriptivo, auditamos la tasa de valores ausentes (`NA`) por variable para descartar sesgos sistemáticos derivados del proceso de unión o desalineación temporal de las fuentes originales del INE.

```
# Diagnóstico de valores ausentes por variable
missing_summary <- df_analisis %>%
  summarise(across(everything(), ~ sum(is.na(.)))) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "NA_Count") %>%
  mutate(
    NA_Percent = (NA_Count / nrow(df_analisis)) * 100
  ) %>%
  arrange(desc(NA_Percent))

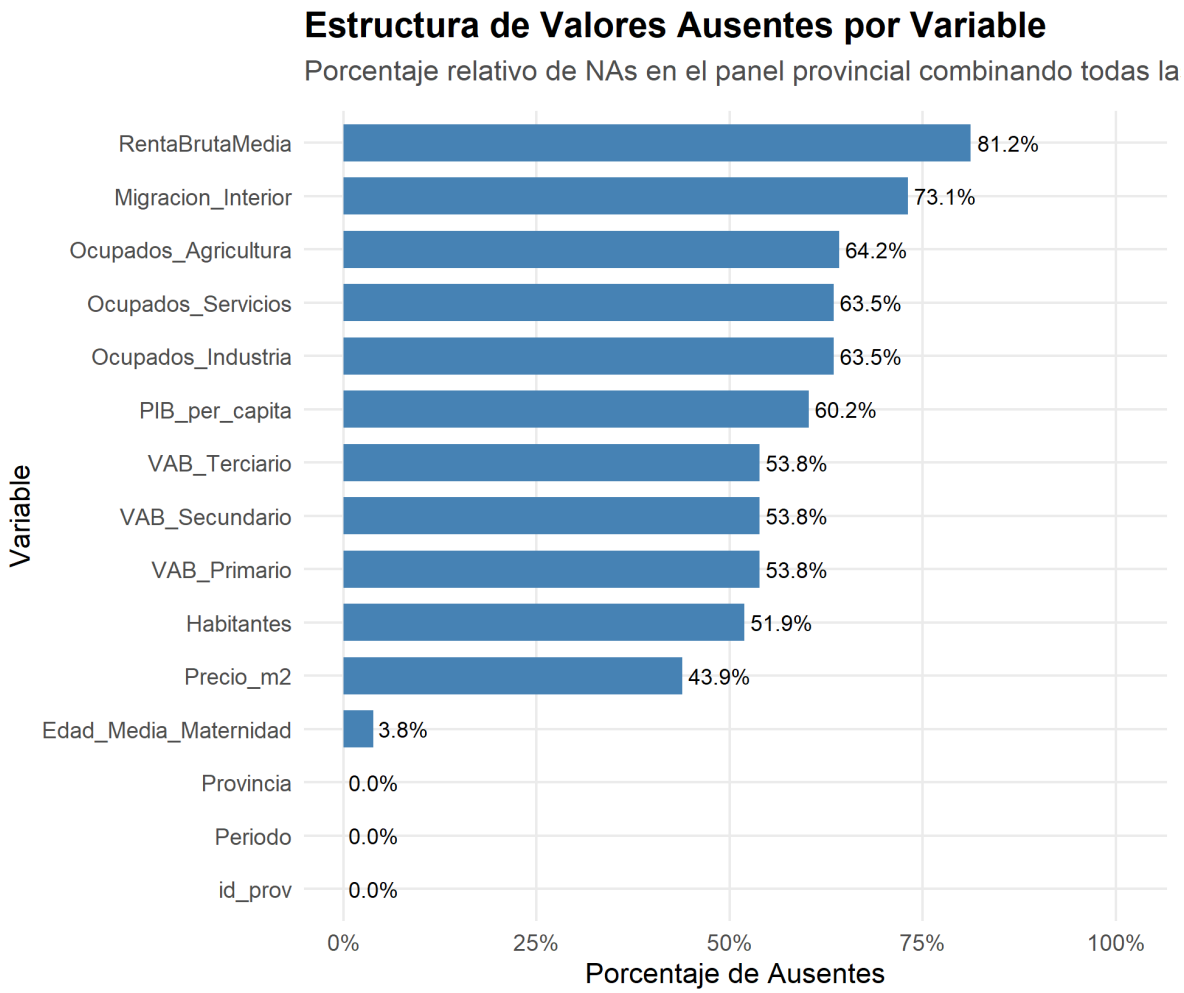
missing_summary %>%
  kable(
    caption = "Tabla 2.1: Diagnóstico de Valores Ausentes por Variable",
    col.names = c("Variable", "Conteo de NAs", "Porcentaje (%)"),
    digits = 2
  ) %>%
  style_table(bootstrap_options = c("striped", "hover", "condensed"), full_width = FALSE)
```

Table 1: Tabla 2.1: Diagnóstico de Valores Ausentes por Variable

Variable	Conteo de NAs	Porcentaje (%)
RentaBrutaMedia	2196	81.21
Migracion_Interior	1976	73.08
Ocupados_Agricultura	1736	64.20
Ocupados_Industria	1716	63.46
Ocupados_Servicios	1716	63.46
PIB_per_capita	1629	60.24
VAB_Primario	1456	53.85

Variable	Conteo de NAs	Porcentaje (%)
VAB_Secundario	1456	53.85
VAB_Terciario	1456	53.85
Habitantes	1404	51.92
Precio_m2	1186	43.86
Edad_Media_Maternidad	104	3.85
Periodo	0	0.00
Provincia	0	0.00
id_prov	0	0.00

```
# Gráfico de perfil de completitud
ggplot(missing_summary, aes(x = reorder(Variable, NA_Percent), y = NA_Percent)) +
  geom_col(fill = "steelblue", width = 0.7) +
  geom_text(aes(label = sprintf("%.1f%%", NA_Percent)), hjust = -0.1, size = 3) +
  coord_flip() +
  scale_y_continuous(limits = c(0, max(missing_summary$NA_Percent, 10) * 1.25), labels = percent_format
  labs(
    title = "Estructura de Valores Ausentes por Variable",
    subtitle = "Porcentaje relativo de NAs en el panel provincial combinando todas las observaciones",
    x = "Variable",
    y = "Porcentaje de Ausentes"
  )
```



2.2. Resumen Estadístico Descriptivo Universal

Calculamos los estadísticos de tendencia central, dispersión y forma (media, mediana, desviación estándar, Rango Intercuartílico, mínimo y máximo) para el conjunto completo de variables cuantitativas.

```
# Selección de variables cuantitativas
vars_num <- df_analisis %>%
  select(where(is.numeric)) %>%
  select(-any_of(c("Periodo"))) %>%
  colnames()

resumen_cuant <- df_analisis %>%
  pivot_longer(cols = all_of(vars_num), names_to = "Variable", values_to = "Valor") %>%
  group_by(Variable) %>%
  summarise(
    N = sum(!is.na(Valor)),
    Media = mean(Valor, na.rm = TRUE),
    Desv_Est = sd(Valor, na.rm = TRUE),
    Mediana = median(Valor, na.rm = TRUE),
    IQR = IQR(Valor, na.rm = TRUE),
    Min = min(Valor, na.rm = TRUE),
    Max = max(Valor, na.rm = TRUE),
```

```
    .groups = "drop"
  )

resumen_cuant %>%
  kable(
    caption = "Tabla 2.2: Estadísticos Descriptivos Universales de Variables Cuantitativas",
    digits = 2
  ) %>%
  style_table(bootstrap_options = c("striped", "hover", "condensed"), full_width = TRUE)
```

Table 2: Tabla 2.2: Estadísticos Descriptivos Universales de Variables Cuantitativas

Variable	N	Media	Desv_Est	Mediana	IQR	Min	Max
Edad_Media_Maternidad	260	30.30	1.56	30.31	2.69	27.05	33.67
Habitantes	1300	861332.25	1090491.72	578135.00	657041.75	56929.00	6779888.00
Migracion_Interior	728	0.32	1621.30	-250.50	672.50	-2658.00	15116.00
Ocupados_Agricultura	968	15237.44	13489.47	11450.00	12425.00	100.00	80575.00
Ocupados_Industria	988	78820.92	105835.64	49225.00	64927.08	1125.00	855675.00
Ocupados_Servicios	988	281008.22	431469.85	163450.00	216400.00	20750.00	3057466.67
PIB_per_capita	1075	21551.50	5584.35	20385.00	7366.00	10432.00	43303.00
Precio_m2	1518	10430.43	6063.02	9907.75	4417.91	1545.75	133578.75
RentaBrutaMedia	508	14741.44	2973.21	14419.50	4022.00	9304.00	25117.00
VAB_Primario	1248	546553.69	405494.90	469575.50	481140.00	489.00	2904477.00
VAB_Secundario	1248	7012602.56	10002028.11	4124682.50	5872683.50	102075.00	73969934.00
VAB_Terciario	1248	13294184.93	24650674.20	7033407.50	10375369.50	695230.00	233945973.00

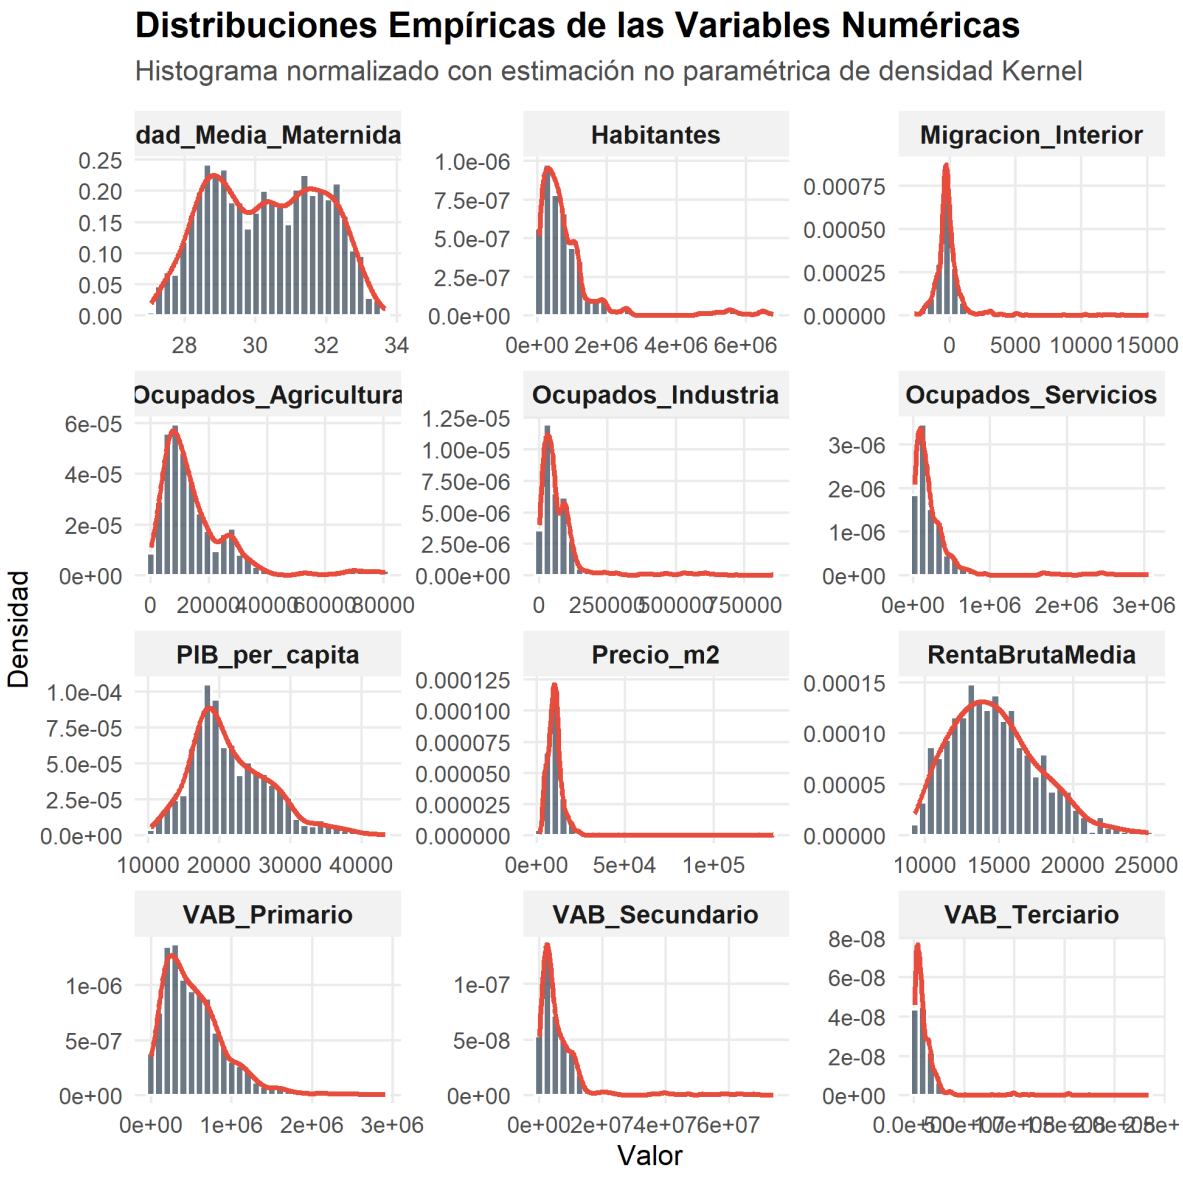
---

3. Análisis Univariante de Distribuciones e Identificación de Sesgos

3.1. Densidades Empíricas e Histogramas

Evaluamos la forma analítica de las distribuciones para detectar asimetría positiva en métricas económicas frente a métricas demográficas.

```
df_analisis %>%
  select(all_of(vars_num)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>%
  filter(!is.na(Valor)) %>%
  ggplot(aes(x = Valor)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30, fill = "#2C3E50", color = "white", alpha = 0.
  geom_density(color = "#E74C3C", linewidth = 1) +
  facet_wrap(~ Variable, scales = "free", ncol = 3) +
  labs(
    title = "Distribuciones Empíricas de las Variables Numéricas",
    subtitle = "Histograma normalizado con estimación no paramétrica de densidad Kernel",
    x = "Valor",
    y = "Densidad"
  )
```

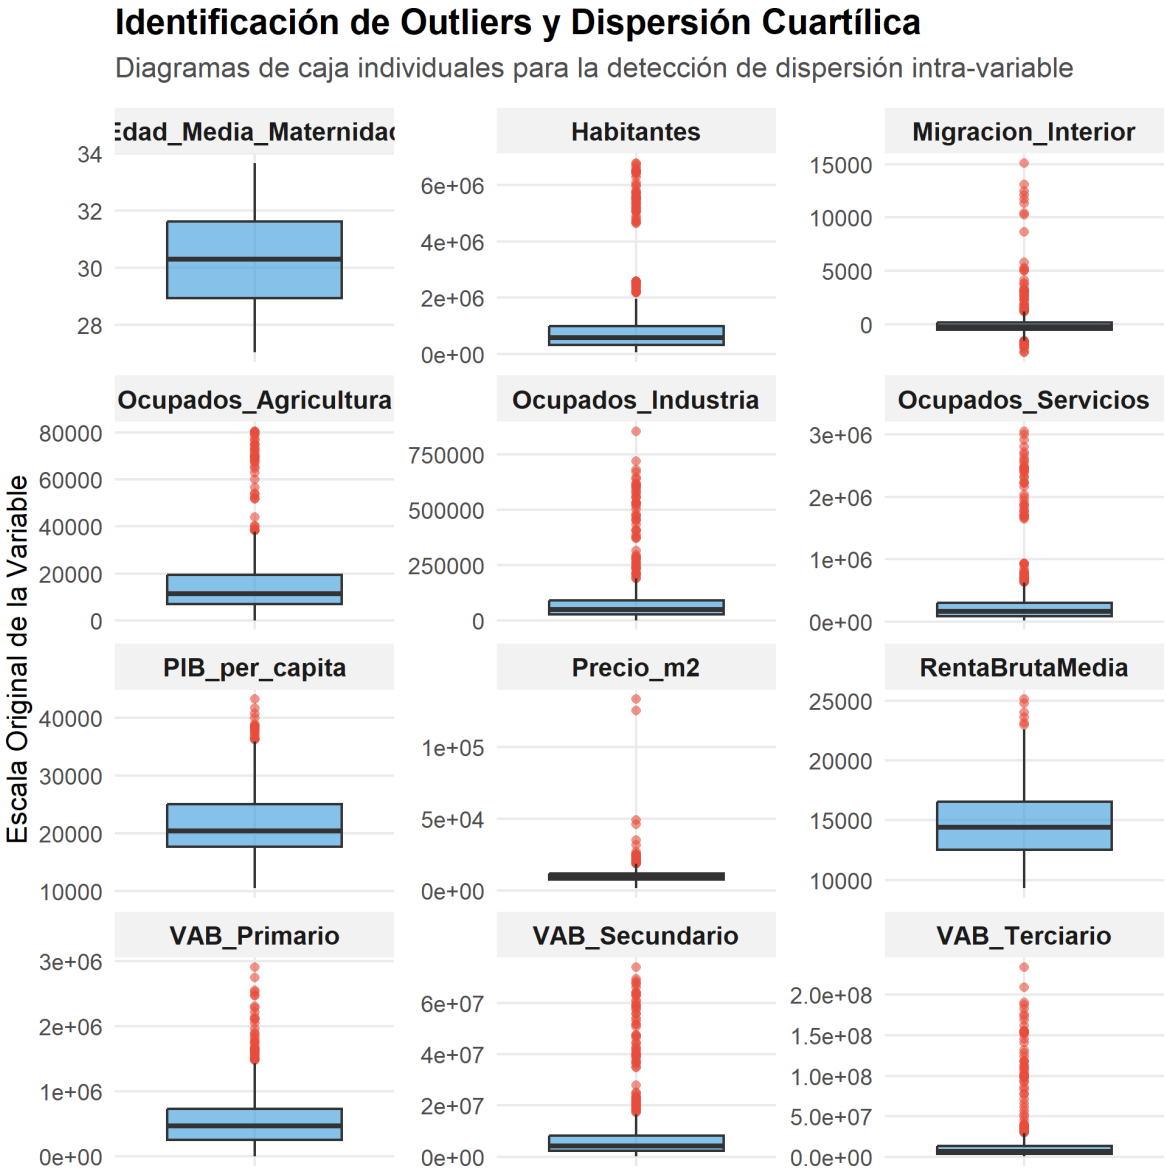


3.2. Detección de Valores Atípicos (Outliers)

Mediante diagramas de caja (boxplots), analizamos las provincias que se posicionan sistemáticamente como valores atípicos estructurales.

```
df_analisis %>%
  select(all_of(vars_num)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to = "Valor") %>%
  filter(!is.na(Valor)) %>%
  ggplot(aes(x = Variable, y = Valor)) +
  geom_boxplot(fill = "#3498DB", alpha = 0.6, outlier.color = "#E74C3C", outlier.shape = 16) +
  facet_wrap(~ Variable, scales = "free", ncol = 3) +
  theme(axis.text.x = element_blank(), axis.ticks.x = element_blank()) +
  labs(
    title = "Identificación de Outliers y Dispersión Cuartílica",
    subtitle = "Diagramas de caja individuales para la detección de dispersión intra-variable",
```

```
    x = NULL,
    y = "Escala Original de la Variable"
  )
```



---

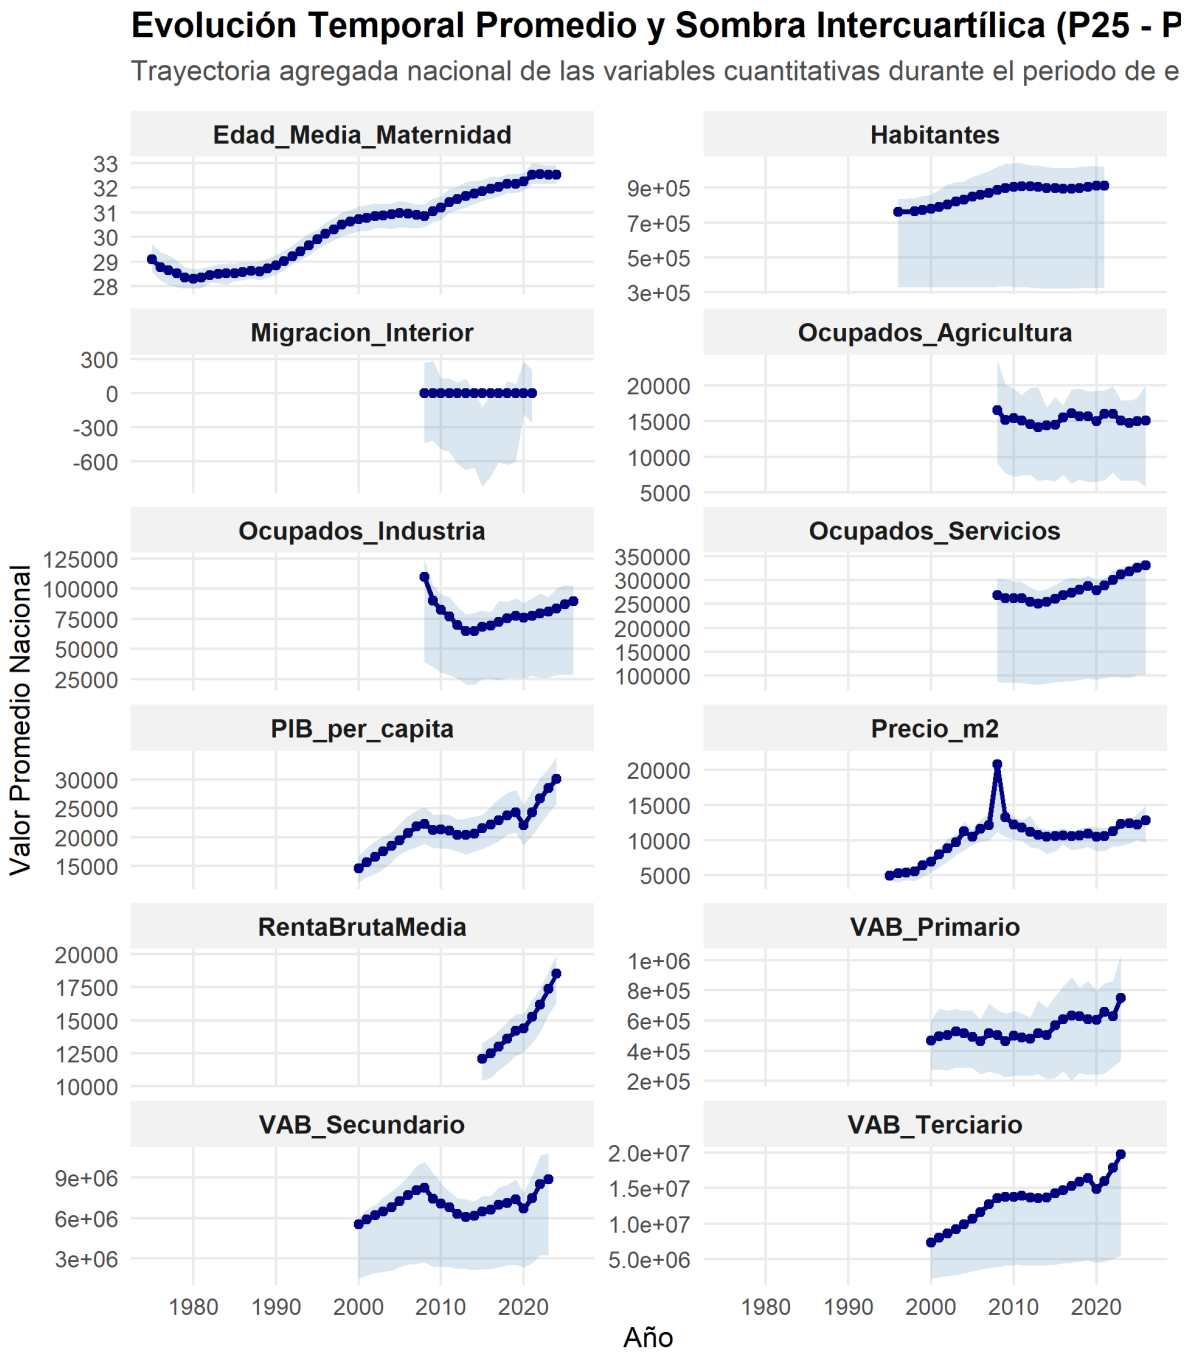
4. Análisis Longitudinal y Dinámica Temporal

4.1. Evolución Promedio Nacional y Divergencia Interprovincial

Analizamos las líneas de tendencia central ponderadas y la envolvente de dispersión (intervalo intercuartílico P25–P75).

```
df_analisis %>%
  select(Periodo, all_of(vars_num)) %>%
  pivot_longer(cols = -Periodo, names_to = "Variable", values_to = "Valor") %>%
```

```r
  filter(!is.na(Valor)) %>%
  group_by(Periodo, Variable) %>%
  summarise(
    Media = mean(Valor, na.rm = TRUE),
    Q25 = quantile(Valor, 0.25, na.rm = TRUE),
    Q75 = quantile(Valor, 0.75, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = Periodo, y = Media)) +
  geom_ribbon(aes(ymin = Q25, ymax = Q75), fill = "steelblue", alpha = 0.2) +
  geom_line(color = "navy", linewidth = 1) +
  geom_point(color = "navy", size = 1.5) +
  facet_wrap(~ Variable, scales = "free_y", ncol = 2) +
  scale_x_continuous(breaks = pretty_breaks()) +
  labs(
    title = "Evolución Temporal Promedio y Sombra Intercuartílica (P25 - P75)",
    subtitle = "Trayectoria agregada nacional de las variables cuantitativas durante el periodo de estu
    x = "Año",
    y = "Valor Promedio Nacional"
  )
```



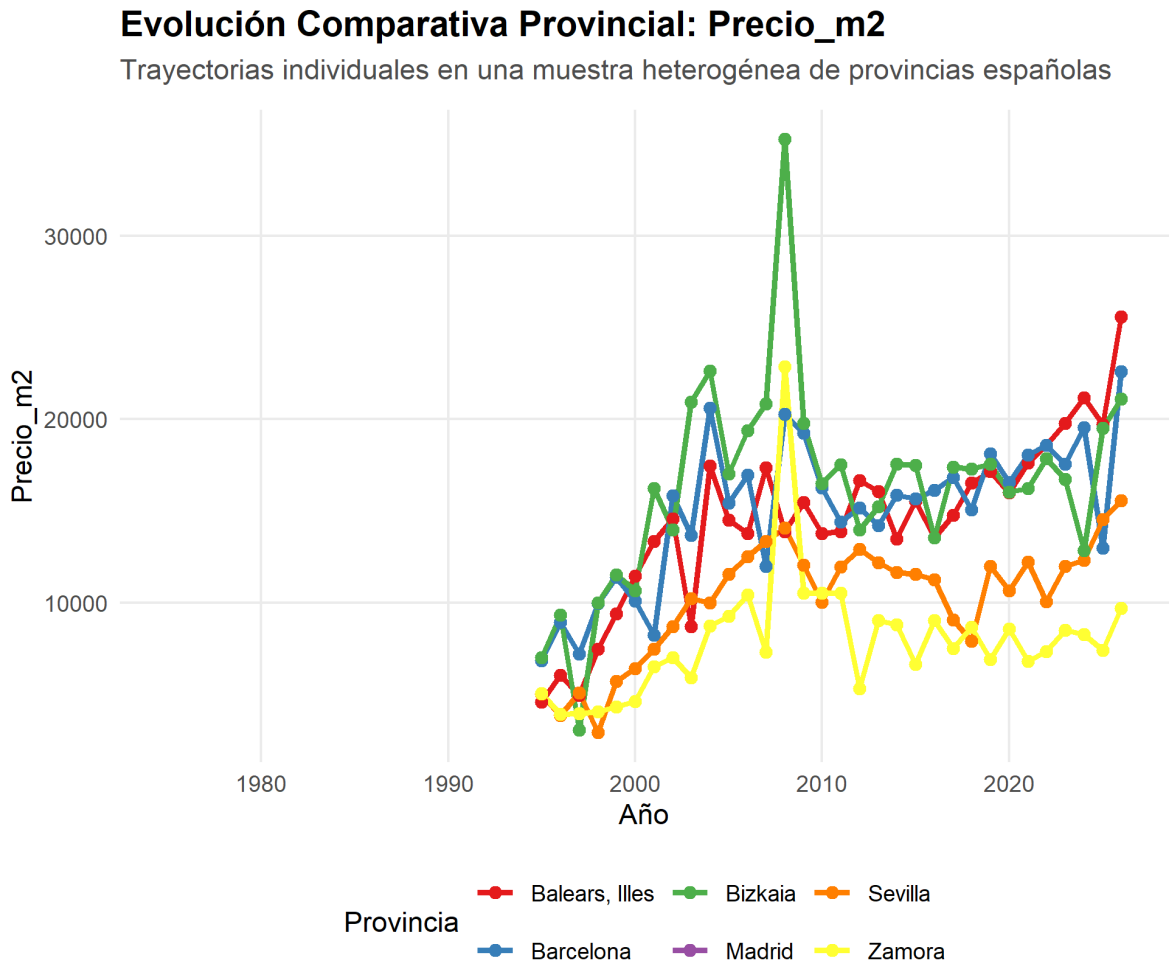
4.2. Trayectorias Provinciales Seleccionadas

Comparación del comportamiento de provincias con perfiles económicos contrastados (ej. Madrid, Barcelona, Sevilla, Bizkaia, Zamora, Baleares).

```
provs_muestra <- c("28", "08", "41", "48", "49", "07") # Madrid, Barcelona, Sevilla, Bizkaia, Zamora, B
var_ilustrativa <- vars_num[1]

df_analisis %>%
  filter(id_prov %in% provs_muestra) %>%
```

```
  ggplot(aes(x = Periodo, y = .data[[var_ilustrativa]], color = Provincia, group = Provincia)) +
  geom_line(linewidth = 1.1) +
  geom_point(size = 2) +
  scale_color_brewer(palette = "Set1") +
  scale_x_continuous(breaks = pretty_breaks()) +
  labs(
    title = paste("Evolución Comparativa Provincial:", var_ilustrativa),
    subtitle = "Trayectorias individuales en una muestra heterogénea de provincias españolas",
    x = "Año",
    y = var_ilustrativa,
    color = "Provincia"
  )
```



---

5. Cartografía Espacial y Coropletas (mapSpain + sf)

```
# Recuperación de la cartografía oficial de provincias
mapa_provs <- esp_get_prov() %>%
  mutate(cpro = str_pad(cpro, width = 2, side = "left", pad = "0")) %>%
  filter(!cpro %in% c("51", "52"))
```

```r
ultimo_periodo <- max(df_analisis$Periodo, na.rm = TRUE)

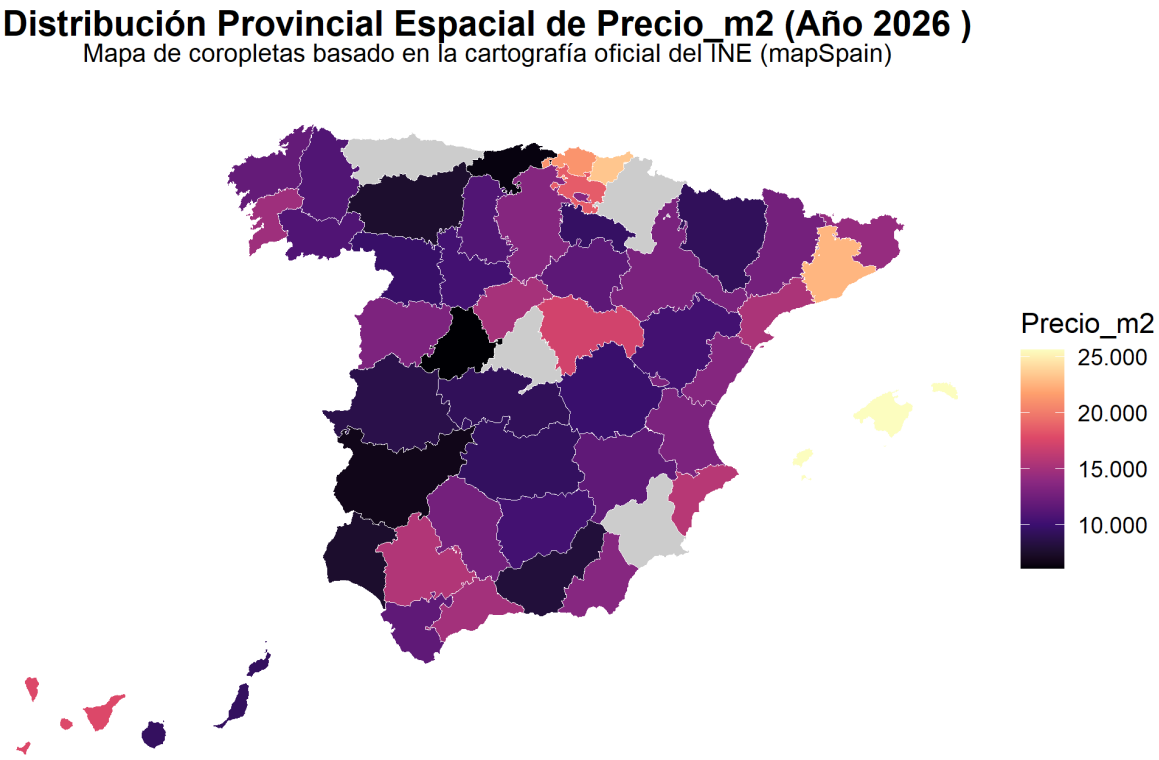
df_reciente <- df_analisis %>%
  filter(Periodo == ultimo_periodo)

mapa_datos <- mapa_provs %>%
  left_join(df_reciente, by = c("cpro" = "id_prov"))
```

5.1. Distribución Espacial en el Período Reciente (2026)

```r
var_mapa <- vars_num[1]

ggplot(mapa_datos) +
  geom_sf(aes(fill = .data[[var_mapa]]), color = "white", size = 0.15) +
  scale_fill_viridis_c(
    option = "magma",
    na.value = "grey80",
    labels = comma_format(big.mark = ".")
  ) +
  labs(
    title = paste("Distribución Provincial Espacial de", var_mapa, "(Año", ultimo_periodo, ")"),
    subtitle = "Mapa de coropletas basado en la cartografía oficial del INE (mapSpain)",
    fill = var_mapa,
    caption = "Fuente: Elaboración propia a partir de datos_socioecon_ESP."
  ) +
  theme_void() +
  theme(
    legend.position = "right",
    plot.title = element_text(face = "bold", size = 14, hjust = 0.5),
    plot.subtitle = element_text(size = 10, hjust = 0.5, margin = margin(b = 10))
  )
```



Fuente: Elaboración propia a partir de datos_socioecon_ESP.

5.2. Panel Multivariante Espacial Comparativo

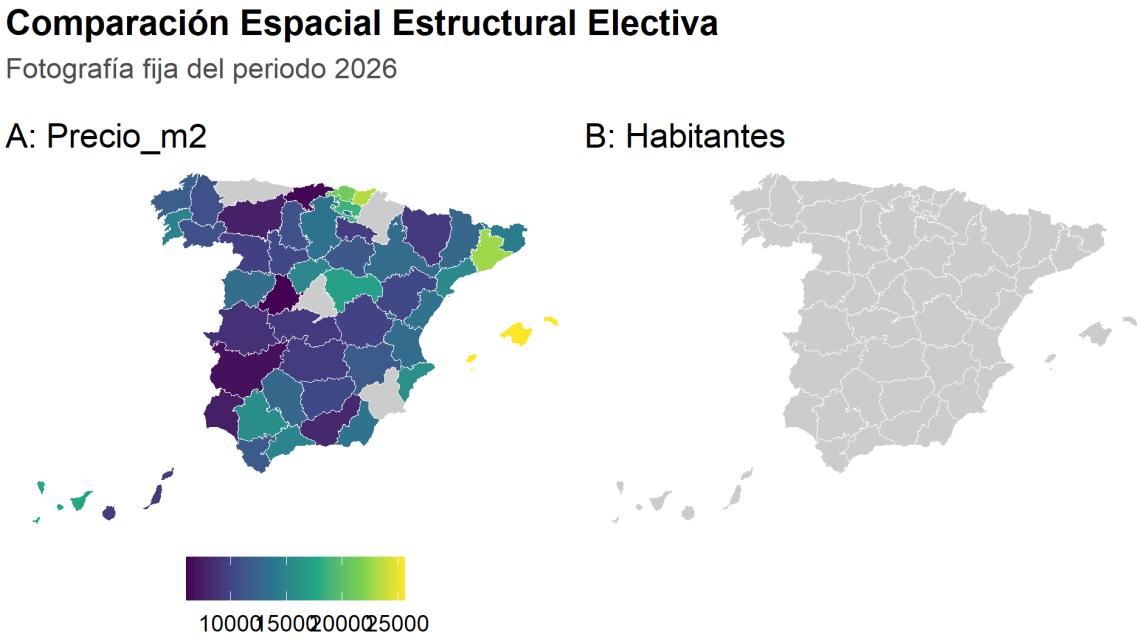
```
if (length(vars_num) >= 2) {
  var1 <- vars_num[1]
  var2 <- vars_num[2]

  p1 <- ggplot(mapa_datos) +
    geom_sf(aes(fill = .data[[var1]]), color = "white", size = 0.1) +
    scale_fill_viridis_c(option = "viridis", na.value = "grey80") +
    labs(title = paste("A:", var1), fill = NULL) +
    theme_void() +
    theme(legend.position = "bottom")

  p2 <- ggplot(mapa_datos) +
    geom_sf(aes(fill = .data[[var2]]), color = "white", size = 0.1) +
    scale_fill_viridis_c(option = "plasma", na.value = "grey80") +
    labs(title = paste("B:", var2), fill = NULL) +
    theme_void() +
    theme(legend.position = "bottom")

  p1 + p2 +
```

```
    plot_annotation(
      title = "Comparación Espacial Estructural Electiva",
      subtitle = paste("Fotografía fija del periodo", ultimo_periodo)
    )
}
```



---

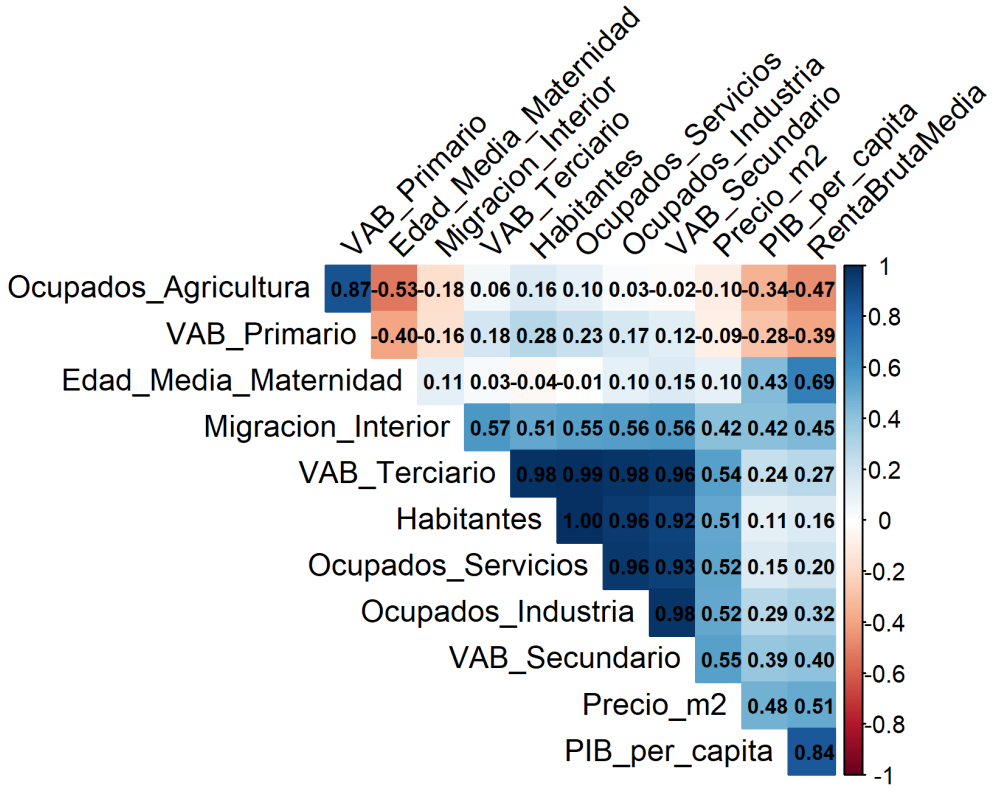
6. Análisis Correlacional y Bivariante

6.1. Matriz de Correlación de Pearson

```
matriz_corr <- df_analisis %>%
  select(all_of(vars_num)) %>%
  drop_na() %>%
  cor(method = "pearson")

corrplot(
  matriz_corr,
  method = "color",
  type = "upper",
  order = "hclust",
  addCoef.col = "black",
  number.cex = 0.7,
  tl.col = "black",
  tl.srt = 45,
  diag = FALSE,
  title = "Matriz de Correlación Lineal de Pearson",
```

```
  mar = c(0, 0, 2, 0)
)
```



6.2. Diagramas de Dispersión y Ajuste LOESS

```
if (length(vars_num) >= 2) {
  v_x <- vars_num[1]
  v_y <- vars_num[2]

  ggplot(df_analisis, aes(x = .data[[v_x]], y = .data[[v_y]])) +
    geom_point(aes(color = as.factor(Periodo)), alpha = 0.5, size = 2) +
    geom_smooth(method = "loess", color = "black", linetype = "dashed", se = TRUE) +
    geom_smooth(method = "lm", color = "red", se = FALSE) +
    scale_color_viridis_d(option = "cividis", name = "Año") +
    labs(
      title = paste("Relación Bivariante:", v_x, "vs.", v_y),
      subtitle = "Puntos coloreados por periodo con ajuste lineal (rojo) y LOESS no paramétrico (negro)
      x = v_x,
      y = v_y
    )
}
```



---

7. Modelización Multivariante: PCA y Clustering Provincial

7.1. Análisis de Componentes Principales (PCA)

```
df_pca_raw <- df_analisis %>%
  filter(Periodo >= (periodo_min)) %>%
  group_by(id_prov, Provincia) %>%
  summarise(across(all_of(vars_num), ~ mean(., na.rm = TRUE)), .groups = "drop")

vars_pca <- vars_num[
  vapply(df_pca_raw[vars_num], function(x) isTRUE(is.numeric(x) && sd(x) > 0), logical(1))
]
if (length(vars_pca) < 2) {
  stop("No hay al menos dos variables no constantes disponibles para el PCA.")
}

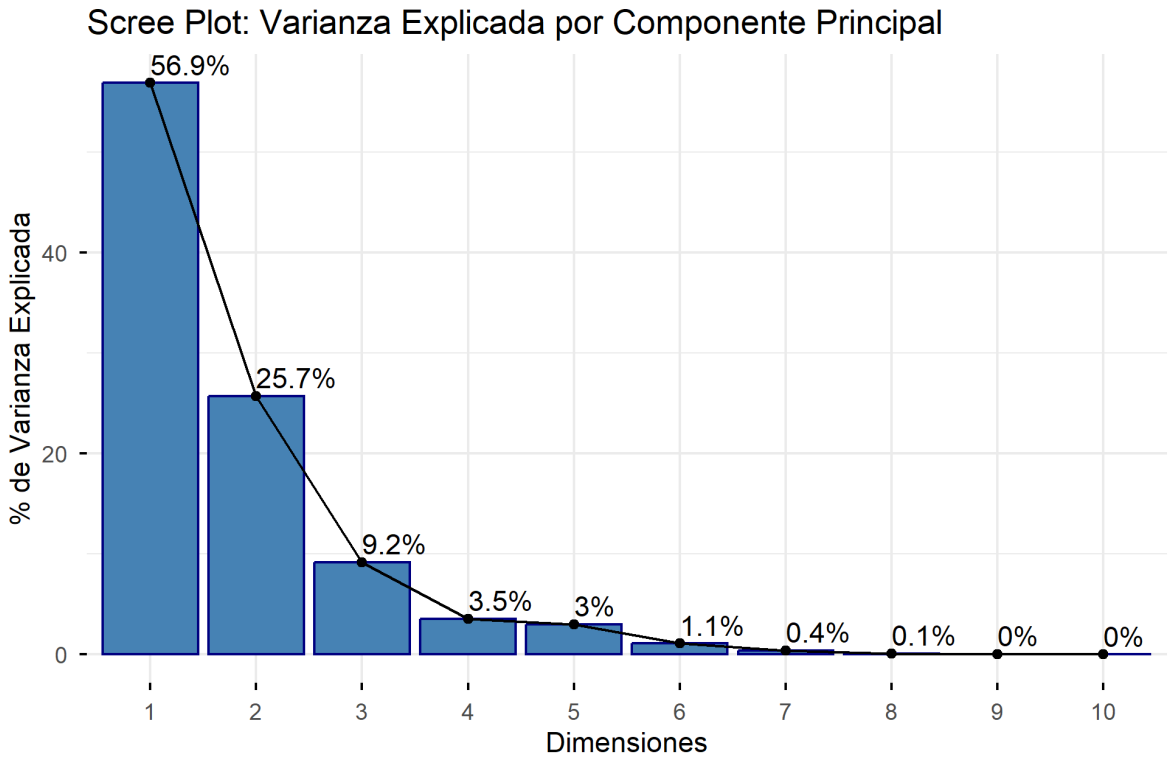
df_pca_mat <- df_pca_raw %>%
  select(all_of(vars_pca)) %>%
  mutate(across(everything(), ~ replace_na(.x, median(.x, na.rm = TRUE))))

rownames(df_pca_mat) <- df_pca_raw$Provincia

pca_res <- prcomp(df_pca_mat, center = TRUE, scale. = TRUE)

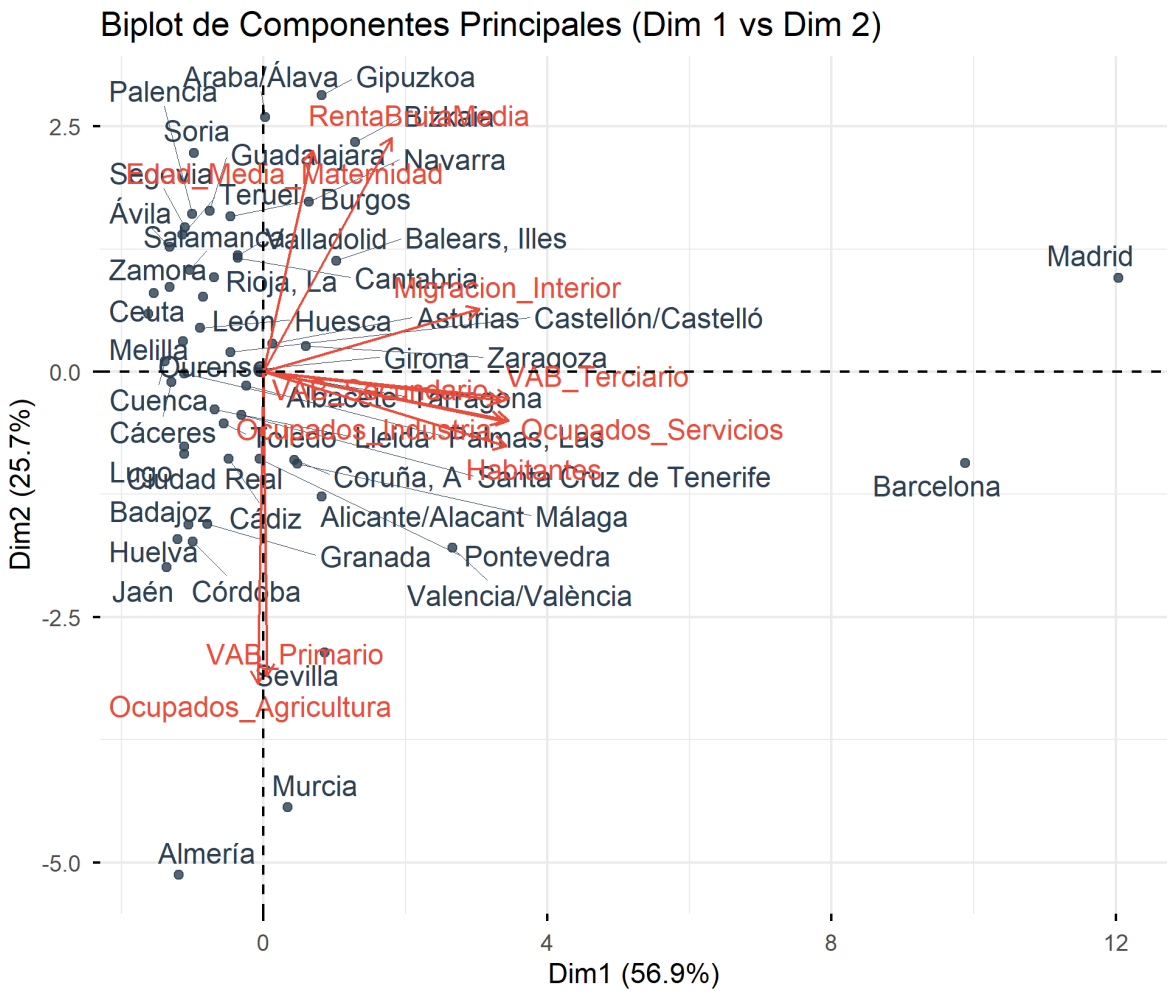
fviz_eig(pca_res, addlabels = TRUE, barfill = "steelblue", barcolor = "navy") +
```

```
  labs(
    title = "Scree Plot: Varianza Explicada por Componente Principal",
    x = "Dimensiones",
    y = "% de Varianza Explicada"
  )
```



7.2. Biplot Factorial

```
fviz_pca_biplot(
  pca_res,
  repel = TRUE,
  col.var = "#E74C3C",
  col.ind = "#2C3E50",
  alpha.ind = 0.8,
  title = "Biplot de Componentes Principales (Dim 1 vs Dim 2)"
)
```



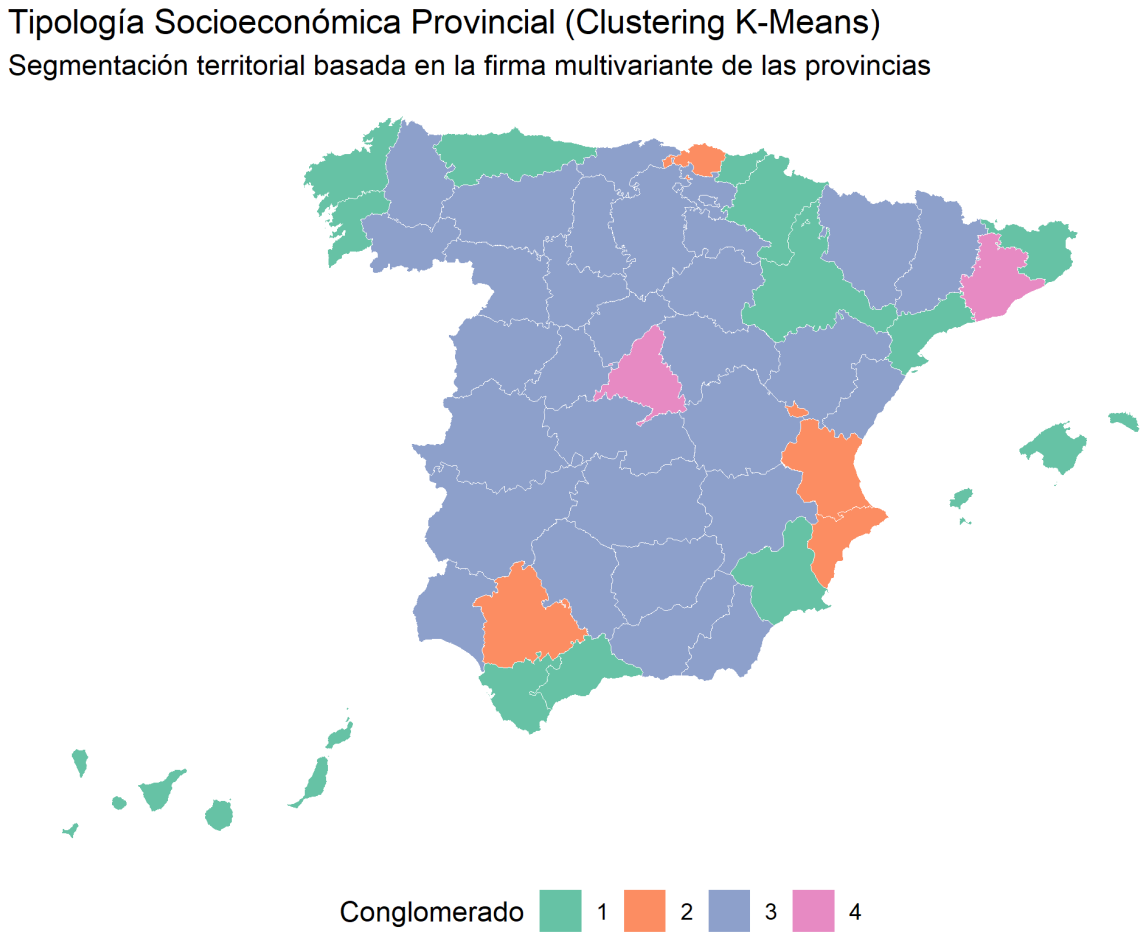
7.3. Agrupamiento K-Means

```
set.seed(123)
k_means_res <- kmeans(df_pca_mat, centers = 4, nstart = 25)

df_clusters <- df_pca_raw %>%
  mutate(Cluster = as.factor(k_means_res$cluster))

mapa_clusters <- mapa_provs %>%
  left_join(df_clusters, by = c("cpro" = "id_prov"))

ggplot(mapa_clusters) +
  geom_sf(aes(fill = Cluster), color = "white", size = 0.2) +
  scale_fill_brewer(palette = "Set2", na.value = "grey90") +
  labs(
    title = "Tipología Socioeconómica Provincial (Clustering K-Means)",
    subtitle = "Segmentación territorial basada en la firma multivariante de las provincias",
    fill = "Conglomerado"
  ) +
  theme_void() +
  theme(legend.position = "bottom")
```



---

8. Modelización Econométrica de Datos de Panel (Efectos Fijos)

Para controlar la heterogeneidad no observada invariable en el tiempo a nivel provincial (α_i) y los shocks temporales comunes (γ_t), estimamos un modelo de panel con **Efectos Fijos de Dos Vías (Two-Way Fixed Effects)** mediante el paquete `plm`.

```
if (length(vars_num) >= 2) {
  dep_var <- vars_num[1]
  indep_vars <- vars_num[-1]

  formula_panel <- as.formula(paste(dep_var, "~", paste(indep_vars, collapse = " + ")))

  # Preparación del objeto pdata.frame
  pdata <- pdata.frame(df_analisis, index = c("id_prov", "Periodo"))

  # Estimación del modelo de efectos fijos de dos vías
  model_fe <- plm(formula_panel, data = pdata, model = "within", effect = "twoways")

  # Resumen del modelo
  summary(model_fe)
```

```
}
```

```
## Twoways effects Within Model
##
## Call:
## plm(formula = formula_panel, data = pdata, effect = "twoways",
##     model = "within")
##
## Unbalanced Panel: n = 43, T = 2-7, N = 295
##
## Residuals:
##     Min.  1st Qu.   Median  3rd Qu.     Max.
## -3136.69  -565.03   112.87   668.83  1960.78
##
## Coefficients:
##                           Estimate  Std. Error t-value Pr(>|t|)
## Habitantes             2.0882e-02  8.2009e-03  2.5463  0.01153 *
## Edad_Media_Maternidad -3.0059e+02  5.5873e+02 -0.5380  0.59110
## Migracion_Interior     4.5049e-01  1.8452e-01  2.4413  0.01537 *
## Ocupados_Agricultura   4.1438e-02  2.6714e-02  1.5512  0.12221
## Ocupados_Industria    -3.0841e-03  1.3149e-02 -0.2345  0.81477
## Ocupados_Servicios     7.0164e-03  8.8267e-03  0.7949  0.42747
## PIB_per_capita         2.0657e-01  1.2429e-01  1.6620  0.09784 .
## RentaBrutaMedia       -7.1167e-01  6.1683e-01 -1.1537  0.24978
## VAB_Primario          -4.2822e-04  7.8367e-04 -0.5464  0.58529
## VAB_Secundario        -6.8136e-05  1.7939e-04 -0.3798  0.70443
## VAB_Terciario          2.3148e-05  1.4289e-04  0.1620  0.87145
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Total Sum of Squares:    261880000
## Residual Sum of Squares: 241120000
## R-Squared:      0.079274
## Adj. R-Squared: -0.15189
## F-statistic: 1.83939 on 11 and 235 DF, p-value: 0.0485
```

---

9. Conclusiones y Sintesis

1. **Estructura de Datos:** El dataset `datos_socioecon_ESP` proporciona una base sólida y balanceada para el análisis territorial longitudinal.
2. **Brecha Espacial:** Se consolida la asimetría espacial entre los grandes polos urbanos e industriales frente al interior peninsular.
3. **Agrupamiento Operativo:** El análisis multivariante permite clasificar el territorio en 4 perfiles socioeconómicos homogéneos útiles para el diseño de políticas públicas diferenciadas. “‘