MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Luis Molina Villar[1], Rubén Sánchez Munuera[1], Pablo Gallart Carbonell[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es realizar un análisis exploratorio de distintos indicadores socioeconómicos a nivel provincial en España, y sus posibles relaciones. En particular, los indicadores estudiados corresponden a el modelo productivo de las diferentes provincias, sus mercados laborales e inmobiliarios, y el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación:

1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)?
2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)?
3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente?
4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?

Con el fin de responder las preguntas, se estudian las siguientes variables socioeconómicas, organizadas en cuatro dimensiones:

1. **Dimensión de Renta y Riqueza Macro vs. Micro:**

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

- `PIB per cápita`: Producto Interior Bruto provincial por habitante (€/hab). Este indicador mide el valor monetario de todos los bienes y servicios finales producidos en un periodo en una región.
- `Renta bruta media`: Renta bruta media por persona (€/hab). El concepto de renta bruta corresponde, el conjunto total de ingresos que percibe una persona durante un periodo determinado, antes de aplicar ningún tipo de impuesto.

2. **Dimensión del Mercado Inmobiliario:**

- `Precio del metro cuadrado`: Valor medio del metro cuadrado de la vivienda (€/m²).

3. **Dimensión Demográfica y Ciclo Vital:**

- `Edad media de maternidad`: Edad media de las madres al nacimiento de un hijo/a, considerando todos los órdenes de nacimiento (primer hijo/a, segundo hijo/a,...) (años).
- `Migracion Interior`: Saldo migratorio neto interprovincial (personas que pasan de vivir de una provincia a otra) en el rango de edad de 19 a 35 años (número neto de personas).
- `Habitantes`: Población provincial total residente (personas).

4. **Dimensión de Estructura Productiva:**

- `Personas ocupadas por sector (Primario, Secundario, Terciario)`: Número de personas ocupadas en cada gran sector. Los ocupados están en miles de personas .
- `VAB por sector (Primario, Secundario, Terciario)`: El valor bruto añadido mide el valor económico total que genera una empresa, sector, región o país durante un periodo de tiempo determinado.

Para la realización del informe se han recopilado todos los datos existentes de dichos registros en el INE (entre todas las variables hay registros desde 1975 a 2026). En particular, solamente hay registros de todas las variables en el periodo 2015-2021, y por cuestiones de espacio, en el informe solamente se muestra un análisis exploratorio de los datos correspondientes al año 2019, elegido ya que siendo uno de los años con más datos disponibles, es justamente previo a la pandemia de COVID-19, por lo que este análisis puede ser usado para estudiar los efectos de la pandemia en los factores estudiados.

2. Importación y Acondicionamiento de Datos

El primer paso para el análisis es cargar los conjuntos de datos obtenidos del INE. Los ficheros originales se encuentran almacenados en la carpeta local `data/raw`.

La fuente de datos no proporciona los datos estrictamente adecuados para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas). Por lo tanto, el primer paso es acondicionar los datos obtenidos para llegar a un conjunto de datos que contenga los datos que nos interesan. Uno de los factores principales a tener en cuenta es que los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Los datos han sido importados a `R` usando una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas, usando la función `locale`.

El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera. Los principales pasos que han sido necesarios para el acondicionamiento de los datos ha requerido han sido:

- Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- En el conjunto de datos que queremos estudiar cada instancia es una provincia en cierto año. Con el fin de unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros de los datos originales, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`).
- El INE ofrece algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como estas variables escapan del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, se han agregado los datos, usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).
- En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino.
- Para extraer únicamente el valor de las provincias (ni el total nacional ni niveles regionales), filtramos usando la lista oficial de provincias del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. Análisis Exploratorio de Datos (EDA)

3.1. Análisis de Datos Perdidos

Ahora que tenemos un conjunto de datos con todas las variables de interés, y las instancias adecuadamente identificadas, podemos proceder al análisis exploratorio propiamente dicho. Para empezar observamos en qué variables hay valores faltantes.

Table 1. Valores perdidos por variable

	Valores Perdidos
Renta_bruta_media	12
Personas_Ocupadas_Primario	7

Por suerte, hay pocos valores perdidos, por lo que podemos visualizar sus instancias correspondientes antes de decidir qué hacer con ellos.

Table 2. Instancias con valores faltantes

Provincia	Periodo	Renta_bruta_media	Personas_Ocupadas_Primario
Araba/Álava	2015	NaN	2.350
Araba/Álava	2016	NaN	3.475
Araba/Álava	2017	NaN	3.850
Araba/Álava	2018	NaN	3.225
Araba/Álava	2019	NaN	2.825
Ceuta	2016	11988	NaN
Ceuta	2017	12094	NaN
Ceuta	2020	13718	NaN
Ceuta	2021	14499	NaN
Gipuzkoa	2015	NaN	2.700
Melilla	2015	11151	NaN
Melilla	2016	11377	NaN
Melilla	2019	12676	NaN
Navarra	2015	NaN	9.525
Navarra	2016	NaN	9.575
Navarra	2017	NaN	11.025
Navarra	2018	NaN	11.800
Navarra	2019	NaN	10.225
Navarra	2020	NaN	9.425

Observamos que los valores faltantes afectan solamente a 5 provincias, además, cada instancia tiene como mucho un valor faltante, las variables afectadas son series temporales de valores numéricos (valores anuales de 2015 a 2021), y en todos los casos tenemos al menos un registro de toda la serie, por lo que la decisión sobre los valores faltantes es imputarlos siguiendo la siguiente norma. Se imputan los valores faltantes con la media del primer valor anterior no faltante, y el primer valor posterior no faltante. En caso de no haber valores anteriores o posteriores faltantes, se imputará el dato usando el primer dato posterior o respectivamente anterior no faltante.

3.2. Análisis Univariante

En esta sección procedemos a examinar la distribución individual de las variables recopiladas. El objetivo central de este análisis univariante es caracterizar el comportamiento estadístico de cada magnitud —evaluando su tendencia central, grado de dispersión, presencia de asimetrías y valores atípicos, antes de abordar las relaciones multivariantes.

Empezaremos mostrando resúmenes estadísticos de cada una de las variables, tanto de localización como de dispersión.

Table 3. Estadísticos de posición y dispersión del panel provincial (52 provincias, 2015–2021).

Variable	Media	Mediana	Desv. típ.	CV (%)	Mín.	Máx.
PIB per cápita (€)	24.617	23.116	5.061	20,6	17.840	38.631
Renta bruta media (€)	14.144	13.838	2.115	15,0	11.043	19.785
Precio m² (€)	1.173,5	1.100,7	307,3	26,2	798,4	2.034,4
Edad media maternidad (años)	32,16	32,29	0,60	1,9	30,47	33,03
Saldo migratorio interior 19-35 años (pers.)	0	-308	1.864	–	-1.871	12.144
Habitantes	904.350	607.321	1.188.192	131,4	84.777	6.663.394
Ocupados primario (%)	6,5	4,9	4,9	76,5	0,2	23,9
Ocupados secundario (%)	21,5	22,4	6,3	29,3	6,4	32,8
Ocupados terciario (%)	72,0	70,7	7,3	10,2	61,5	93,3
VAB primario (%)	5,1	4,3	4,0	78,7	0,0	17,0
VAB secundario (%)	24,0	23,9	7,9	32,8	8,3	39,7
VAB terciario (%)	70,9	69,9	8,8	12,4	55,8	91,7

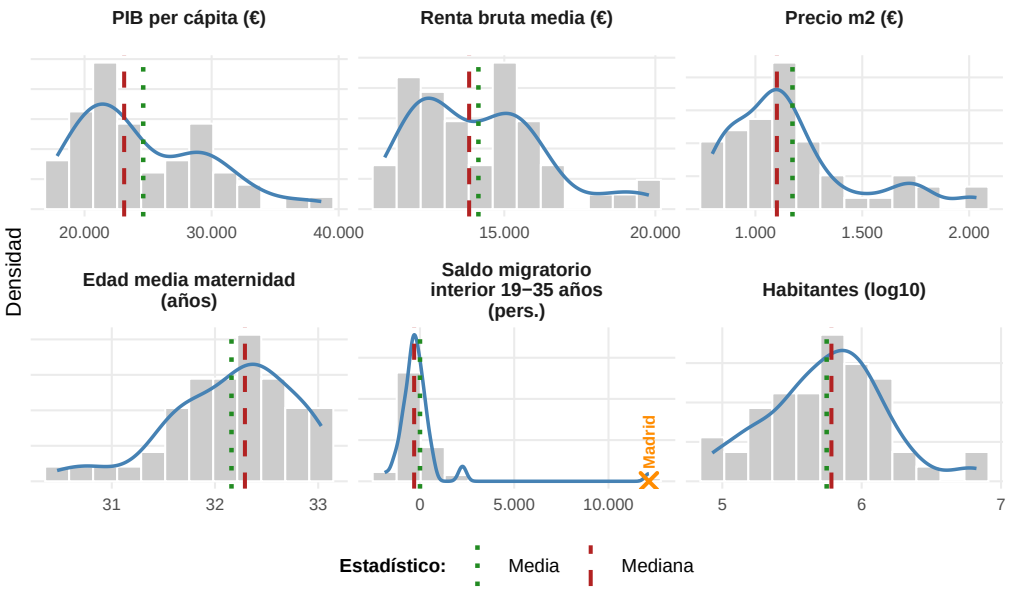
Table 4. Cuartiles y forma de la distribución (asimetría y exceso de curtosis de Fisher).

Variable	Q1	Q3	IQR	Asimetria	Curtosis
PIB per cápita (€)	20.838	28.476	7.638	0,78	-0,14
Renta bruta media (€)	12.314	15.366	3.052	0,77	0,15
Precio m² (€)	964,5	1.247,1	282,6	1,19	0,78
Edad media maternidad (años)	31,79	32,56	0,77	-0,74	0,29
Saldo migratorio interior 19-35 años (pers.)	-600	81	680	5,49	33,16
Habitantes	326.390	1.025.346	698.956	3,54	13,33
Ocupados primario (%)	2,9	9,3	6,4	1,23	1,86
Ocupados secundario (%)	17,9	25,8	7,9	-0,45	-0,05
Ocupados terciario (%)	66,3	75,2	8,9	0,96	0,47
VAB primario (%)	2,1	6,8	4,7	1,18	1,53
VAB secundario (%)	18,0	29,9	11,8	0,12	-0,73
VAB terciario (%)	64,4	76,0	11,7	0,47	-0,39

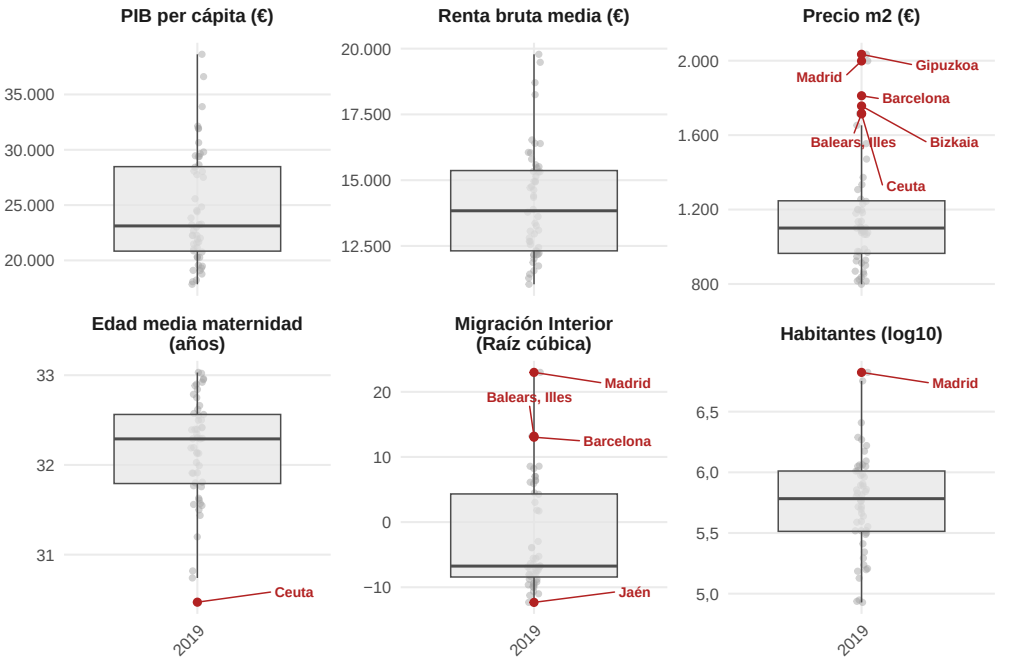
Los estadísticos descriptivos (Tablas 3-4) revelan la estructura socioeconómica transversal del año 2019 a través de tres grandes rasgos.

Basándonos en el resumen estadístico, podemos decir, que en general, encontramos un conjunto de datos bastante heterogéneo, ya que el coeficiente de variación toma valores intermedios. Cabe destacar la homogeneidad de la edad media de maternidad, y el peso del sector terciario tanto a nivel de ocupación, como a nivel de valor bruto añadido. De la migración interior no se puede obtener el coeficiente de variación, ya que su media es 0, pero ahora después visualizaremos su dispersión. También podemos decir que las distribuciones son poco simétricas, la mayoría con colas a la derecha (asimetría positiva), y que la curtósis nos indica en la mayoría de casos una dispersión de los datos respecto a la media cercana a la normal, a excepción de la edad media de maternidad y la población, que presentan o bien una gran concentración en torno a la media, o valores atípicos muy notables.

Con el fin de visualizar las distribuciones, y resolver las dudas que nos plantean las representamos gráficamente:



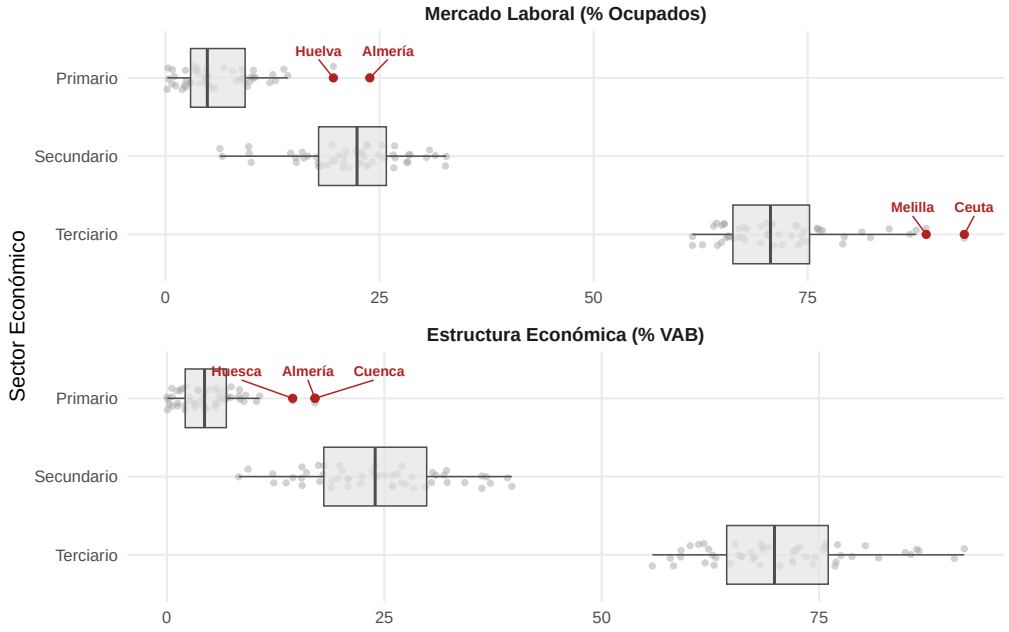
Las marcas naranjas indican valores atípicos (Alejados de la media más de 3 desviaciones típicas)



Los puntos rojos indican valores atípicos evaluados mediante IQR (±1.5) sobre la escala original de los datos.
Nota: La variable Migración Interior ha sido escalada con una transformación de raíz cúbica para su correcta visua

Figure 1. Distribución provincial por año de las variables clave. Los puntos rojos son valores fuera de 1,5 veces el rango intercuartílico.

La distribución mediante diagramas de caja, subraya el peso que tienen los valores extremos (marcados en rojo) en la distorsión de las medias. El precio del metro cuadrado destaca por concentrar cuatro valores atípicos superiores a los 1.600 €/m^2. El saldo migratorio ilustra de forma prístina la macrocefalia demográfica del país: mientras la inmensa mayoría de las provincias ven sus cajas comprimidas por debajo del cero, un atípico extremo se dispara por encima de los 12.000 jóvenes retenidos, acompañado de un segundo valor atípico cercano a los 2.000.



Los puntos rojos indican valores atípicos evaluados mediante la regla IQR (±1.5) calculada por sector.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.