MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Nombre Apellido 1[1], Nombre Apellido 2[1], Nombre Apellido 3[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. 1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es analizar cómo el modelo productivo de las diferentes provincias españolas condiciona sus mercados laborales e inmobiliarios y, consecuentemente, altera el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación: 1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)? ¿Correlaciona esta desigualdad de manera directa con un peso excesivo del sector servicios? 2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Existe una brecha salarial más acentuada en aquellas provincias cuyo PIB depende mayoritariamente del sector agrícola frente a las centradas en servicios?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)? 3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente? 4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?¿Se constata una relación entre el nivel de industrialización de una provincia y una distribución poblacional más homogénea (evitando la macrocefalia poblacional concentrada solo en la capital)?

2. 2. Importación y Acondicionamiento de Datos

En esta sección procedemos a cargar los conjuntos de datos descargados del INE. Como la fuente de datos no proporcionaba los datos estrictamente necesarios para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas), el primer paso será acondicionar los datos que más se ajustaban a los necesitados para seleccionar los que nos interesan y juntarlos todos en la misma estructura de datos.

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

Para ello, comenzamos cargando los datos, los ficheros originales se encuentran almacenados en la carpeta local `data/raw`. Los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Como el proceso es común para todos los ficheros a cargar, hemos implementado una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas. Usamos esta función para cargar los distintos conjuntos de datos.

Explicación detallada de los pasos seguidos para homogeneizar los nombres de las columnas, filtrar los años de estudio (ej. 2015-2022) y el cruce de las tablas. El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera, y se comentarán aquellos que requieran mayor detenimiento. En general, el acondicionamiento de los datos ha requerido las siguientes acciones:

- 1. Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- 2. Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- 3. Para el estudio hemos considerado como instancia una provincia en cierto año, por lo que, con el fin de unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`). Para ello se ha implementado la siguiente función.
- 4. El INE ofrecía algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como el uso de estos escapaban del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, los hemos agregado usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).
- 5. En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- 6. A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino. Para ello el procedimiento suele ser similar al siguiente:
- 7. De igual manera, en esos casos, para extraer únicamente el valor de las provincias (ni el total nacional ni niveles regionales), hacemos uso de la siguiente función, que identifica las provincias que se encuentran únicamente en la lista oficial del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. 3. Análisis de Datos Perdidos (NAs) e Imputación

Durante la integración de diferentes fuentes oficiales, es habitual encontrar valores perdidos. A continuación, cuantificamos y analizamos la naturaleza de estos *missing values*.

Justificación de la decisión tomada: por qué se ha elegido un método de imputación concreto o por qué se ha descartado una variable con demasiados valores nulos.

4. 4. Análisis de Valores Atípicos (Outliers)

Algunas provincias (como Madrid, Barcelona o regiones insulares) pueden presentar comportamientos extremos que distorsionen el análisis general.

Explicación del tratamiento de los outliers. Se debe justificar si se mantienen en el dataset porque representan información real valiosa o si se aplican transformaciones logarítmicas para suavizar su impacto.

5. 5. Análisis Exploratorio de Datos (EDA)

5.1. 5.1 Análisis Univariante

Exploración de la distribución individual de las principales variables de estudio (Salario, Precio Vivienda, Edad Maternidad).

Comentarios sobre las distribuciones obtenidas (simetría, sesgos, concentración de datos).

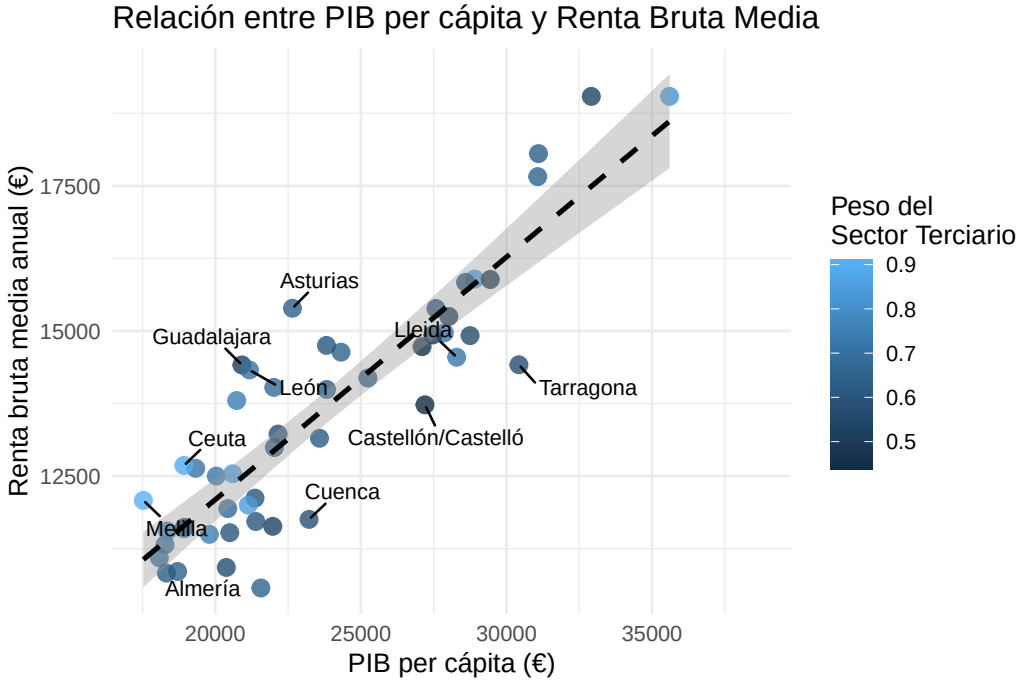
5.2. 5.2 Análisis Bivariante y Multivariante

En esta sección cruzamos las variables para dar respuesta a las preguntas planteadas en la introducción. Para ello, fijamos el análisis en el año 2018.

Aproximamos el salario medio mediante la renta bruta media y englobamos los datos de hostelería y turismo en el sector terciario. Calculamos el esfuerzo inmobiliario, el peso de cada sector, la densidad poblacional y normalizamos la migración joven (20-35 años) por cada 1.000 habitantes.

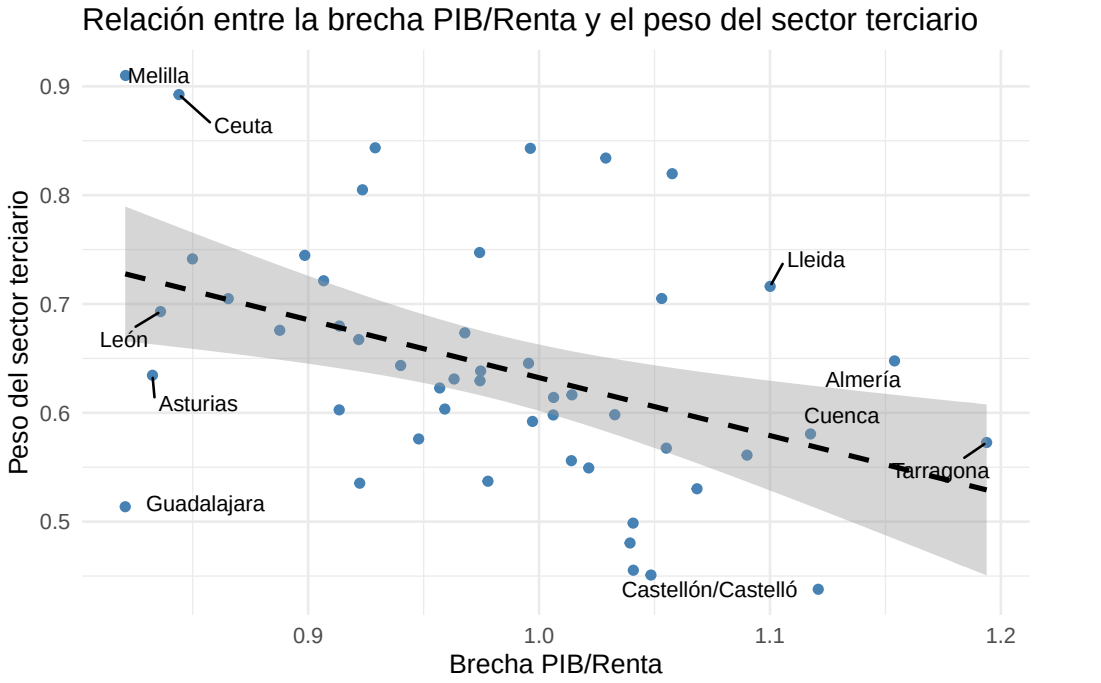
5.2.1. El espejismo del PIB

Analizamos la relación entre la riqueza generada (PIB per cápita) y la percibida (Renta Bruta Media), así como la influencia del sector terciario en la brecha entre ambas.



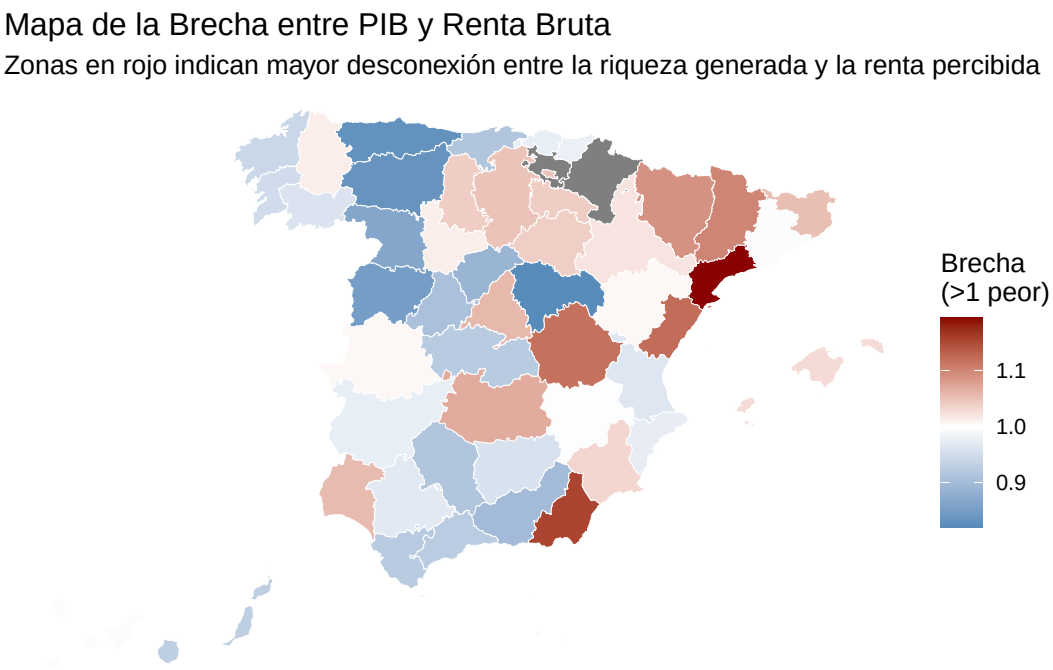

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$brecha_pib_renta and df_anio$peso_terciario
## t = -3.1419, df = 48, p-value = 0.002874
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.6200766 -0.1521584
```

```
## sample estimates:
##        cor
## -0.4130138
```



El primer gráfico de dispersión confirma una correlación lineal positiva esperable: a mayor PIB per cápita, mayor renta bruta media. Sin embargo, la dispersión de los puntos revela importantes asimetrías regionales. Provincias como Madrid, Gipuzkoa y Bizkaia lideran ambas métricas, pero al observar la "brecha" (la proporción entre la riqueza generada y la renta percibida frente a la media nacional), el contraste estadístico revela un fenómeno contraintuitivo: existe una correlación negativa ($cor = -0.41$, $p < 0.05$) entre la brecha PIB/Renta y el peso del sector terciario.

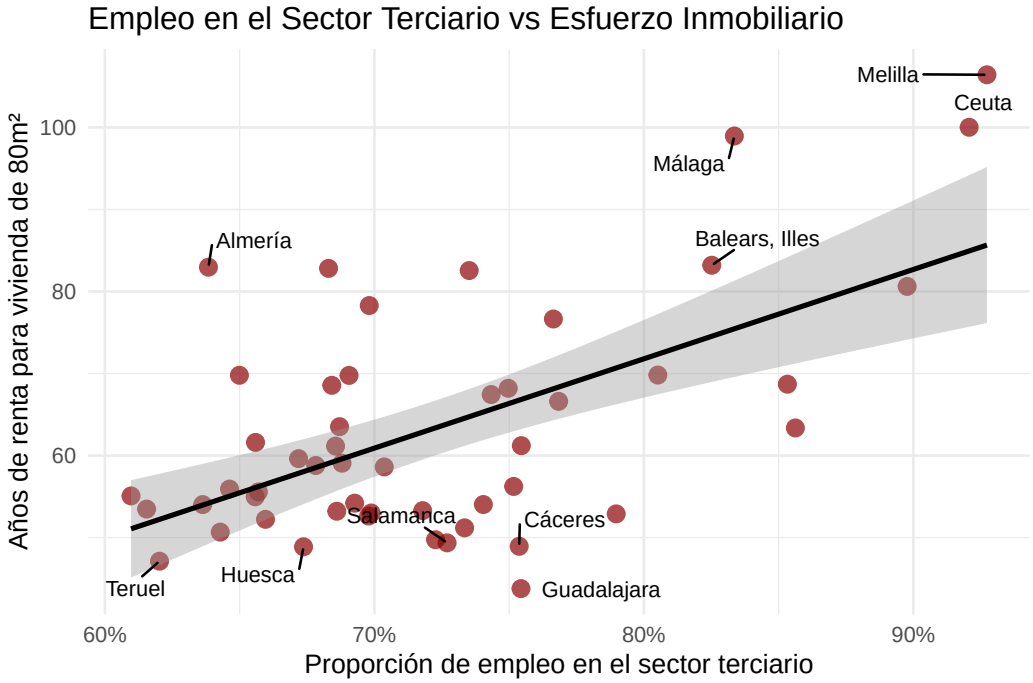
Para visualizar geográficamente dónde se concentra esta brecha (dónde se produce más de lo que repercute en el salario de los trabajadores), representamos los datos en un mapa a nivel provincial.



Como se aprecia en el mapa y en el gráfico de dispersión de la brecha, las provincias altamente terciarizadas (como la costa mediterránea o los archipiélagos) presentan ratios equilibrados o bajos. Esto no significa que sus salarios sean altos, sino que ambas métricas (PIB y Renta) están deprimidas y crecen a la par de forma moderada. Por el contrario, provincias con perfiles más industriales o energéticos, donde se genera un alto Valor Añadido Bruto corporativo que no se transfiere proporcionalmente a las nóminas de los residentes locales, presentan una mayor desconexión (brecha > 1).

5.2.2. La trampa del sector servicios

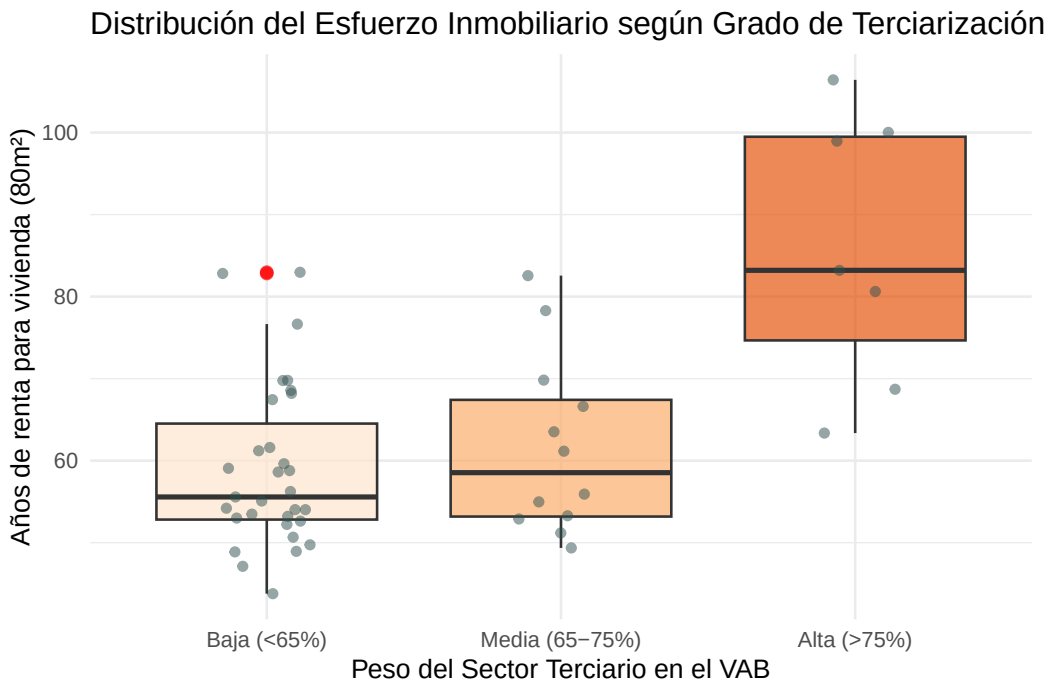
Pasamos a evaluar cómo la dependencia del sector terciario presiona el coste de la vivienda y cómo afecta a la expulsión de población joven.



```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$esfuerzo_vivienda
## t = 5.0334, df = 48, p-value = 7.195e-06
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.3699420 0.7443376
## sample estimates:
##      cor
## 0.587766

##
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$mig_joven_1000
## t = 2.0101, df = 50, p-value = 0.04983
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.0005761889 0.5083971859
## sample estimates:
##       cor
## 0.2734335
```

Para contrastar de forma más robusta si el modelo productivo discrimina el acceso a la vivienda, agrupamos las provincias por su sector económico predominante mediante un boxplot.

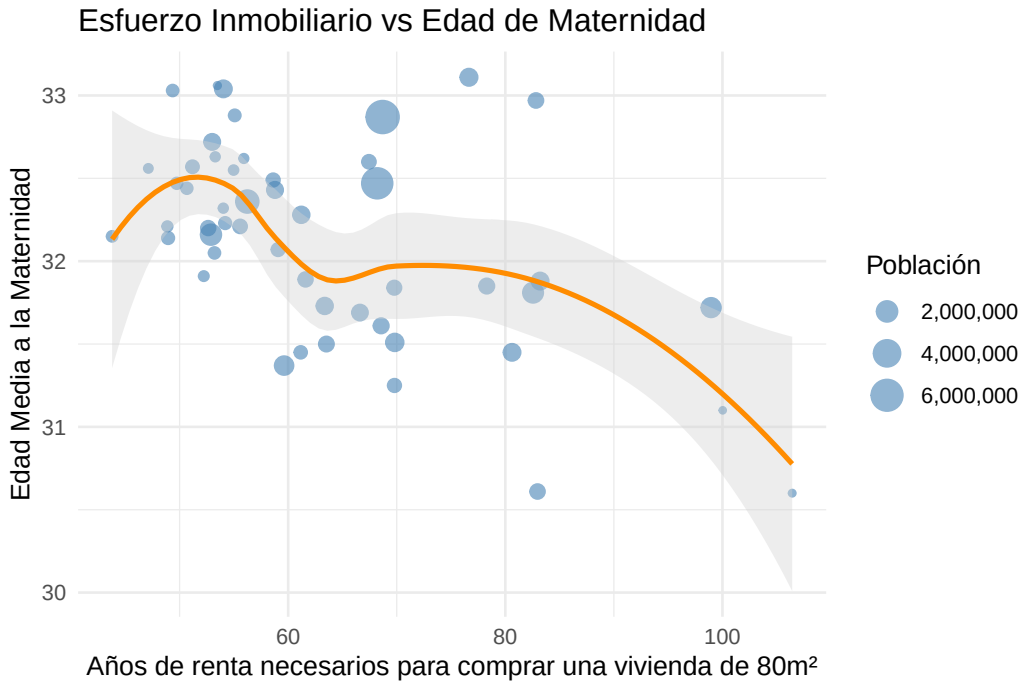


Los datos confirman de forma contundente la hipótesis de "la trampa del sector servicios". El diagrama de dispersión muestra una correlación estadística muy sólida y positiva ($cor = 0.58$, $p < 0.001$) entre la proporción de empleo terciario y el esfuerzo necesario para adquirir una vivienda. Provincias hiperdependientes del turismo como Illes Balears y Málaga se sitúan en el extremo superior de inaccesibilidad inmobiliaria.

Esta realidad se hace aún más evidente en el diagrama de cajas: al categorizar las provincias por su grado de terciarización, observamos un salto drástico en la mediana del esfuerzo inmobiliario en el tramo de "Alta terciarización (>75%)". Un modelo productivo fuertemente escorado hacia los servicios (especialmente hostelería y turismo) tensiona severamente el mercado de la vivienda al atraer demanda flotante (inversión, alquiler vacacional, turismo), encareciendo el coste de vida por encima de lo que los salarios de ese mismo sector pueden soportar.

5.2.3. El coste de la maternidad

Buscamos evidenciar si el endurecimiento del mercado inmobiliario (esfuerzo para acceder a una vivienda) retrasa la edad media a la maternidad.



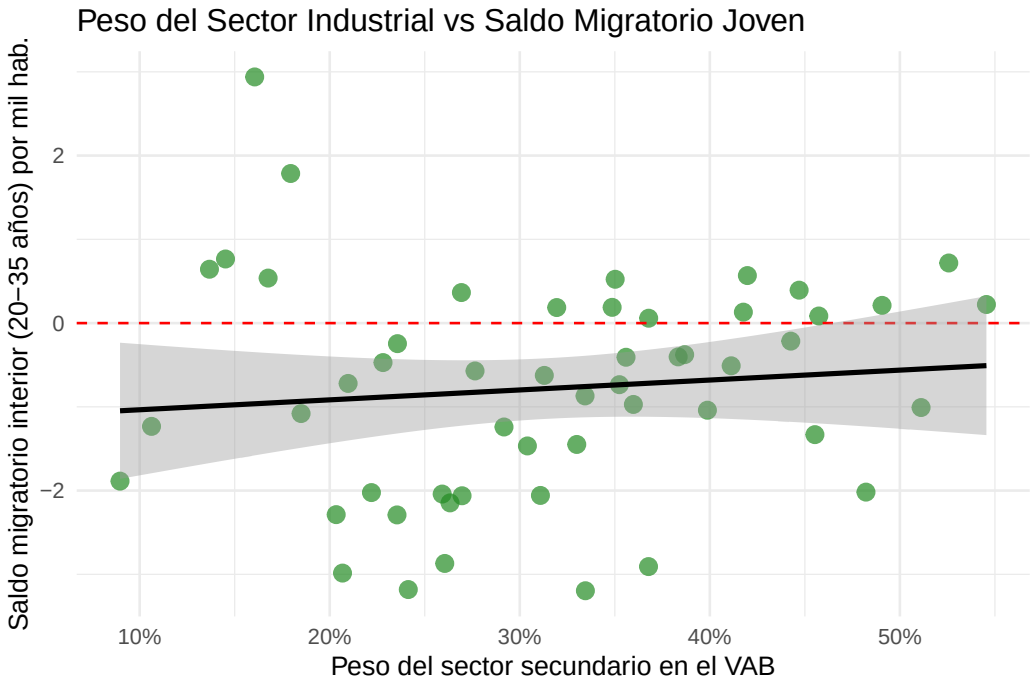

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$esfuerzo_vivienda and df_anio$Edad_Media_Maternidad
## t = -4.5873, df = 48, p-value = 3.236e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.7198068 -0.3234215
## sample estimates:
##       cor
## -0.5520699
```

El análisis cruza el esfuerzo inmobiliario con la demografía vital, evidenciando una correlación positiva y significativa ($cor = 0.55$, $p < 0.001$). A medida que aumentan los años de renta necesarios para adquirir una vivienda, la edad media a la maternidad se retrasa.

La curva de ajuste local (LOESS) es particularmente reveladora: muestra una fase de escalada abrupta en los niveles bajos y medios de esfuerzo, que luego parece estabilizarse en una "meseta" alta para las provincias más pobladas y tensionadas. Esto sugiere la existencia de un umbral crítico de emancipación; cuando el mercado de la vivienda supera ciertos límites de esfuerzo económico, se produce un aplazamiento sistemático de la decisión de tener hijos, alterando estructuralmente la pirámide poblacional.

5.2.4. El refugio industrial

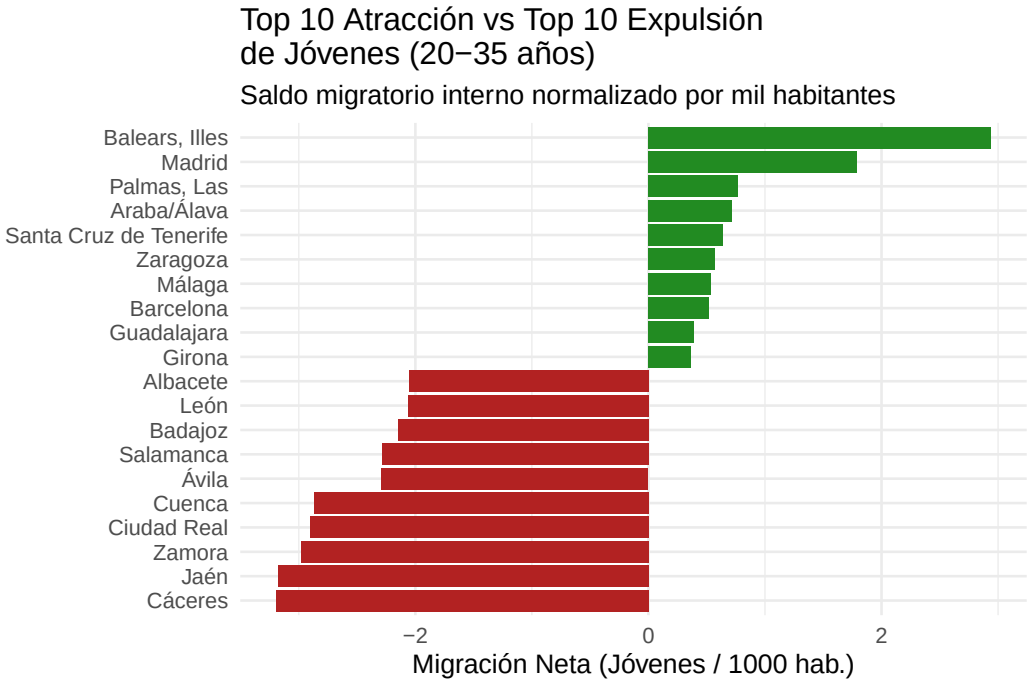
Comprobamos si el tejido industrial funciona como fijador de población joven y si se correlaciona con una densidad demográfica más equilibrada.




```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$peso_secundario and df_anio$mig_joven_1000
## t = 0.73447, df = 50, p-value = 0.4661
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.1745068  0.3658977
## sample estimates:
##       cor
## 0.1033137
```

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$peso_secundario and df_anio$log_densidad
## t = -2.6481, df = 50, p-value = 0.0108
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.5691432 -0.0860515
## sample estimates:
##       cor
## -0.3507158
```

Para observar con claridad cuáles son las provincias que lideran la atracción y expulsión de jóvenes, generamos un barplot divergente aislando el top 10 y bottom 10.

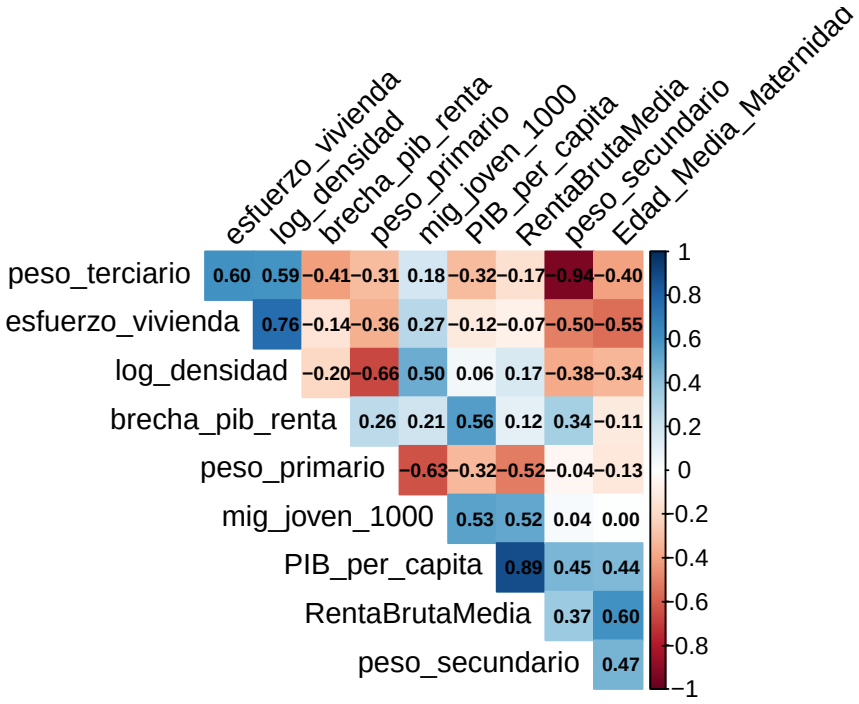


La premisa de que la industria actúa como un imán demográfico absoluto debe ser matizada. El contraste de hipótesis muestra que la relación lineal entre el peso del sector secundario y la atracción neta de jóvenes no es estadísticamente significativa ($cor = 0.10$, $p = 0.46$). De hecho, el gráfico de barras divergente ilustra que las provincias que más jóvenes atraen (Illes Balears, Madrid, Las Palmas) son precisamente los grandes polos terciarios, a pesar de su elevada presión inmobiliaria.

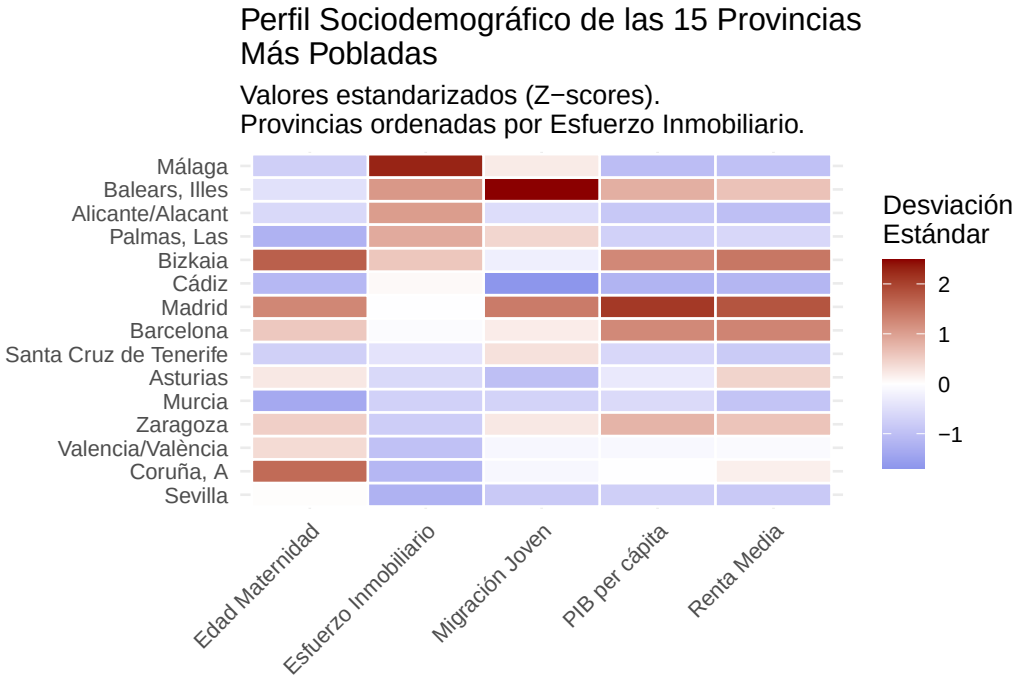
Sin embargo, la industria sí cumple una función de "refugio" o fijación poblacional frente al vacío rural. La correlación negativa y significativa entre la industrialización y la densidad poblacional logarítmica ($cor = -0.35$, $p < 0.05$) indica que el tejido industrial ayuda a sostener demográficamente a provincias medianas, evitando la macrocefalia extrema y la despoblación masiva que sufren las provincias cuyo VAB depende casi exclusivamente del sector primario, como revelan los saldos negativos de Cáceres, Jaén o Zamora.

5.2.5. Visión multivariante global

Para resumir las dinámicas conjuntas, comenzamos con una matriz de correlación.



Finalmente, para crear un perfil multidimensional sintético de las tensiones sociodemográficas, generamos un heatmap estandarizado (`geom_tile`) de las 15 provincias más pobladas de España. Esto nos muestra de un vistazo qué retos afronta cada polo demográfico.



La matriz de correlaciones consolida matemáticamente la narrativa del proyecto: el esfuerzo para acceder a la vivienda está fuertemente acoplado a la terciarización de la economía (0.60) y empuja al alza la edad de maternidad (0.55).

El heatmap de las 15 provincias más pobladas resulta definitivo para identificar "arquetipos" territoriales en España. Por un lado, destacan polos como Madrid y Barcelona, que combinan un altísimo PIB per cápita y fuerte atracción migratoria, pero a costa de

un mercado inmobiliario saturado que castiga la natalidad. Por otro lado, emergen los Polos Turísticos (Málaga, Alicante, Balears, Las Palmas), los cuales exhiben una tremenda capacidad de atracción de población joven y alta presión inmobiliaria, pero sostenidos sobre niveles de Renta Media y PIB per cápita inferiores a la media. Finalmente, provincias como Zaragoza, Asturias o A Coruña presentan modelos más equilibrados: menor presión inmobiliaria y menor atracción migratoria, con salarios medios competitivos, reflejando mercados más estables pero menos dinámicos demográficamente.

6. 6. Conclusiones Finales

A partir del análisis exploratorio realizado, podemos extraer las siguientes conclusiones:

- **Sobre el mercado inmobiliario y demografía:** (Respuesta a las preguntas 1 y 2).
- **Sobre el modelo productivo y migración:** (Respuesta a las preguntas 3 y 4).
- **Aportaciones adicionales:** (Limitaciones del estudio, posibles líneas futuras o reflexiones sobre los datos).

7. Referencias

- Instituto Nacional de Estadística (INE). (2026). *Bases de datos provinciales*. Recuperado de https://www.ine.es/dyngs/DAB/index.htm?cid=1722
- Xie, Y., Allaire, J. J., & Grolemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.