MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Luis Molina Villar[1], Rubén Sánchez Munuera[1], Pablo Gallart Carbonell[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. 1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es realizar un análisis exploratorio de distintos indicadores socioeconómicos a nivel provincial en España, y sus posibles relaciones. En particular, los indicadores estudiados corresponden a el modelo productivo de las diferentes provincias, sus mercados laborales e inmobiliarios, y el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación:

1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)?
2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)?
3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente?
4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?

2. 2. Importación y Acondicionamiento de Datos

El primer paso para el análisis es cargar los conjuntos de datos obtenidos del INE. Los ficheros originales se encuentran almacenados en la carpeta local `data/raw`.

La fuente de datos no proporciona los datos estrictamente adecuados para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas). Por lo tanto, el primer paso será acondicionar los datos que más se

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

ajustaban a los necesitados para seleccionar los que nos interesan y juntarlos todos en la misma estructura de datos. Uno de los factores principales a tener en cuenta es que los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Los datos han sido importados a `R` usando una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas, usando la función `locale`.

Explicación de los pasos seguidos para homogeneizar los nombres de las columnas, filtrar los años de estudio (ej. 2015-2021 y el cruce de las tablas.

El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera. Los principales pasos que han sido necesarios para el acondicionamiento de los datos ha requerido han sido:

- Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- En el conjunto de datos que queremos estudiar cada instancia es una provincia en cierto año. Con el fin de unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros de los datos originales, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`).
- El INE ofrece algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como estas variables escapan del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, se han agregado los datos, usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).
- En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino.
- Para extraer únicamente el valor de las provincias (ni el total nacional ni niveles regionales), filtramos usando la lista oficial de provincias del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. 3. Análisis de Datos Perdidos (NAs) e Imputación

Ahora que tenemos un conjunto de datos con todas las variables de interés, y las instancias adecuadamente identificadas, podemos proceder al análisis exploratorio propiamente dicho. Para empezar observamos en qué variables hay valores faltantes.

Table 1. Valores perdidos por variable

	Valores Perdidos
Renta_bruta_media	12
Personas_Ocupadas_Primario	7

Por suerte, hay pocos valores perdidos, por lo que podemos visualizar sus instancias correspondientes para decidir que realizar con ellos.

Table 2. Instancias con valores faltantes

Provincia	Periodo	Renta_bruta_media	Personas_Ocupadas_Primario
Araba/Álava	2015	NaN	2.350
Araba/Álava	2016	NaN	3.475
Araba/Álava	2017	NaN	3.850
Araba/Álava	2018	NaN	3.225
Araba/Álava	2019	NaN	2.825
Ceuta	2016	11988	NaN
Ceuta	2017	12094	NaN
Ceuta	2020	13718	NaN
Ceuta	2021	14499	NaN
Gipuzkoa	2015	NaN	2.700
Melilla	2015	11151	NaN
Melilla	2016	11377	NaN
Melilla	2019	12676	NaN
Navarra	2015	NaN	9.525
Navarra	2016	NaN	9.575
Navarra	2017	NaN	11.025
Navarra	2018	NaN	11.800
Navarra	2019	NaN	10.225
Navarra	2020	NaN	9.425

Observamos que los valores faltantes afectan solamente a 5 provincias, además, las variables afectadas son series temporales de valores numéricos (valores anuales de 2015 a 2021), y en todos los casos tenemos al menos un registro de toda la serie, por lo que la decisión sobre los valores faltantes es imputarlos siguiendo la siguiente norma. Se imputan los valores faltantes con la media del primer valor anterior no faltante, y el primer valor posterior no faltante. En caso de no haber valores anteriores o posteriores faltantes, se imputará el dato usando el primer dato posterior o respectivamente anterior no faltante.

Justificación de la decisión tomada: por qué se ha elegido un método de imputación concreto o por qué se ha descartado una variable con demasiados valores nulos.

4. 4. Análisis de Valores Atípicos (Outliers)

Algunas provincias (como Madrid, Barcelona o regiones insulares) pueden presentar comportamientos extremos que distorsionen el análisis general.

```
# Código para visualizar outliers mediante boxplots
# Métodos aplicados (ej. Rango Intercuartílico - IQR) para filtrar o transformar v
```

Explicación del tratamiento de los outliers. Se debe justificar si se mantienen en el dataset porque representan información real valiosa o si se aplican transformaciones logarítmicas para suavizar su impacto.

5. 5. Análisis Exploratorio de Datos (EDA)

5.1. Análisis Univariante

En esta sección procedemos a examinar la distribución individual de las principales variables socioeconómicas, demográficas y de estructura productiva obtenidas tras el acondicionamiento del conjunto de datos. El objetivo central de este análisis univariante es caracterizar el comportamiento estadístico de cada magnitud —evaluando su tendencia central, grado de dispersión, presencia de asimetrías y colas pesadas— antes de abordar las relaciones bivariantes.

A partir del dataset unificado `df_completo` (resultante del cruce de las tablas de datos socioeconómicos y laborales), seleccionamos y derivamos las variables cuantitativas continuas organizadas en cuatro dimensiones:

- **Dimensión de Renta y Riqueza Macro vs. Micro:**
  - `PIB_per_capita`: Producto Interior Bruto provincial por habitante (€/hab). Mide la producción agregada regional.
  - `Renta_bruta_media`: Renta bruta media por persona (€/hab, antes de impuestos). Funciona como *proxy* de la renta realmente percibida por los residentes.
- **Dimensión del Mercado Inmobiliario:**
  - `Precio_m2`: valor medio del metro cuadrado de la vivienda (€/m²), media anual de los cuatro trimestres.
- **Dimensión Demográfica y Ciclo Vital:**
  - `Edad_Media_Maternidad`: Edad media de las madres al nacimiento de un hijo, considerando todos los órdenes de nacimiento (años).
  - `Migracion_Interior`: Saldo migratorio neto interprovincial en la cohorte joven de 19 a 35 años (número neto de personas).
  - `Habitantes`: Población provincial total residente (personas).
- **Dimensión de Estructura Productiva (Métricas Derivadas):**
  - `% Ocupados (Primario, Secundario, Terciario)`: Porcentaje de personas ocupadas en cada sector sobre la suma de los tres sectores (%). Los ocupados están en miles de personas (media anual de los valores trimestrales).
  - `% VAB (Primario, Secundario, Terciario)`: Porcentaje del Valor Añadido Bruto aportado por cada sector sobre la suma del VAB de los tres sectores (%).

Para caracterizar formalmente la distribución de cada variable X evaluamos su posición (media $\bar{x}$, mediana y cuartiles), su dispersión (desviación típica muestral s, rango intercuartílico RIC $= Q_3 - Q_1$, extremos y coeficiente de variación CV $= 100\, s/\bar{x}$, solo para variables no negativas) y su forma (coeficiente de asimetría de Fisher γ_1 y exceso de curtosis γ_2, con $m_k = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^k$):

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \quad s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}, \quad \gamma_1 = \frac{m_3}{m_2^{3/2}}, \quad \gamma_2 = \frac{m_4}{m_2^2} - 3.$$

A partir de las 52 observaciones correspondientes a las provincias y ciudades autónomas en el año 2019, contrastamos finalmente la hipótesis de normalidad con el test de Shapiro-Wilk.

Variable	N	Media	Mediana	Desv. típ.	CV (%)	Mín.	Máx.
PIB per cápita (€)	52	24.617	23.116	5.061	20,6	17.840	38.631
Renta bruta media (€)	52	14.144	13.838	2.115	15,0	11.043	19.785
Precio m² (€)	52	1.173,5	1.100,7	307,3	26,2	798,4	2.034,4
Edad media maternidad (años)	52	32,16	32,29	0,60	1,9	30,47	33,03
Saldo migratorio 19-35 años (pers.)	52	0	-308	1.864	–	-1.871	12.144
Habitantes	52	904.350	607.321	1.188.192	131,4	84.777	6.663.394
Ocupados primario (%)	52	6,5	4,9	4,9	76,5	0,2	23,9
Ocupados secundario (%)	52	21,5	22,4	6,3	29,3	6,4	32,8
Ocupados terciario (%)	52	72,0	70,7	7,3	10,2	61,5	93,3
VAB primario (%)	52	5,1	4,3	4,0	78,7	0,0	17,0
VAB secundario (%)	52	24,0	23,9	7,9	32,8	8,3	39,7
VAB terciario (%)	52	70,9	69,9	8,8	12,4	55,8	91,7

Table 3. Estadísticos de posición y dispersión del panel provincial (52 provincias, 2015–2021).

Variable	Q1	Q3	RIC	Asimetría	Curtosis
PIB per cápita (€)	20.838	28.476	7.638	0,78	-0,14
Renta bruta media (€)	12.314	15.366	3.052	0,77	0,15
Precio m² (€)	964,5	1.247,1	282,6	1,19	0,78
Edad media maternidad (años)	31,79	32,56	0,77	-0,74	0,29
Saldo migratorio 19-35 años (pers.)	-600	81	680	5,49	33,16
Habitantes	326.390	1.025.346	698.956	3,54	13,33
Ocupados primario (%)	2,9	9,3	6,4	1,23	1,86
Ocupados secundario (%)	17,9	25,8	7,9	-0,45	-0,05
Ocupados terciario (%)	66,3	75,2	8,9	0,96	0,47
VAB primario (%)	2,1	6,8	4,7	1,18	1,53
VAB secundario (%)	18,0	29,9	11,8	0,12	-0,73
VAB terciario (%)	64,4	76,0	11,7	0,47	-0,39

Table 4. Cuartiles, forma de la distribución (asimetría y exceso de curtosis de Fisher) y porcentaje de la varianza total debido a diferencias entre provincias.

Variable	2019
PIB per cápita (€)	23.116
Renta bruta media (€)	13.838
Precio m² (€)	1.100,7
Edad media maternidad (años)	32,29
Saldo migratorio 19-35 años (pers.)	-308
Habitantes	607.321
Ocupados primario (%)	4,9
Ocupados secundario (%)	22,4
Ocupados terciario (%)	70,7
VAB primario (%)	4,3
VAB secundario (%)	23,9
VAB terciario (%)	69,9

Table 5. Mediana provincial de cada variable por año.

Variable	2019
PIB per cápita (€)	20,6
Renta bruta media (€)	15,0
Precio m² (€)	26,2
Edad media maternidad (años)	1,9
Saldo migratorio 19-35 años (pers.)	–
Habitantes	131,4
Ocupados primario (%)	76,5
Ocupados secundario (%)	29,3
Ocupados terciario (%)	10,2
VAB primario (%)	78,7
VAB secundario (%)	32,8
VAB terciario (%)	12,4

Table 6. Coeficiente de variación (%) entre provincias por año (no definido para el saldo migratorio, que toma valores negativos).

Los estadísticos descriptivos (Tablas 3-6) revelan la estructura socioeconómica transversal del año 2019 a través de tres grandes rasgos.

En primer lugar, las magnitudes económicas presentan asimetría positiva, aunque con diferencias notables en su dispersión. El PIB per cápita (media de 24.617 € y mediana de 23.116 €) y la renta bruta media (media de 14.144 €) muestran coeficientes de variación moderados ($20,6\%$ y $15,0\%$, respectivamente) sin colas excesivamente pesadas. Sin embargo, el precio de la vivienda (Precio_m2) es mucho más heterogéneo: su CV alcanza el $26,2\%$ con un claro sesgo a la derecha (asimetría de $1,19$), abarcando desde un mínimo de $798,4\ €/m^2$ hasta un máximo de $2.034,4\ €/m^2$. Su media ($1.173,5$ €) supera a la mediana ($1.100,7$ €) precisamente por la tracción que ejercen las provincias más encarecidas.

En segundo lugar, la demografía y los flujos migratorios están monopolizados por unos pocos núcleos. El volumen de habitantes exhibe un CV extremo del $131,4\%$ y una curtosis de $13,33$, evidenciando el salto desde ciudades autónomas de 84.777 residentes hasta macro-urbes de más de $6,6$ millones. Esto se refleja de forma drástica en el saldo migratorio joven: aunque la mediana es de -308 personas (la mayor parte del territorio expulsa jóvenes), su enorme asimetría ($5,49$) y curtosis ($33,16$) muestran que el talento es absorbido por un número muy reducido de polos, con un pico de atracción neta máximo de 12.144 jóvenes.

En tercer lugar, se confirma la profunda terciarización del tejido productivo provincial. El sector servicios acapara de media el $72,0\%$ de la ocupación y el $70,9\%$ del VAB, mientras que el sector secundario ronda el $21\% - 24\%$. El sector primario queda con un peso residual (en torno al $5\% - 6,5\%$) pero muy desigual (CV cercano al $78\% - 76\%$), ya que unas pocas provincias mantienen una dependencia agraria significativa que alcanza hasta el $23,9\%$ de sus ocupados.

Para visualizar mejor estas distribuciones, las representamos gráficamente:

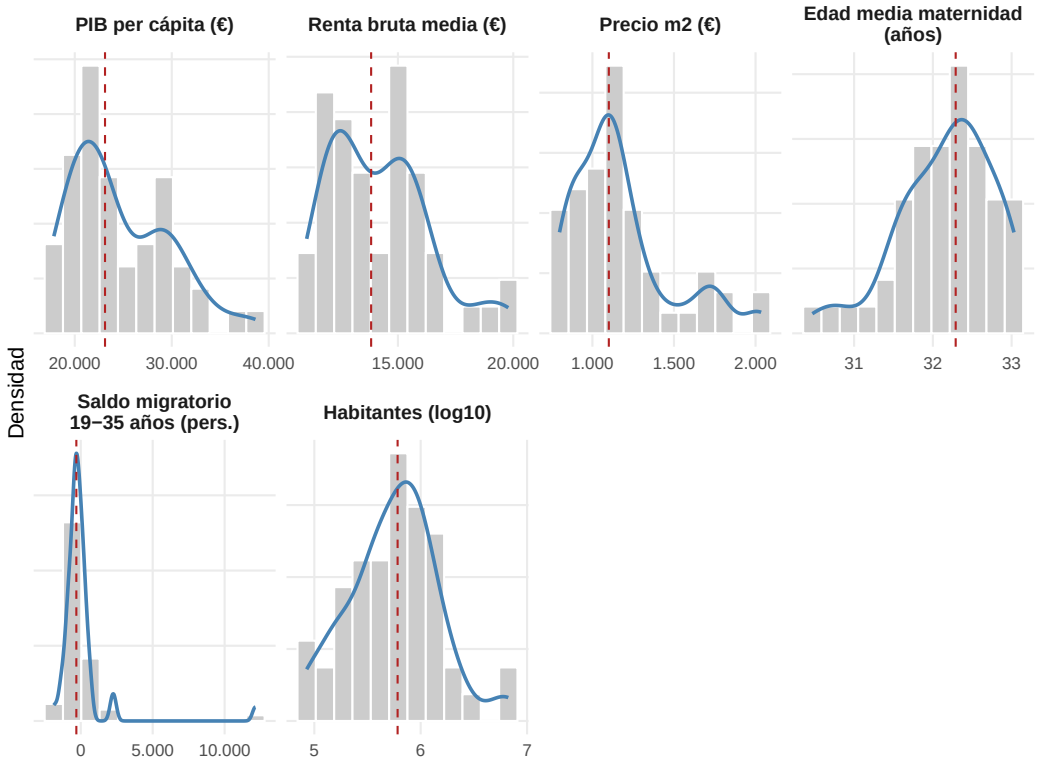


Figure 1. Distribución de las variables económicas y demográficas del panel provincial (2015-2021): histograma, densidad (azul) y mediana (rojo discontinuo). El número de habitantes se muestra en escala logarítmica.

En la primera figura, el PIB per cápita y la renta bruta muestran distribuciones unimodales, aunque en el PIB se insinúa un ligero abultamiento en la cola derecha (cerca de los 30.000 €), reflejo de las provincias más ricas. El precio de la vivienda evidencia su fuerte asimetría: una gran masa concentrada en torno a los $1.000 - 1.200\,€/m^2$ y una cola alargada hacia la derecha. La gráfica del saldo migratorio joven es especialmente reveladora, con un pico leptocúrtico masivo ligeramente por debajo de cero y una cola derecha extensa y casi plana que llega hasta los 12.000. Por su parte, la aplicación de la escala logarítmica normaliza la campana de la población ($\log_{10}(\text{Habitantes})$), aislando de forma clara en la cola superior a las provincias millonarias.

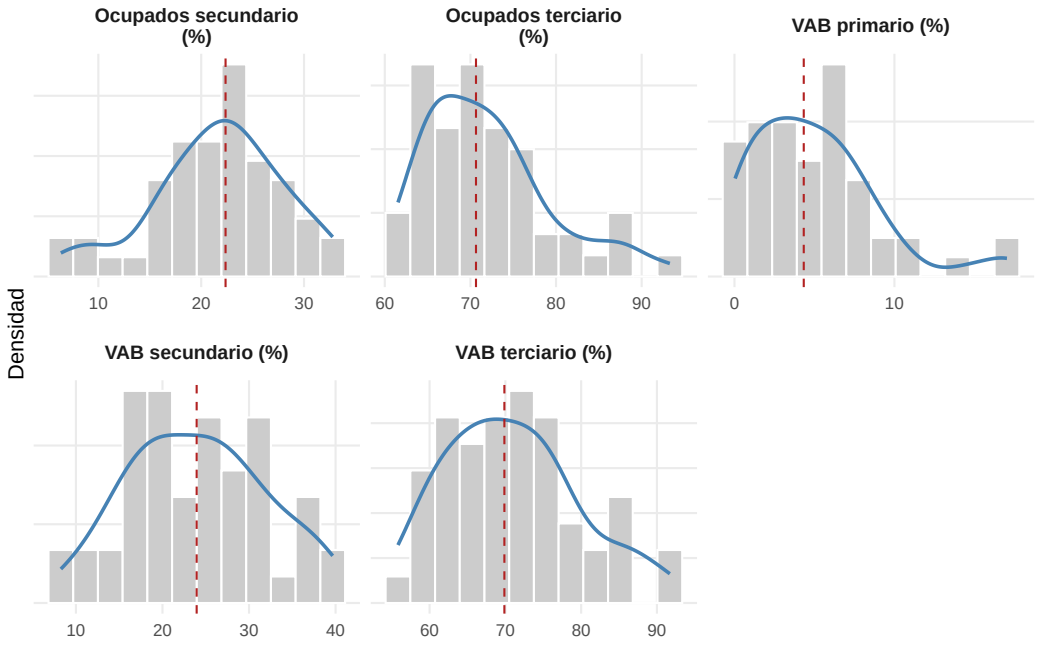


Figure 2. Distribución de la estructura productiva provincial: porcentaje de ocupados (fila superior) y de VAB (fila inferior) por sector.

En la segunda figura, la distribución de la estructura productiva muestra cómo el peso del primario (tanto en VAB como en ocupados) se agolpa contra el cero con una larga cola derecha, mientras que los sectores secundario y terciario adoptan formas más amplias y centradas en valores considerablemente más altos.

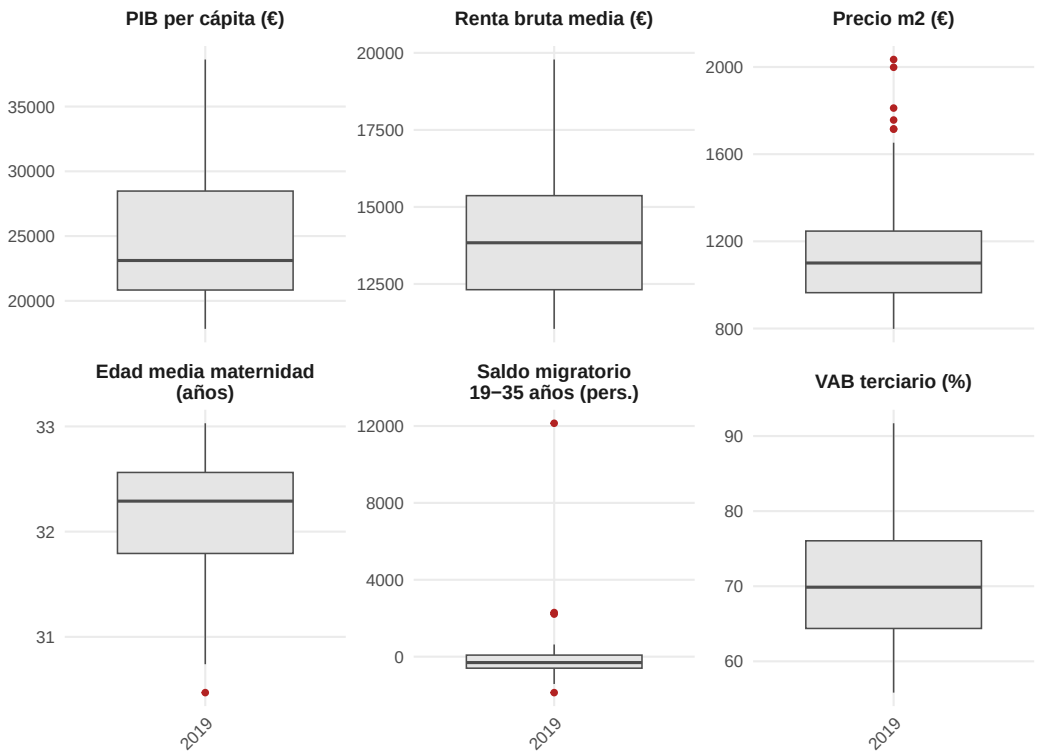


Figure 3. Distribución provincial por año de las variables clave. Los puntos rojos son valores fuera de 1,5 veces el rango intercuartílico.

La distribución mediante diagramas de caja (Figura 3), circunscrita al único año de observación (2019), subraya el peso que tienen los valores extremos (marcados en rojo) en la distorsión de las medias. El precio del metro cuadrado destaca por concentrar cuatro valores atípicos superiores a los 1.600 €/m^2. El saldo migratorio ilustra de forma prístina la macrocefalia demográfica del país: mientras la inmensa mayoría de las provincias ven sus cajas comprimidas por debajo del cero, un atípico extremo se dispara por encima de los 12.000 jóvenes retenidos, acompañado de un segundo valor atípico cercano a los 2.000. En el ámbito productivo, el VAB terciario exhibe un atípico inferior por debajo del 60%, apuntando a la existencia de alguna provincia altamente especializada fuera de los servicios.

Variable	W	p-valor
PIB per cápita (€)	0,924	0,003
Renta bruta media (€)	0,933	0,006
Precio m² (€)	0,874	<0,001
Edad media maternidad (años)	0,950	0,029
Saldo migratorio 19-35 años (pers.)	0,437	<0,001
Habitantes	0,572	<0,001
Ocupados primario (%)	0,901	<0,001
Ocupados secundario (%)	0,971	0,238
Ocupados terciario (%)	0,925	0,003
VAB primario (%)	0,903	<0,001
VAB secundario (%)	0,983	0,643
VAB terciario (%)	0,969	0,189
Habitantes (log10)	0,980	0,523

Table 7. Contraste de normalidad de Shapiro-Wilk (panel completo, orientativo por la repetición de provincias).

La Tabla 7 y la Figura 4 demuestran formalmente el rechazo de la hipótesis de normalidad para prácticamente todas las variables críticas ($p < 0{,}05$). El estadístico W de Shapiro-Wilk cuantifica la severidad de esta desviación: las magnitudes menos normales son el saldo migratorio ($W = 0{,}437$), el número absoluto de habitantes ($W = 0{,}572$) y el precio de la vivienda ($W = 0{,}874$).

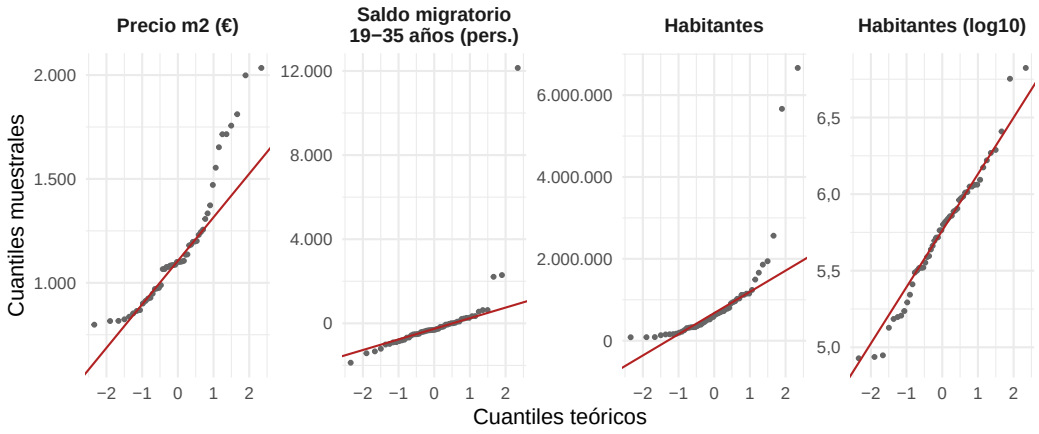


Figure 4. Gráficos cuantil-cuantil de las variables más asimétricas; la línea roja es la normal teórica.

Los gráficos cuantil-cuantil localizan con precisión el origen de esta ruptura. En el precio de la vivienda y en el saldo migratorio, los cuantiles muestrales se despegan abruptamente de la recta teórica en su extremo superior, traccionados por las provincias elitistas que forman la pesada cola derecha. En los habitantes, Madrid y Barcelona provocan un escalón aislado en la parte alta. No obstante, la transformación logarítmica de la

población logra corregir esta desviación estructural de forma sobresaliente, alineando los puntos con la normal (donde W pasa de 0,572 a 0,980) a excepción de los inevitables extremos demográficos absolutos. Estos resultados ratifican la idoneidad de emplear correlaciones no paramétricas (Spearman) en las posteriores fases bivariantes.

5.2. 5.2 Análisis Bivariante y Multivariante

En esta sección cruzamos las variables para dar respuesta a las preguntas planteadas en la introducción. Para ello, fijamos el análisis en el año 2019.

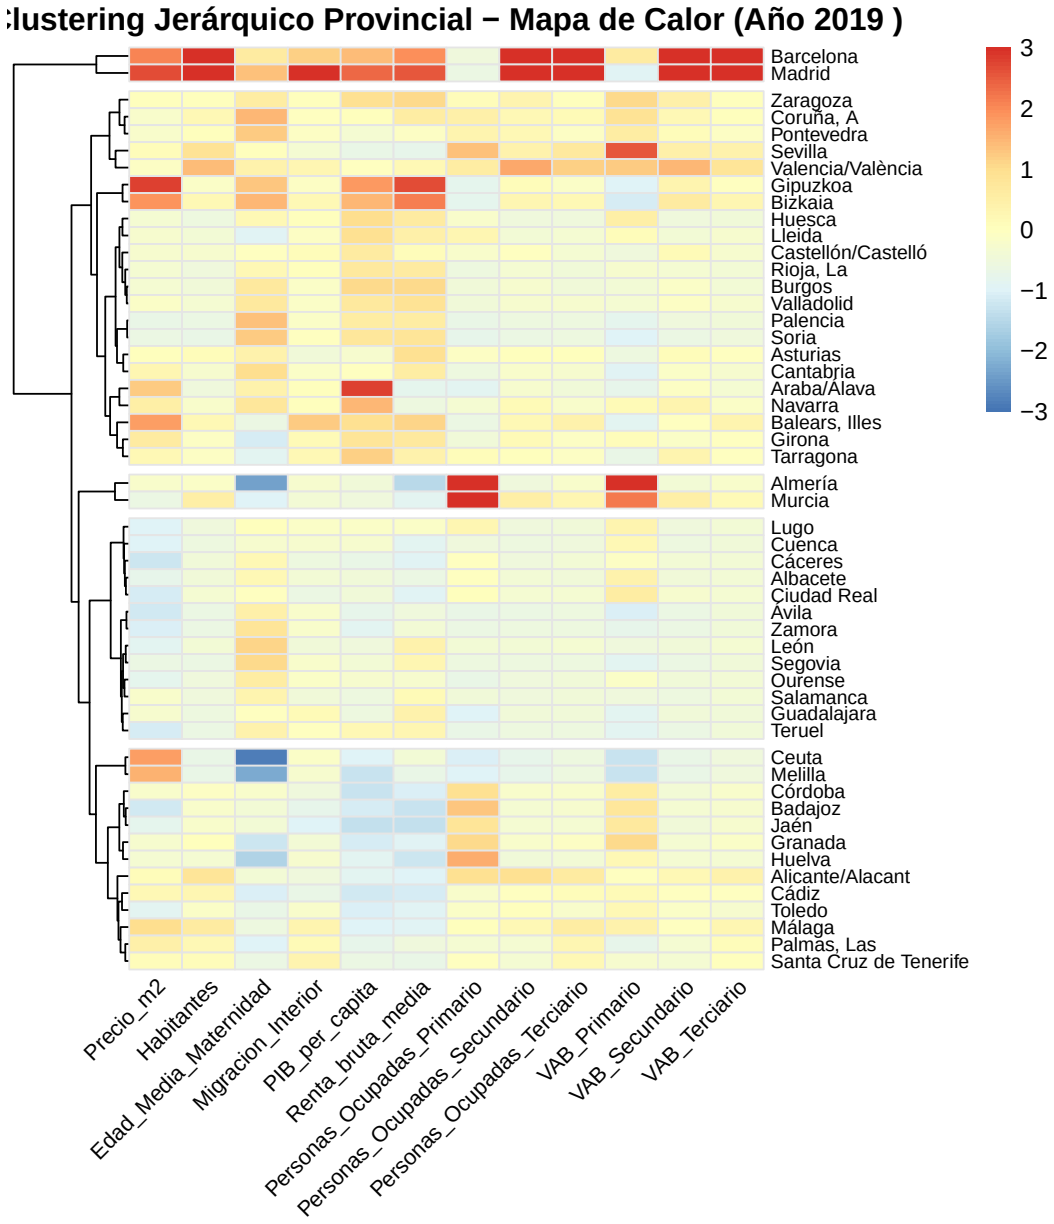
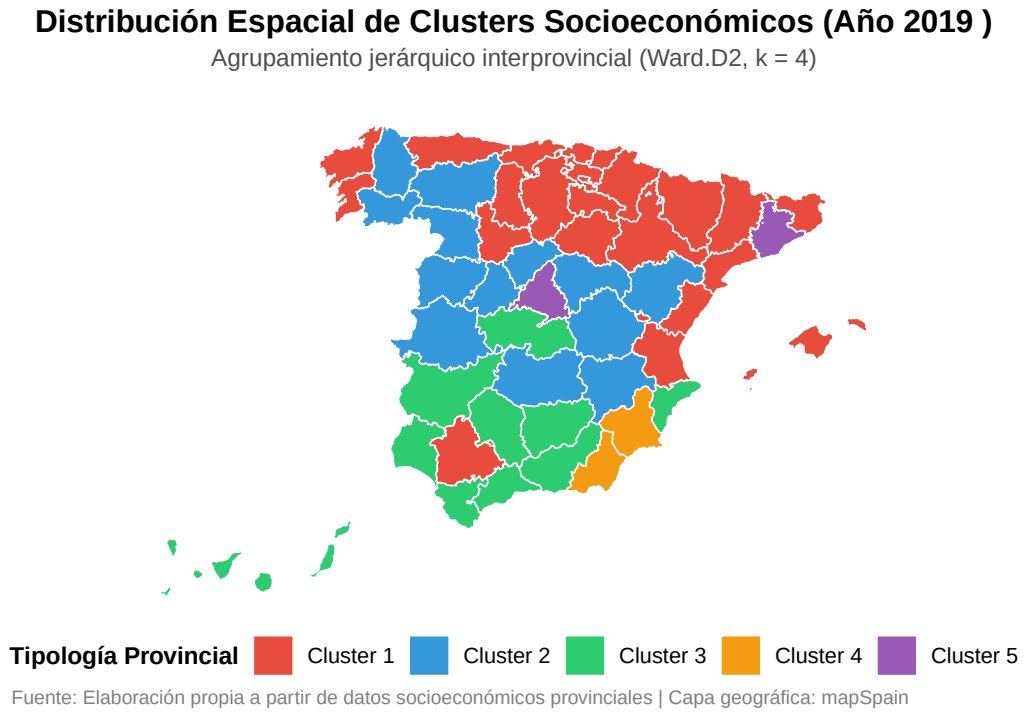

lustering Jerárquico Provincial − Mapa de Calor (Año 2019)
Barcelona
Madrid
Zaragoza
Coruña, A
Pontevedra
Sevilla
Valencia/València
Gipuzkoa
Bizkaia
Huesca
Lleida
Castellón/Castelló
Rioja, La
Burgos
Valladolid
Palencia
Soria
Asturias
Cantabria
Araba/Álava
Navarra
Balears, Illes
Girona
Tarragona
Almería
Murcia
Lugo
Cuenca
Cáceres
Albacete
Ciudad Real
Ávila
Zamora
León
Segovia
Ourense
Salamanca
Guadalajara
Teruel
Ceuta
Melilla
Córdoba
Badajoz
Jaén
Granada
Huelva
Alicante/Alacant
Cádiz
Toledo
Málaga
Palmas, Las
Santa Cruz de Tenerife
Precio_m2
Habitantes
Edad_Media_Maternidad
Migracion_Interior
PIB_per_capita
Renta_bruta_media
Personas_Ocupadas_Primario
Personas_Ocupadas_Secundario
Personas_Ocupadas_Terciario
VAB_Primario
VAB_Secundario
VAB_Terciario
3
2
1
0
−1
−2
−3

Table 8. Perfil demográfico y económico por Cluster (Año 2018)

Cluster	Num_Provincias	Periodo	Precio_m2	Habitantes	Edad_Media_Maternidad	Migracion_Interior	PIB_per_capita	Renta_bruta_media
Cluster 1	22	2019	1255.17	791080.6	32.43	46.91	28381.23	15415.40
Cluster 2	13	2019	908.54	290536.4	32.38	-509.77	22344.85	13616.54
Cluster 3	13	2019	1207.48	869751.5	31.55	-581.38	19414.92	12173.54
Cluster 4	2	2019	1044.45	1105359.0	31.16	-602.50	22141.50	11671.50
Cluster 5	2	2019	1905.09	6163986.5	32.75	7179.00	34258.00	18865.50

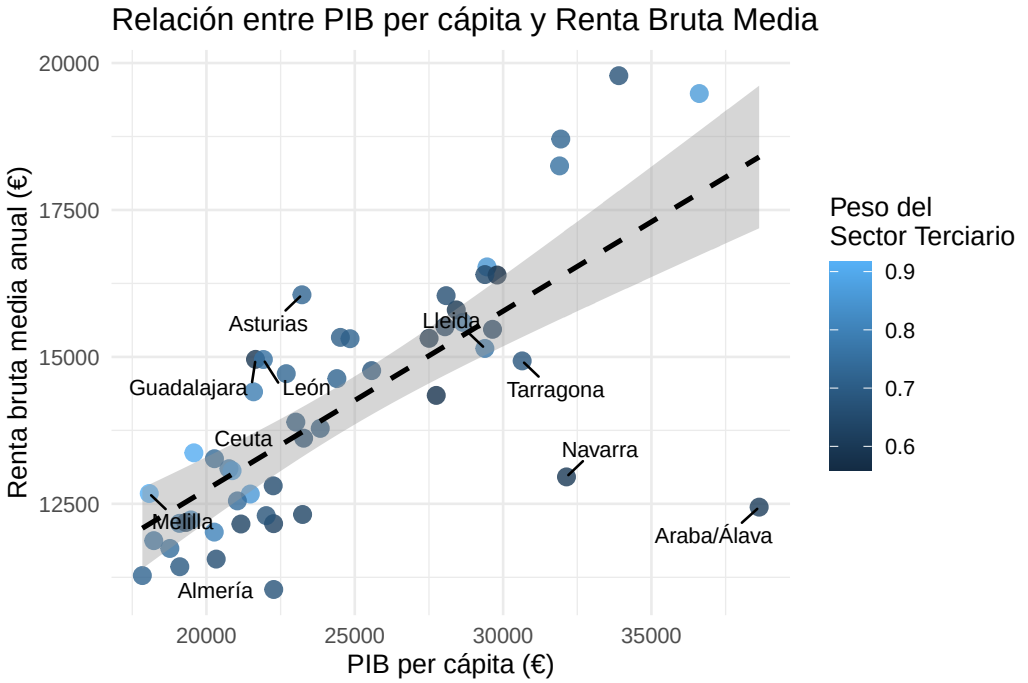
Table 9. Perfil laboral y productivo por Cluster (Año 2018)

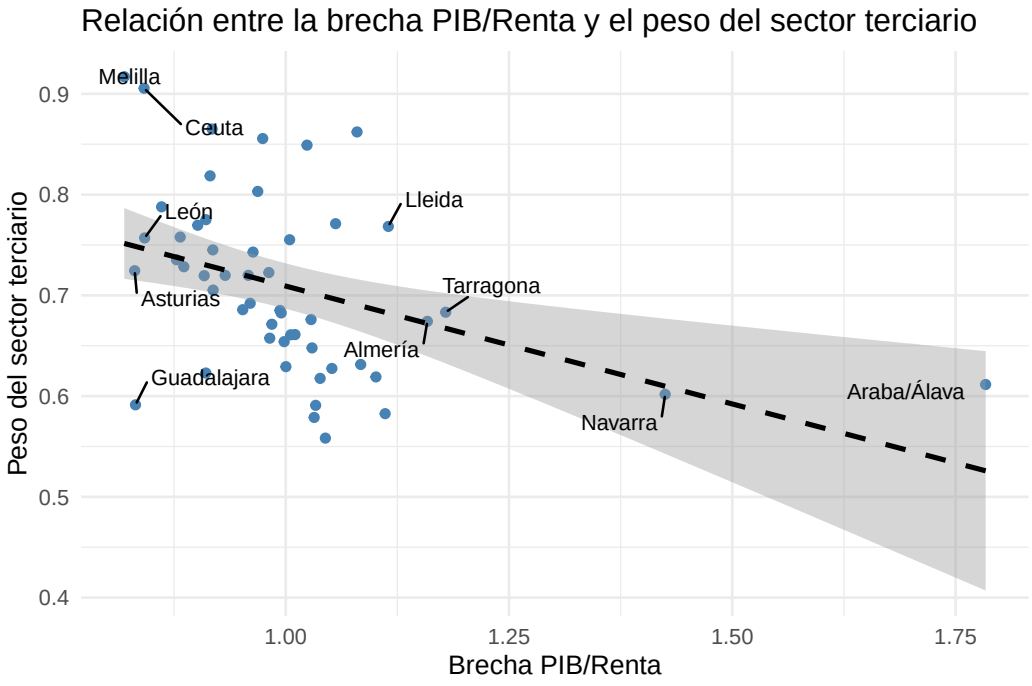
Cluster	Num_Provincias	Personas_Ocupadas_Primario	Personas_Ocupadas_Secundario	Personas_Ocupadas_Terciario	VAB_Primario	VAB_Secundario	VAB_Terciario
Cluster 1	22	12.17	79.06	243.84	562610.9	5255379	13636199
Cluster 2	13	9.23	25.27	81.08	457796.7	1406016	3994811
Cluster 3	13	19.64	57.25	258.86	622205.1	2832170	12216136
Cluster 4	2	70.97	77.54	298.89	2055028.5	5153293	14996902
Cluster 5	2	6.81	536.84	2279.78	531739.5	34721836	157058499



5.2.1. El espejismo del PIB

Analizamos la relación entre la riqueza generada (PIB per cápita) y la percibida (Renta Bruta Media), así como la influencia del sector terciario en la brecha entre ambas.

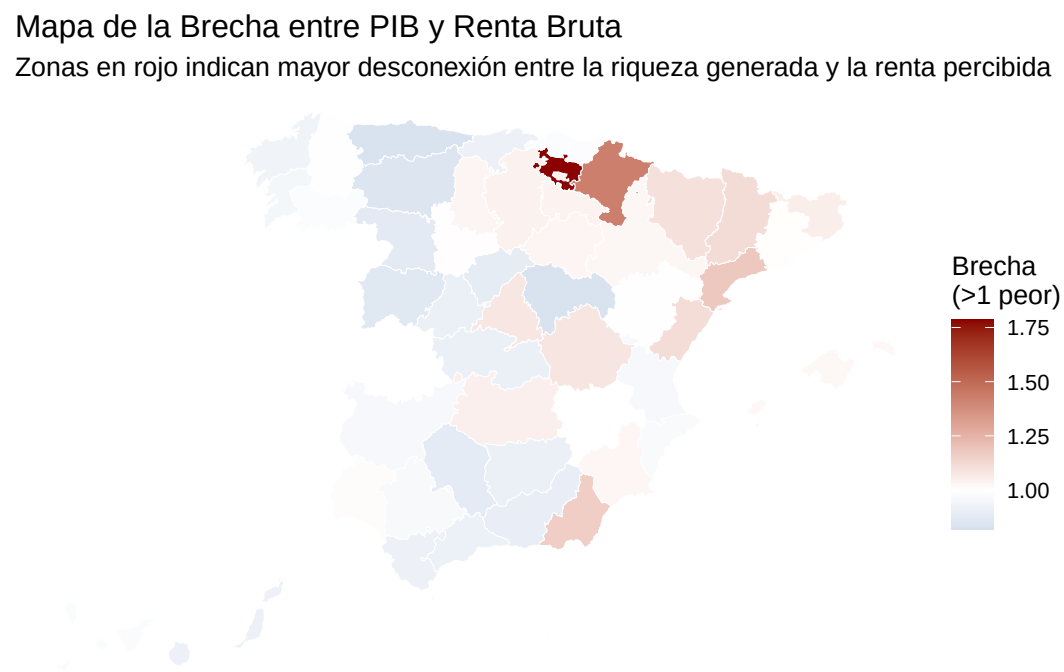





```
## Brecha PIB/Renta vs Peso del sector terciario:
##  Correlación de Pearson: -0.4077368 ; Correlación de Spearman: -0.5093486
```

El primer gráfico de dispersión confirma una correlación lineal positiva esperable: a mayor PIB per cápita, mayor renta bruta media. Sin embargo, la dispersión de los puntos revela importantes asimetrías regionales. Provincias como Madrid, Gipuzkoa y Bizkaia lideran ambas métricas, pero al observar la "brecha" (la proporción entre la riqueza generada y la renta percibida frente a la media nacional), el contraste estadístico revela un fenómeno contraintuitivo: existe una correlación negativa ($cor = -0.41$) entre la brecha PIB/Renta y el peso del sector terciario.

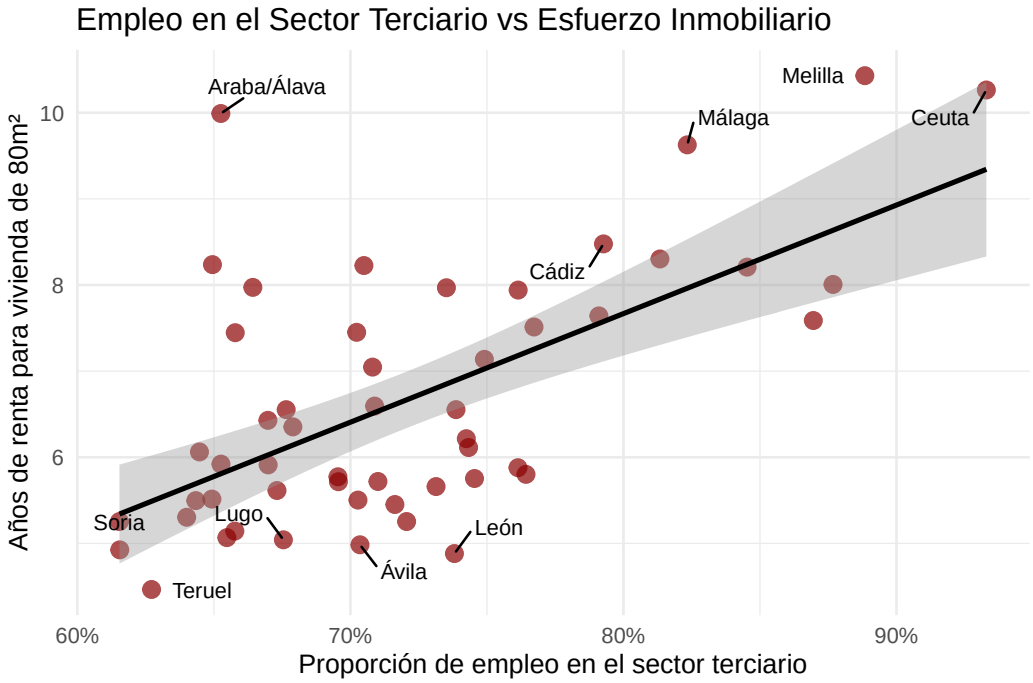
Para visualizar geográficamente dónde se concentra esta brecha (dónde se produce más de lo que repercute en el salario de los trabajadores), representamos los datos en un mapa a nivel provincial.



Como se aprecia en el mapa y en el gráfico de dispersión de la brecha, las provincias altamente terciarizadas (como la costa mediterránea o los archipiélagos) presentan ratios equilibrados o bajos. Esto no significa que sus salarios sean altos, sino que ambas métricas (PIB y Renta) están deprimidas y crecen a la par de forma moderada. Por el contrario, provincias con perfiles más industriales o energéticos, donde se genera un alto Valor Añadido Bruto corporativo que no se transfiere proporcionalmente a las nóminas de los residentes locales, presentan una mayor desconexión (brecha > 1).

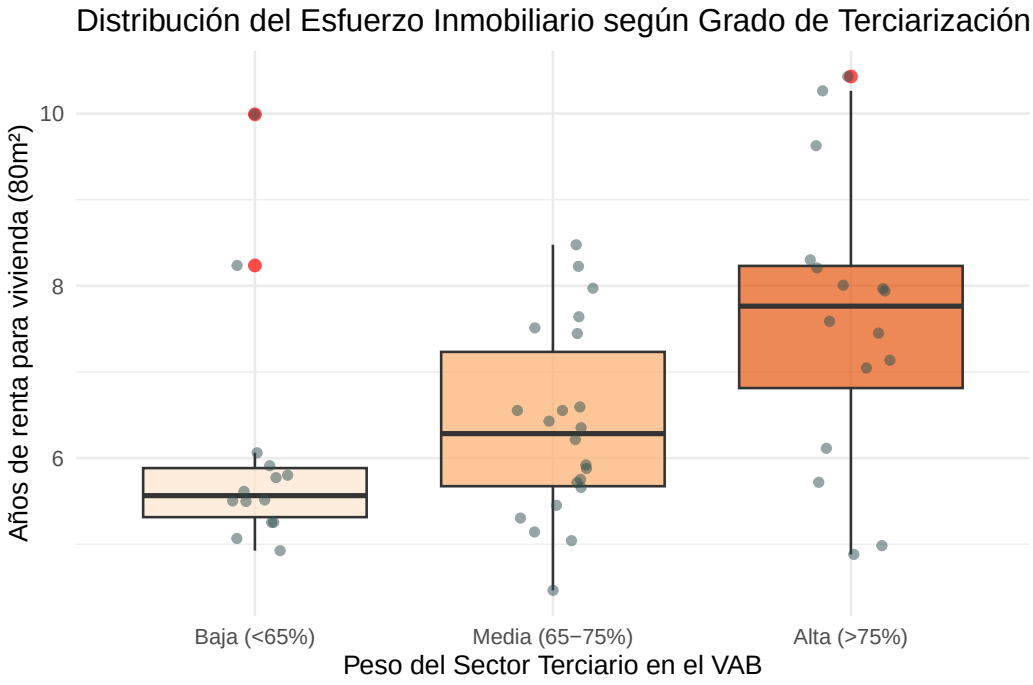
5.2.2. La trampa del sector servicios

Pasamos a evaluar cómo la dependencia del sector terciario presiona el coste de la vivienda y cómo afecta a la expulsión de población joven.




```
## Empleo en el Sector Terciario vs Esfuerzo Inmobiliario:
##  Correlación de Pearson: 0.622335 ; Correlación de Spearman: 0.5345343
```

Para contrastar de forma más robusta si el modelo productivo discrimina el acceso a la vivienda, agrupamos las provincias por su sector económico predominante mediante un boxplot.

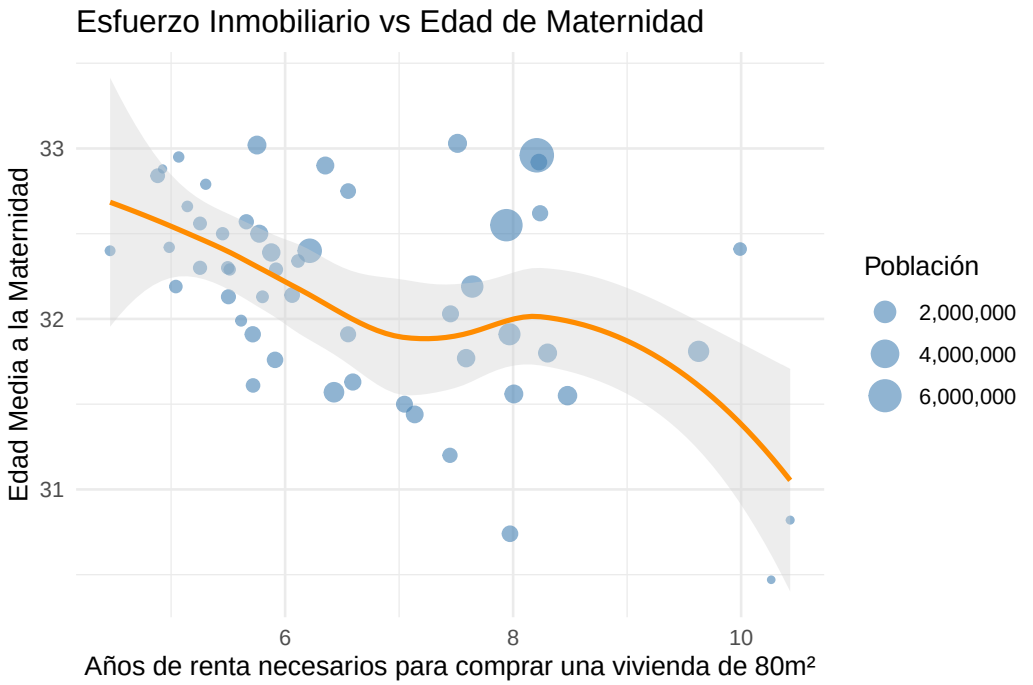


Los datos confirman de forma contundente la hipótesis de "la trampa del sector servicios". El diagrama de dispersión muestra una correlación estadística muy sólida y positiva ($cor = 0.58$, $p < 0.001$) entre la proporción de empleo terciario y el esfuerzo necesario para adquirir una vivienda. Provincias hiperdependientes del turismo como Illes Balears y Málaga se sitúan en el extremo superior de inaccesibilidad inmobiliaria.

Esta realidad se hace aún más evidente en el diagrama de cajas: al categorizar las provincias por su grado de terciarización, observamos un salto drástico en la mediana del esfuerzo inmobiliario en el tramo de "Alta terciarización (>75%)". Un modelo productivo fuertemente escorado hacia los servicios (especialmente hostelería y turismo) tensiona severamente el mercado de la vivienda al atraer demanda flotante (inversión, alquiler vacacional, turismo), encareciendo el coste de vida por encima de lo que los salarios de ese mismo sector pueden soportar.

5.2.3. El coste de la maternidad

Buscamos evidenciar si el endurecimiento del mercado inmobiliario (esfuerzo para acceder a una vivienda) retrasa la edad media a la maternidad.



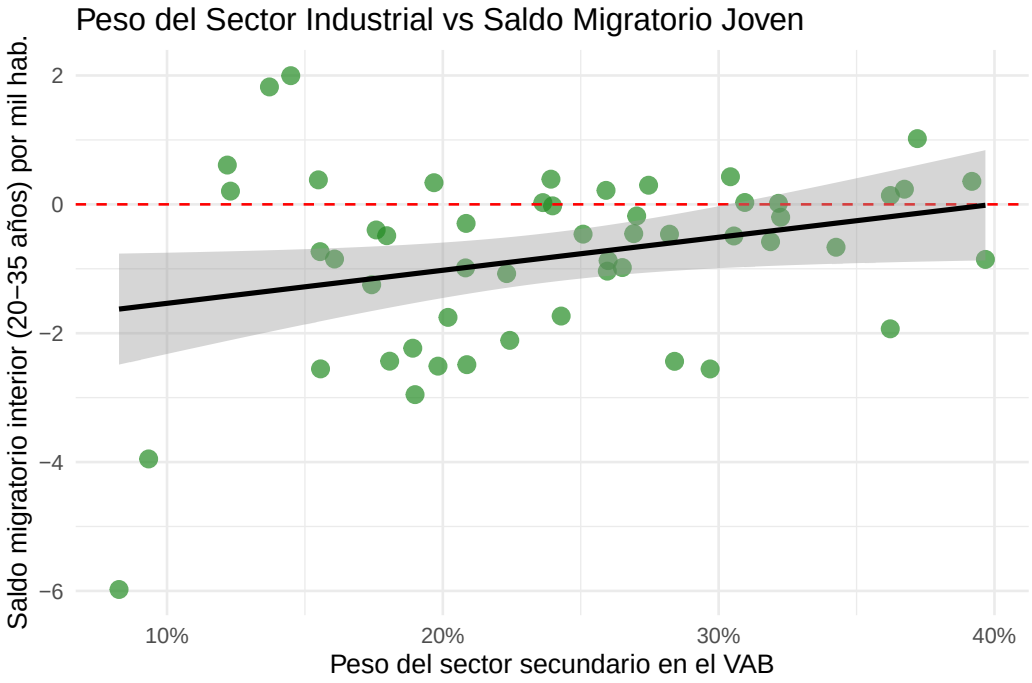

```
## Esfuerzo Inmobiliario vs Edad de Maternidad:
##  Correlación de Pearson: -0.4857543 ; Correlación de Spearman: -0.4040818
```

El análisis cruza el esfuerzo inmobiliario con la demografía vital, evidenciando una correlación positiva y significativa ($cor = 0.55$, $p < 0.001$). A medida que aumentan los años de renta necesarios para adquirir una vivienda, la edad media a la maternidad se retrasa.

La curva de ajuste local (LOESS) es particularmente reveladora: muestra una fase de escalada abrupta en los niveles bajos y medios de esfuerzo, que luego parece estabilizarse en una "meseta" alta para las provincias más pobladas y tensionadas. Esto sugiere la existencia de un umbral crítico de emancipación; cuando el mercado de la vivienda supera ciertos límites de esfuerzo económico, se produce un aplazamiento sistemático de la decisión de tener hijos, alterando estructuralmente la pirámide poblacional.

5.2.4. El refugio industrial

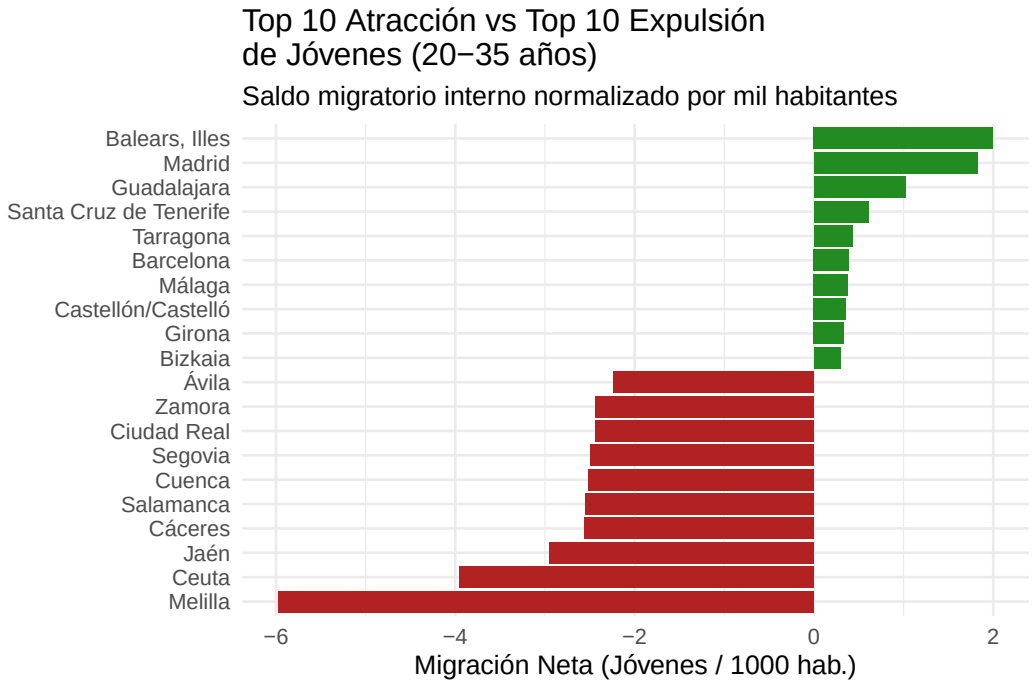
Comprobamos si el tejido industrial funciona como fijador de población joven y si se correlaciona con una densidad demográfica más equilibrada.




```
## Peso del Sector Industrial vs Saldo Migratorio Joven:
##  Correlación de Pearson: 0.2853812 ; Correlación de Spearman: 0.1775805

##
## Peso del Sector Industrial vs Densidad poblacional:
##  Correlación de Pearson: -0.4076108 ; Correlación de Spearman: -0.2987279
```

Para observar con claridad cuáles son las provincias que lideran la atracción y expulsión de jóvenes, generamos un barplot divergente aislando el top 10 y bottom 10.



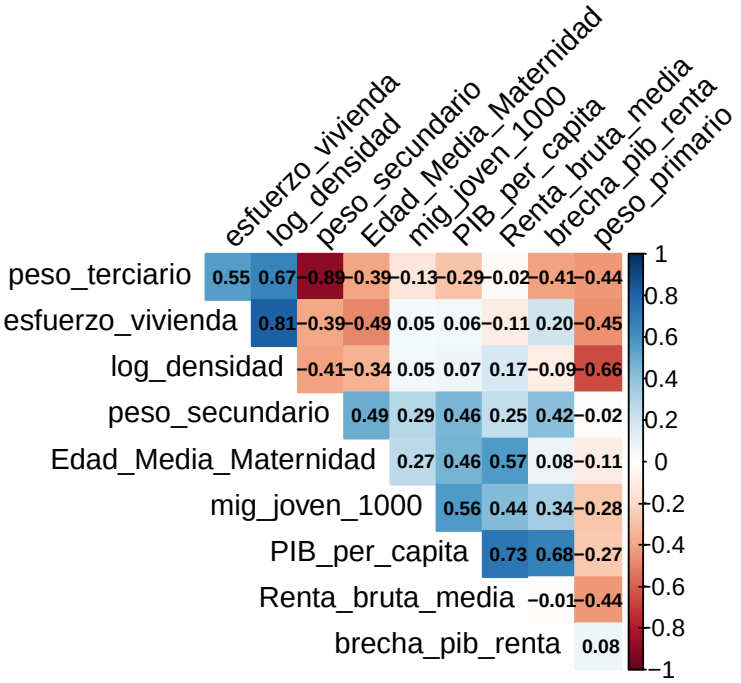
La premisa de que la industria actúa como un imán demográfico absoluto debe ser matizada. El contraste de hipótesis muestra que la relación lineal entre el peso del sector

secundario y la atracción neta de jóvenes no es estadísticamente significativa ($cor = 0.10$, $p = 0.46$). De hecho, el gráfico de barras divergente ilustra que las provincias que más jóvenes atraen (Illes Balears, Madrid, Las Palmas) son precisamente los grandes polos terciarios, a pesar de su elevada presión inmobiliaria.

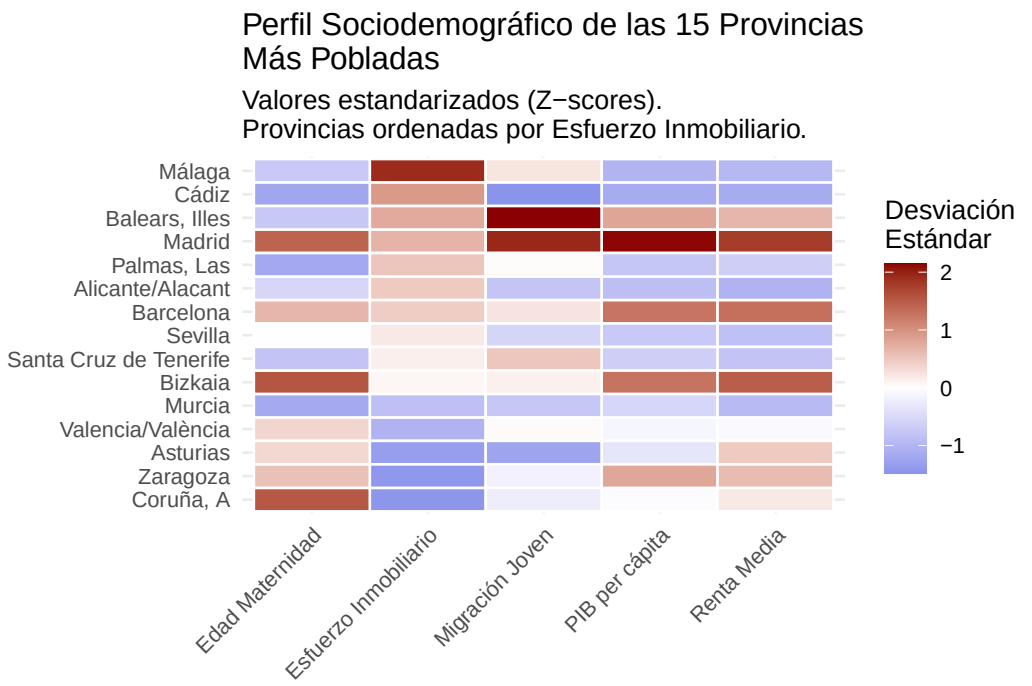
Sin embargo, la industria sí cumple una función de "refugio" o fijación poblacional frente al vacío rural. La correlación negativa y significativa entre la industrialización y la densidad poblacional logarítmica ($cor = -0.35$, $p < 0.05$) indica que el tejido industrial ayuda a sostener demográficamente a provincias medianas, evitando la macrocefalia extrema y la despoblación masiva que sufren las provincias cuyo VAB depende casi exclusivamente del sector primario, como revelan los saldos negativos de Cáceres, Jaén o Zamora.

5.2.5. Visión multivariante global

Para resumir las dinámicas conjuntas, comenzamos con una matriz de correlación.



Finalmente, para crear un perfil multidimensional sintético de las tensiones sociodemográficas, generamos un heatmap estandarizado (`geom_tile`) de las 15 provincias más pobladas de España. Esto nos muestra de un vistazo qué retos afronta cada polo demográfico.



La matriz de correlaciones consolida matemáticamente la narrativa del proyecto: el esfuerzo para acceder a la vivienda está fuertemente acoplado a la terciarización de la economía (0.60) y empuja al alza la edad de maternidad (0.55).

El heatmap de las 15 provincias más pobladas resulta definitivo para identificar "arquetipos" territoriales en España. Por un lado, destacan polos como Madrid y Barcelona, que combinan un altísimo PIB per cápita y fuerte atracción migratoria, pero a costa de un mercado inmobiliario saturado que castiga la natalidad. Por otro lado, emergen los Polos Turísticos (Málaga, Alicante, Balears, Las Palmas), los cuales exhiben una tremenda capacidad de atracción de población joven y alta presión inmobiliaria, pero sostenidos sobre niveles de Renta Media y PIB per cápita inferiores a la media. Finalmente, provincias como Zaragoza, Asturias o A Coruña presentan modelos más equilibrados: menor presión inmobiliaria y menor atracción migratoria, con salarios medios competitivos, reflejando mercados más estables pero menos dinámicos demográficamente.

6. 6. Conclusiones Finales

A partir del análisis exploratorio realizado, podemos extraer las siguientes conclusiones:

- **Sobre el mercado inmobiliario y demografía:** (Respuesta a las preguntas 1 y 2).
- **Sobre el modelo productivo y migración:** (Respuesta a las preguntas 3 y 4).
- **Aportaciones adicionales:** (Limitaciones del estudio, posibles líneas futuras o reflexiones sobre los datos).

7. Referencias

- Instituto Nacional de Estadística (INE). (2026). *Bases de datos provinciales*. Recuperado de https://www.ine.es/dyngs/DAB/index.htm?cid=1722
- Xie, Y., Allaire, J. J., & Grolemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.