MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Nombre Apellido 1[1], Nombre Apellido 2[1], Nombre Apellido 3[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. 1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es analizar cómo el modelo productivo de las diferentes provincias españolas condiciona sus mercados laborales e inmobiliarios y, consecuentemente, altera el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación: 1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)? ¿Correlaciona esta desigualdad de manera directa con un peso excesivo del sector servicios? 2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Existe una brecha salarial más acentuada en aquellas provincias cuyo PIB depende mayoritariamente del sector agrícola frente a las centradas en servicios?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)? 3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente? 4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?¿Se constata una relación entre el nivel de industrialización de una provincia y una distribución poblacional más homogénea (evitando la macrocefalia poblacional concentrada solo en la capital)?

2. 2. Importación y Acondicionamiento de Datos

En esta sección procedemos a cargar los conjuntos de datos descargados del INE. Como la fuente de datos no proporcionaba los datos estrictamente necesarios para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas), el primer paso será acondicionar los datos para seleccionar los que nos interesan y juntarlos todos en la misma estructura de datos.

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

Para ello, comenzamos cargando los datos, los ficheros originales se encuentran almacenados en la carpeta local `data/raw`. Los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Como el proceso es común para todos los ficheros a cargar, hemos implementado una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas. Usamos esta función para cargar los distintos conjuntos de datos.

```
leer_base <- function(fichero, separador) {
  readr::read_delim(
    file = fichero,
    delim = separador,
    locale = readr::locale(decimal_mark = ",", grouping_mark = "."),
    na = c("", "NA", "null",".."),
    name_repair = "minimal",
    show_col_types = FALSE,
    progress = FALSE
  )
}
```

```
# Los datos no se deberían cargar limpios, si no sucios y tratarlos en este archiv
#load("./data/Datos_SocioEcon.Rdata")
#load("./data/Datos_Laborales.Rdata")

# Juntamos los datos en formato tidy. Para lo cual separamos los datos laborales e

#laborales_tidy <- datos_laborales_ESP %>%
#  pivot_wider(
#    names_from = Sector,
#    values_from = c(Personas_Ocupadas, VAB),
#    # Modificamos el nombre para que quede claro, ej: "Personas_Ocupadas_Primario"
#    names_glue = "{.value}_{Sector}"
#  )

#df_completo <- datos_socioecon_ESP %>%
#  full_join(laborales_tidy,by = "id") %>%
#  separate(id, into = c("Periodo", "Cod_Provincia"), sep = "_", convert = FALSE)
#  mutate(Periodo = as.integer(Periodo)) %>%
#  left_join(ine_provincias,by = "Cod_Provincia") %>%
#  rename(Provincia = Nom_Provincia) %>%
#  select(-Cod_Provincia)

# Aquí se realizará el proceso de limpieza inicial y el 'left_join'
# por el código de provincia para unificar todo en un único dataset 'df_final'.
```

Explicación detallada de los pasos seguidos para homogeneizar los nombres de las columnas, filtrar los años de estudio (ej. 2015-2022) y el cruce de las tablas.

3. 3. Análisis de Datos Perdidos (NAs) e Imputación

Durante la integración de diferentes fuentes oficiales, es habitual encontrar valores perdidos. A continuación, cuantificamos y analizamos la naturaleza de estos *missing values*.

```
# Código para identificar y visualizar NAs
# Aplicación de métodos de imputación si procede (ej. media, interpolación) o elim
```

Justificación de la decisión tomada: por qué se ha elegido un método de imputación concreto o por qué se ha descartado una variable con demasiados valores nulos.

4. 4. Análisis de Valores Atípicos (Outliers)

Algunas provincias (como Madrid, Barcelona o regiones insulares) pueden presentar comportamientos extremos que distorsionen el análisis general.

```
# Código para visualizar outliers mediante boxplots
# Métodos aplicados (ej. Rango Intercuartílico - IQR) para filtrar o transformar v
```

Explicación del tratamiento de los outliers. Se debe justificar si se mantienen en el dataset porque representan información real valiosa o si se aplican transformaciones logarítmicas para suavizar su impacto.

5. 5. Análisis Exploratorio de Datos (EDA)

5.1. 5.1 Análisis Univariante

Exploración de la distribución individual de las principales variables de estudio (Salario, Precio Vivienda, Edad Maternidad).

```
# Código para histogramas, densidades y estadísticos descriptivos básicos.
```

Comentarios sobre las distribuciones obtenidas (simetría, sesgos, concentración de datos).

5.2. 5.2 Análisis Bivariante y Multivariante

En esta sección cruzamos las variables para dar respuesta a las preguntas planteadas en la introducción.

```
# Código para gráficos de dispersión (scatter plots), matrices de correlación (cor
```

Explicación detallada de los gráficos mostrados. "Contar la historia" que revelan los datos. ¿Se confirman las hipótesis iniciales?

6. 6. Conclusiones Finales

A partir del análisis exploratorio realizado, podemos extraer las siguientes conclusiones:

- **Sobre el mercado inmobiliario y demografía:** (Respuesta a las preguntas 1 y 2).
- **Sobre el modelo productivo y migración:** (Respuesta a las preguntas 3 y 4).
- **Aportaciones adicionales:** (Limitaciones del estudio, posibles líneas futuras o reflexiones sobre los datos).

7. Referencias

- Instituto Nacional de Estadística (INE). (2026). *Bases de datos provinciales*. Recuperado de https://www.ine.es/dyngs/DAB/index.htm?cid=1722
- Xie, Y., Allaire, J. J., & Grolemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.