MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Nombre Apellido 1[1], Nombre Apellido 2[1], Nombre Apellido 3[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. 1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es analizar cómo el modelo productivo de las diferentes provincias españolas condiciona sus mercados laborales e inmobiliarios y, consecuentemente, altera el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación: 1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)? ¿Correlaciona esta desigualdad de manera directa con un peso excesivo del sector servicios? 2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Existe una brecha salarial más acentuada en aquellas provincias cuyo PIB depende mayoritariamente del sector agrícola frente a las centradas en servicios?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)? 3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente? 4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?¿Se constata una relación entre el nivel de industrialización de una provincia y una distribución poblacional más homogénea (evitando la macrocefalia poblacional concentrada solo en la capital)?

2. 2. Importación y Acondicionamiento de Datos

En esta sección procedemos a cargar los conjuntos de datos descargados del INE. Como la fuente de datos no proporcionaba los datos estrictamente necesarios para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas), el primer paso será acondicionar los datos que más se ajustaban a los necesitados para seleccionar los que nos interesan y juntarlos todos en la misma estructura de datos.

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

Para ello, comenzamos cargando los datos, los ficheros originales se encuentran almacenados en la carpeta local `data/raw`. Los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Como el proceso es común para todos los ficheros a cargar, hemos implementado una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas. Usamos esta función para cargar los distintos conjuntos de datos.

```
leer_base <- function(fichero, separador) {
  readr::read_delim(
    file = fichero,
    delim = separador,
    locale = readr::locale(decimal_mark = ",", grouping_mark = "."),
    na = c("", "NA", "null",".."),
    name_repair = "minimal",
    show_col_types = FALSE,
    progress = FALSE
  )
}
```

Explicación detallada de los pasos seguidos para homogeneizar los nombres de las columnas, filtrar los años de estudio (ej. 2015-2022) y el cruce de las tablas. El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera, y se comentarán aquellos que requieran mayor detenimiento. En general, el acondicionamiento de los datos ha requerido las siguientes acciones:

- 1. Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- 2. Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- 3. Para el estudio hemos considerado como instancia una provincia en cierto año, por lo que, con el fin de unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`). Para ello se ha implementado la siguiente función.

```
# Función para generar el ID único
generar_id_obs <- function(df, col_anyo, col_prov) {
  df %>%
    mutate(
      id = paste0(
        as.numeric({{ col_anyo }}),
        "_",
        str_pad(as.character({{ col_prov }}), width = 2, side = "left", pad = "0")
      )
    )
}
```

- 4. El INE ofrecía algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como el uso de estos escapaban del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el

identificador único, los hemos agregado usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).

- 5. En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- 6. A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino. Para ello el procedimiento suele ser similar al siguiente:

```
# En las comunidades uniprovinciales, el fichero incluye filas regionales
# (CPRO vacio) cuyo valor coincide con el de la provincia. Las incorporamos
# usando el codigo de comunidad autonoma antes de eliminar CODAUTO.
coste_uniprov_codes <- c(
  "03" = "33", # Asturias
  "04" = "07", # Illes Balears
  "06" = "39", # Cantabria
  "13" = "28", # Madrid
  "14" = "30", # Murcia
  "15" = "31", # Navarra
  "17" = "26", # La Rioja
  "18" = "51", # Ceuta
  "19" = "52"  # Melilla
)

coste_vivienda <- coste_vivienda %>%
  mutate(
    codigo_ccaa = str_pad(as.character(.data[["CODAUTO"]]), width = 2, side = "lef
    codigo_ccaa = case_when(
      str_detect(str_to_lower(Comunidad_Autonoma), "astur") ~ "03",
      str_detect(str_to_lower(Comunidad_Autonoma), "balear") ~ "04",
      str_detect(str_to_lower(Comunidad_Autonoma), "cantabr") ~ "06",
      str_detect(str_to_lower(Comunidad_Autonoma), "madrid") ~ "13",
      str_detect(str_to_lower(Comunidad_Autonoma), "murcia") ~ "14",
      str_detect(str_to_lower(Comunidad_Autonoma), "navarr") ~ "15",
      str_detect(str_to_lower(Comunidad_Autonoma), "rioja") ~ "17",
      str_detect(str_to_lower(Comunidad_Autonoma), "ceuta") ~ "18",
      str_detect(str_to_lower(Comunidad_Autonoma), "melilla") ~ "19",
      TRUE ~ codigo_ccaa
    ),
    CPRO = if_else(
      is.na(CPRO),
      unname(coste_uniprov_codes[codigo_ccaa]),
      as.character(CPRO)
    )
  ) %>%
  select(-codigo_ccaa)

coste_vivienda$CODAUTO <- NULL
coste_vivienda$Comunidad_Autonoma <- NULL
```

- 7. De igual manera, en esos casos, para extraer únicamente el valor de las provincias (ni el total nacional ni niveles regionales), hacemos uso de la siguiente función, que identifica las provincias que se encuentran únicamente en la lista oficial del INE.

```
filtrar_provincias <- function(df) {
  df %>%
    mutate(id_prov = str_pad(as.character(id_prov), width = 2, side = "left", pad
    filter(id_prov %in% ine_provincias$id_prov)
}
```

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

```
# Juntamos los datos en formato tidy. Para lo cual separamos los datos laborales e

laborales_tidy <- datos_laborales_ESP %>%
  pivot_wider(
    names_from = Sector,
    values_from = c(Personas_Ocupadas, VAB),
     #Modificamos el nombre para que quede claro el valor, ej: "Personas_Ocupadas_
    names_glue = "{.value}_{Sector}"
  )

df_completo <- datos_socioecon_ESP %>%
  full_join(laborales_tidy,by = "id") %>%
  separate(id, into = c("Periodo", "id_prov"), sep = "_", convert = FALSE) %>%
  mutate(Periodo = as.integer(Periodo)) %>%
  left_join(ine_provincias,by = "id_prov")%>%
  rename(Provincia = Provincia_clean) %>%
  select(-id_prov)

# Aquí se realizará el proceso de limpieza inicial y el 'left_join'
# por el código de provincia para unificar todo en un único dataset 'df_final'.
```

3. 3. Análisis de Datos Perdidos (NAs) e Imputación

Durante la integración de diferentes fuentes oficiales, es habitual encontrar valores perdidos. A continuación, cuantificamos y analizamos la naturaleza de estos *missing values*.

```
# Código para identificar y visualizar NAs
# Aplicación de métodos de imputación si procede (ej. media, interpolación) o elim
```

Justificación de la decisión tomada: por qué se ha elegido un método de imputación concreto o por qué se ha descartado una variable con demasiados valores nulos.

4. 4. Análisis de Valores Atípicos (Outliers)

Algunas provincias (como Madrid, Barcelona o regiones insulares) pueden presentar comportamientos extremos que distorsionen el análisis general.

```
# Código para visualizar outliers mediante boxplots
# Métodos aplicados (ej. Rango Intercuartílico - IQR) para filtrar o transformar v
```

Explicación del tratamiento de los outliers. Se debe justificar si se mantienen en el dataset porque representan información real valiosa o si se aplican transformaciones logarítmicas para suavizar su impacto.

5. 5. Análisis Exploratorio de Datos (EDA)

5.1. 5.1 Análisis Univariante

Exploración de la distribución individual de las principales variables de estudio (Salario, Precio Vivienda, Edad Maternidad).

```
# Código para histogramas, densidades y estadísticos descriptivos básicos.
```

Comentarios sobre las distribuciones obtenidas (simetría, sesgos, concentración de datos).

5.2. 5.2 Análisis Bivariante y Multivariante

En esta sección cruzamos las variables para dar respuesta a las preguntas planteadas en la introducción, para lo cual fijamos un año concreto.

Cabe destacar que por limitaciones en los datos, aproximaremos el salario medio mediante la renta bruta media y los datos respectivos a hostelería y turismo quedan englobadas en el sector terciario. Además, para contabilizar la migración, normalizaremos por el número de habitantes de la provincia para que no dominen las provincias de mayor población y obtendremos la migración por 1000 habitantes. Por otra parte, calculamos el peso de cada sector en la economía, la densidad poblacional y el esfuerzo para adquirir una vivienda.

```
Anyo <- 2018   #Fijamos un año para el análisis

# Superficie provincial a partir de mapSpain (para la densidad)
areas_prov <- esp_get_prov() %>%
  mutate(area_km2 = as.numeric(st_area(geometry)) / 1e6) %>%
  st_drop_geometry() %>%
  select(id_prov = cpro, area_km2)

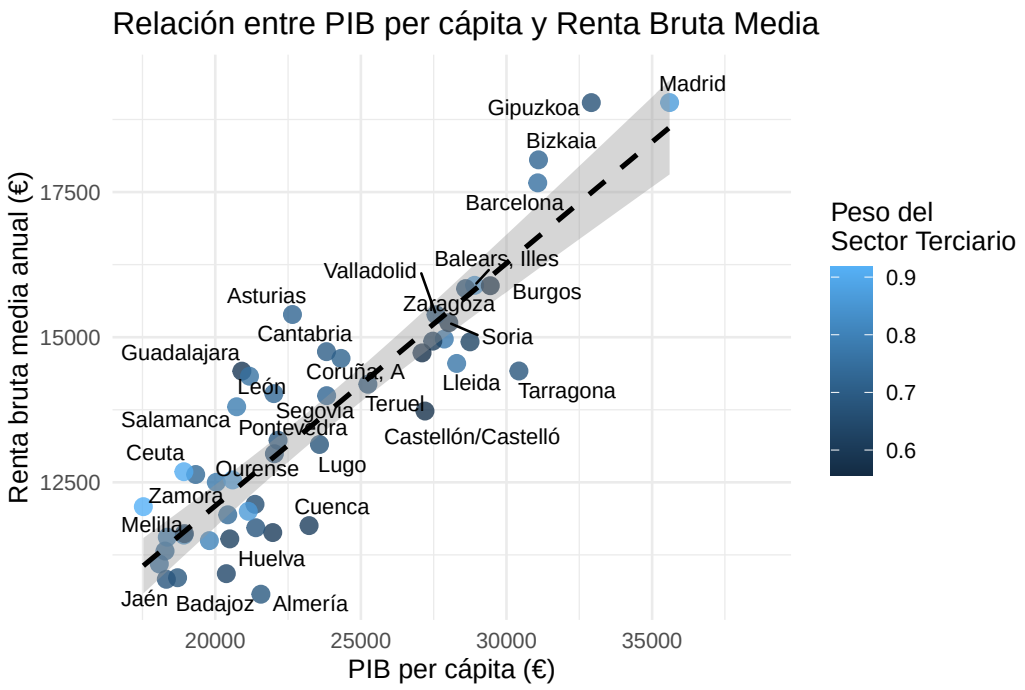
df_completo <- df_completo %>%
  left_join(ine_provincias, by = c("Provincia" = "Provincia_clean")) %>%  # recupe
  left_join(areas_prov, by = "id_prov") %>%
  mutate(
    peso_primario     = VAB_Primario   / VAB_Total,
    peso_secundario   = VAB_Secundario / VAB_Total,
    peso_terciario    = VAB_Terciario  / VAB_Total,
    emp_terciario     = Personas_Ocupadas_Terciario / Personas_Ocupadas_Total,
    # años de renta bruta media necesarios para una vivienda de 80 m2
    # (es la inversa de la ratio Salario/Vivienda de la pregunta 3)
    esfuerzo_vivienda = Precio_m2 * 80 / RentaBrutaMedia,
    mig_joven_1000    = Migracion_Interior / Habitantes * 1000,
    log_densidad      = log10(Habitantes / area_km2)
  ) %>%
  group_by(Periodo) %>%
  mutate(
    # >1: la provincia genera más PIB que renta percibe, respecto a la media nacio
    brecha_pib_renta = (PIB_per_capita / mean(PIB_per_capita, na.rm = TRUE)) /
                       (RentaBrutaMedia / mean(RentaBrutaMedia, na.rm = TRUE))
  ) %>%
  ungroup()

df_anio <- df_completo %>% filter(Periodo == Anyo) %>% select(-id_prov)
```

5.2.1. El espejismo del PIB

Analizamos la relación entre la riqueza generada (PIB per cápita) y la percibida (Renta Bruta Media), así como la influencia del sector terciario en la brecha entre ambas.

```
ggplot(df_anio, aes(x = PIB_per_capita, y = RentaBrutaMedia)) +
  geom_point(aes(colour = peso_terciario), size = 3, alpha = 0.8) +
  geom_smooth(method = "lm", col = "black", linetype = "dashed") +
  geom_text_repel(aes(label = Provincia), size = 3, max.overlaps = 10) +
  labs(
    title = "Relación entre PIB per cápita y Renta Bruta Media",
    x = "PIB per cápita (€)",
    y = "Renta bruta media anual (€)",
    color = "Peso del\nSector Terciario"
  ) +
  theme_minimal()
```

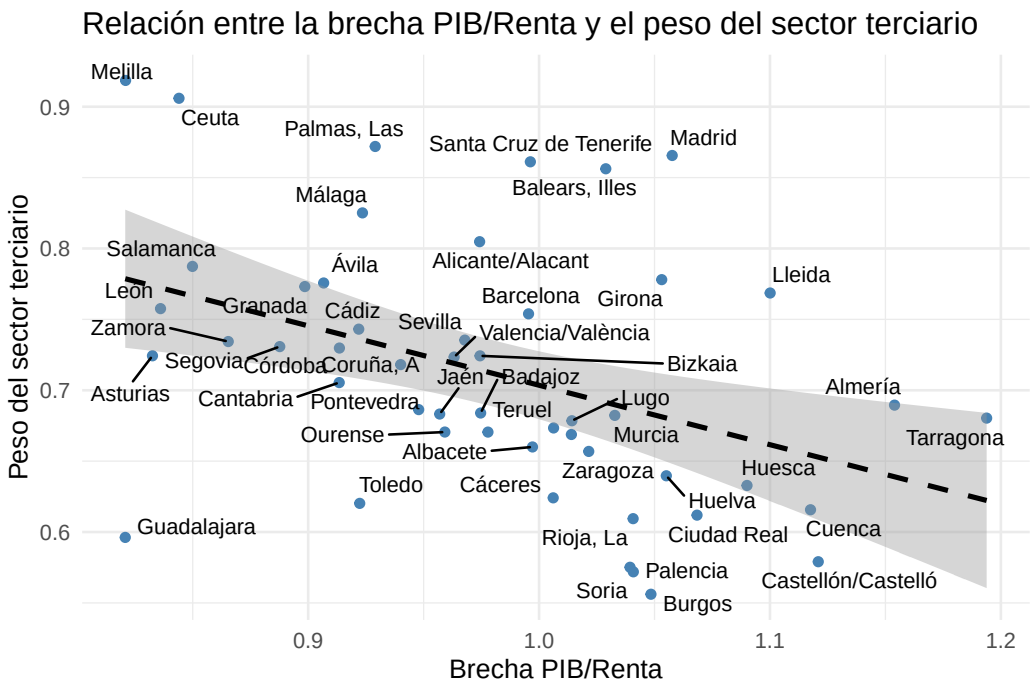



```
# Contraste de correlación: Brecha PIB/Renta vs Peso del sector terciario
cor.test(df_anio$brecha_pib_renta, df_anio$peso_terciario)
```

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$brecha_pib_renta and df_anio$peso_terciario
## t = -3.1463, df = 48, p-value = 0.002839
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.6204302 -0.1527197
## sample estimates:
##        cor
## -0.4134903
```

```
df_anio %>% ggplot(aes(x = brecha_pib_renta, y = peso_terciario)) +
  geom_point(colour = "steelblue") + geom_smooth(method = "lm", col = "black", lin
  geom_text_repel(aes(label = Provincia), size = 3, max.overlaps = 10) +
  labs(
    title = "Relación entre la brecha PIB/Renta y el peso del sector terciario",
```

```
    x = "Brecha PIB/Renta",
    y = "Peso del sector terciario",
    color = "Peso del\nSector Terciario"
  ) +
  theme_minimal()
```

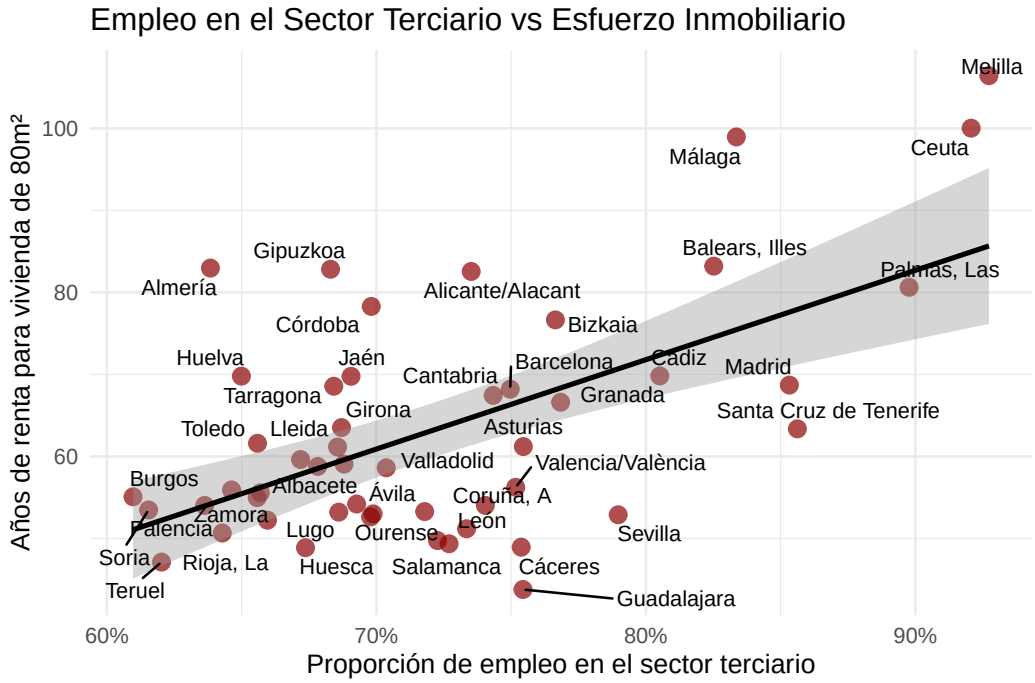


Interpretación: Observamos si las provincias que quedan por debajo de la línea de tendencia (mayor brecha, perciben menos renta de la que producen) coinciden con altos porcentajes del sector terciario. El contraste de hipótesis evalúa la significancia estadística de esta correlación.

5.2.2. La trampa del sector servicios

Evaluamos cómo la dependencia del sector terciario presiona el coste de la vivienda y cómo afecta a la expulsión de población joven.

```
ggplot(df_anio, aes(x = emp_terciario, y = esfuerzo_vivienda)) +
  geom_point(alpha = 0.7, color = "darkred", size = 3) +
  geom_smooth(method = "lm", se = TRUE, color = "black") +
  geom_text_repel(aes(label = Provincia), size = 3) +
  scale_x_continuous(labels = scales::percent) +
  labs(
    title = "Empleo en el Sector Terciario vs Esfuerzo Inmobiliario",
    x = "Proporción de empleo en el sector terciario",
    y = "Años de renta para vivienda de 80m²"
  ) +
  theme_minimal()
```




```
# Contraste: Empleo terciario y esfuerzo inmobiliario
cor.test(df_anio$emp_terciario, df_anio$esfuerzo_vivienda)
```

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$esfuerzo_vivienda
## t = 5.0334, df = 48, p-value = 7.195e-06
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.3699420 0.7443376
## sample estimates:
##      cor
## 0.587766
```

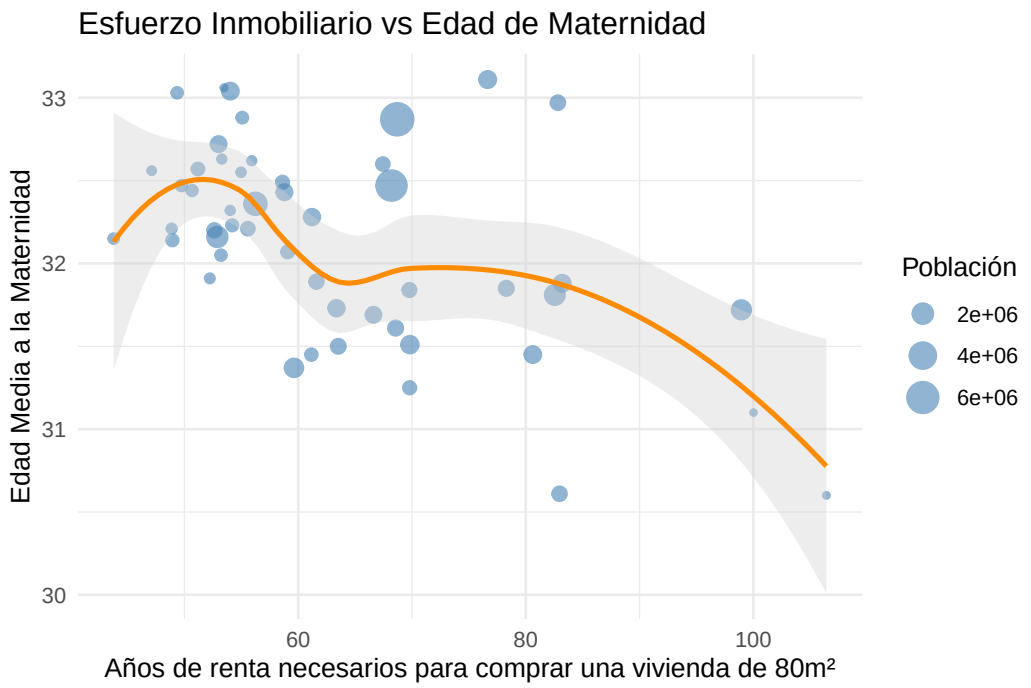
```
# Contraste: Empleo terciario y migración joven (expulsión)
cor.test(df_anio$emp_terciario, df_anio$mig_joven_1000)
```

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$mig_joven_1000
## t = 2.0101, df = 50, p-value = 0.04983
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.0005761889 0.5083971859
## sample estimates:
##       cor
## 0.2734335
```

5.2.3. El coste de la maternidad

Buscamos evidenciar si el endurecimiento del mercado inmobiliario (esfuerzo para acceder a una vivienda) retrasa la edad media a la maternidad.

```r
ggplot(df_anio, aes(x = esfuerzo_vivienda, y = Edad_Media_Maternidad)) +
  geom_point(aes(size = Habitantes), alpha = 0.6, color = "steelblue") +
  geom_smooth(method = "loess", color = "darkorange", fill = "lightgray") +
  labs(
    title = "Esfuerzo Inmobiliario vs Edad de Maternidad",
    x = "Años de renta necesarios para comprar una vivienda de 80m²",
    y = "Edad Media a la Maternidad",
    size = "Población"
  ) +
  theme_minimal()
```




```r
# Contraste de correlación lineal
cor.test(df_anio$esfuerzo_vivienda, df_anio$Edad_Media_Maternidad)
```

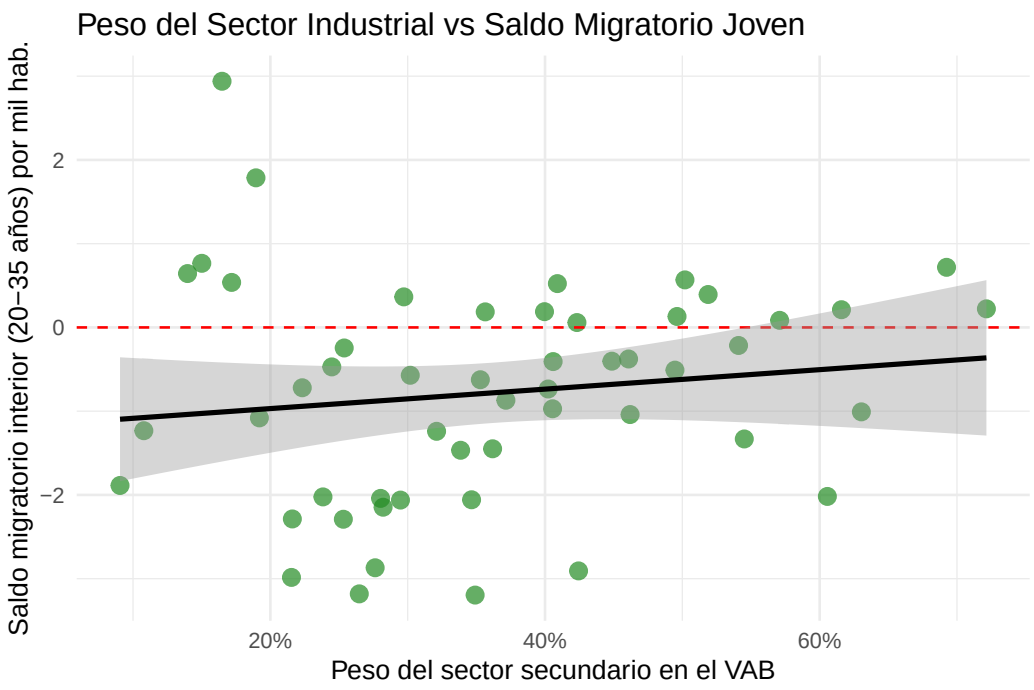
```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$esfuerzo_vivienda and df_anio$Edad_Media_Maternidad
## t = -4.5873, df = 48, p-value = 3.236e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.7198068 -0.3234215
## sample estimates:
##       cor
## -0.5520699
```

Interpretación: La curva de ajuste local (LOESS) permite observar si existe un crecimiento no lineal o un umbral crítico de esfuerzo inmobiliario a partir del cual la edad de maternidad se dispara.

5.2.4. El refugio industrial

Comprobamos si el tejido industrial funciona como fijador de población joven y si se correlaciona con una densidad demográfica más equilibrada.

```r
ggplot(df_anio, aes(x = peso_secundario, y = mig_joven_1000)) +
  geom_point(color = "forestgreen", size = 3, alpha = 0.7) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
  geom_smooth(method = "lm", color = "black") +
  scale_x_continuous(labels = scales::percent) +
  labs(
    title = "Peso del Sector Industrial vs Saldo Migratorio Joven",
    x = "Peso del sector secundario en el VAB",
    y = "Saldo migratorio interior (20-35 años) por mil hab."
  ) +
  theme_minimal()
```




```r
# Contraste: Industrialización vs retención de jóvenes
cor.test(df_anio$peso_secundario, df_anio$mig_joven_1000)
```

```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$peso_secundario and df_anio$mig_joven_1000
## t = 0.98037, df = 50, p-value = 0.3316
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.1408473  0.3954127
## sample estimates:
##       cor
## 0.1373316
```

```r
# Contraste: Industrialización vs Densidad poblacional
cor.test(df_anio$peso_secundario, df_anio$log_densidad)
```

```
##
##  Pearson's product-moment correlation
```

```
##
## data:  df_anio$peso_secundario and df_anio$log_densidad
## t = -2.2209, df = 50, p-value = 0.03092
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.5292693 -0.0291316
## sample estimates:
##       cor
## -0.2996497
```

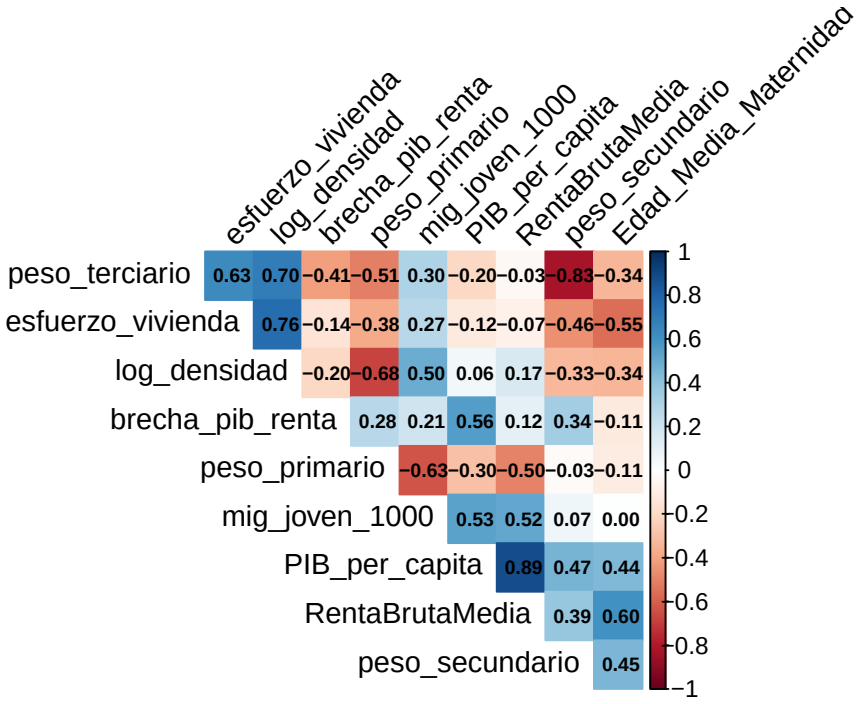
5.2.5. Visión multivariante global

Para resumir las dinámicas entre el modelo productivo, la economía familiar y la demografía, construimos una matriz de correlación con las variables numéricas clave.

```r
# Seleccionamos las variables continuas de interés
var_corr <- df_anio %>%
  select(
    PIB_per_capita, RentaBrutaMedia, brecha_pib_renta,
    peso_primario, peso_secundario, peso_terciario,
    esfuerzo_vivienda, Edad_Media_Maternidad, mig_joven_1000, log_densidad
  ) %>%
  drop_na()

# Calculamos matriz de correlación
matriz_cor <- cor(var_corr)

# Visualización
corrplot(matriz_cor,
         method = "color",
         type = "upper",
         order = "hclust",
         tl.col = "black",
         tl.srt = 45,
         addCoef.col = "black",
         number.cex = 0.7,
         diag = FALSE)
```



Explicación detallada de los gráficos mostrados. "Contar la historia" que revelan los datos. ¿Se confirman las hipótesis iniciales?

6. 6. Conclusiones Finales

A partir del análisis exploratorio realizado, podemos extraer las siguientes conclusiones:

- **Sobre el mercado inmobiliario y demografía:** (Respuesta a las preguntas 1 y 2).
- **Sobre el modelo productivo y migración:** (Respuesta a las preguntas 3 y 4).
- **Aportaciones adicionales:** (Limitaciones del estudio, posibles líneas futuras o reflexiones sobre los datos).

7. Referencias

- Instituto Nacional de Estadística (INE). (2026). *Bases de datos provinciales*. Recuperado de https://www.ine.es/dyngs/DAB/index.htm?cid=1722
- Xie, Y., Allaire, J. J., & Grolemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.