MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Luis Molina Villar[1], Rubén Sánchez Munuera[1], Pablo Gallart Carbonell[1]

[1] Máster en Ciencia de Datos, Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos (AED) evalúa las dinámicas entre el modelo productivo provincial, el coste de la vivienda y su impacto en la demografía española utilizando datos del INE.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar cómo la hiperdependencia de ciertos sectores tensiona el mercado inmobiliario, afectando a los saldos migratorios y al ciclo vital. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos y atípicos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía; Mercado Inmobiliario; R

1. 1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es realizar un análisis exploratorio de distintos indicadores socioeconómicos a nivel provincial en España, y sus posibles relaciones. En particular, los indicadores estudiados corresponden a el modelo productivo de las diferentes provincias, sus mercados laborales e inmobiliarios, y el ciclo vital y demográfico de sus habitantes.

A partir del cruce de datos, nos planteamos responder a las siguientes preguntas de investigación:

1. **El espejismo del PIB:** ¿En qué provincias es mayor la brecha entre la riqueza generada (PIB per cápita) y la riqueza percibida por los trabajadores (salario medio)?
2. **La trampa del sector servicios:** ¿Existe una correlación entre el porcentaje de empleo en hostelería/turismo y el encarecimiento de la vivienda respecto al salario medio?¿Genera la hiperdependencia del sector turismo una expulsión de la población joven nativa (saldo migratorio interior negativo para la franja de 20-35 años)?
3. **El coste de la maternidad:** ¿Hay un umbral crítico en la ratio Salario/Vivienda a partir del cual la edad media a la maternidad aumenta significativamente?
4. **El refugio industrial:** ¿Logran las provincias con un tejido industrial fuerte retener mejor a la población joven (saldo migratorio positivo) frente a aquellas con modelos primarios?

2. 2. Importación y Acondicionamiento de Datos

El primer paso para el análisis es cargar los conjuntos de datos obtenidos del INE. Los ficheros originales se encuentran almacenados en la carpeta local `data/raw`.

La fuente de datos no proporciona los datos estrictamente adecuados para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas). Por lo tanto, el primer paso será acondicionar los datos que más se

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Data* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Data* for possible open access publication under the terms and conditions of the Creative Commons Attri- bution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

ajustaban a los necesitados para seleccionar los que nos interesan y juntarlos todos en la misma estructura de datos. Uno de los factores principales a tener en cuenta es que los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Los datos han sido importados a `R` usando una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas, usando la función `locale`.

Explicación de los pasos seguidos para homogeneizar los nombres de las columnas, filtrar los años de estudio (ej. 2015-2021 y el cruce de las tablas.

El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera. Los principales pasos que han sido necesarios para el acondicionamiento de los datos ha requerido han sido:

- Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- En el conjunto de datos que queremos estudiar cada instancia es una provincia en cierto año. Con el fin de unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros de los datos originales, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`).
- El INE ofrece algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como estas variables escapan del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, se han agregado los datos, usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).
- En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino.
- Para extraer únicamente el valor de las provincias (ni el total nacional ni niveles regionales), filtramos usando la lista oficial de provincias del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. 3. Análisis de Datos Perdidos (NAs) e Imputación

Ahora que tenemos un conjunto de datos con todas las variables de interés, y las instancias adecuadamente identificadas, podemos proceder al análisis exploratorio propiamente dicho. Para empezar observamos la presencia de valores faltantes.

Table 1. Valores perdidos por variable

	Valores Perdidos
Periodo	0
Precio_m2	0
Habitantes	0
Edad_Media_Maternidad	0
Migracion_Interior	0
PIB_per_capita	0
RentaBrutaMedia	12
Personas_Ocupadas_Primario	7
Personas_Ocupadas_Secundario	0
Personas_Ocupadas_Terciario	0
VAB_Primario	0
VAB_Secundario	0
VAB_Terciario	0
Provincia	0

Por suerte, hay pocos valores perdidos, por lo que podemos visualizar sus instancias correspondientes para decidir que realizar con ellos.

Table 2. Instancias con valores faltantes

Provincia	Periodo	RentaBrutaMedia	Personas_Ocupadas_Primario
Araba/Álava	2015	NaN	2.350
Araba/Álava	2016	NaN	3.475
Araba/Álava	2017	NaN	3.850
Araba/Álava	2018	NaN	3.225
Araba/Álava	2019	NaN	2.825
Ceuta	2016	11988	NaN
Ceuta	2017	12094	NaN
Ceuta	2020	13718	NaN
Ceuta	2021	14499	NaN
Gipuzkoa	2015	NaN	2.700
Melilla	2015	11151	NaN
Melilla	2016	11377	NaN
Melilla	2019	12676	NaN
Navarra	2015	NaN	9.525
Navarra	2016	NaN	9.575
Navarra	2017	NaN	11.025
Navarra	2018	NaN	11.800
Navarra	2019	NaN	10.225
Navarra	2020	NaN	9.425

Observamos que los valores faltantes afectan solamente a 5 provincias, además, las variables afectadas son series temporales de valores numéricos (valores anuales de 2015 a 2021), y en todos los casos tenemos al menos un registro de toda la serie, por lo que la decisión sobre los valores faltantes es imputarlos siguiendo la siguiente norma. Se imputan los valores faltantes con la media del primer valor anterior no faltante, y el primer valor posterior no faltante. En caso de no haber valores anteriores o posteriores faltantes, se imputará el dato usando el primer dato posterior o respectivamente anterior no faltante.

Justificación de la decisión tomada: por qué se ha elegido un método de imputación concreto o por qué se ha descartado una variable con demasiados valores nulos.

4. 4. Análisis de Valores Atípicos (Outliers)

Algunas provincias (como Madrid, Barcelona o regiones insulares) pueden presentar comportamientos extremos que distorsionen el análisis general.

```
# Código para visualizar outliers mediante boxplots
# Métodos aplicados (ej. Rango Intercuartílico - IQR) para filtrar o transformar v
```

Explicación del tratamiento de los outliers. Se debe justificar si se mantienen en el dataset porque representan información real valiosa o si se aplican transformaciones logarítmicas para suavizar su impacto.

5. 5. Análisis Exploratorio de Datos (EDA)

5.1. 5.1 Análisis Univariante

En esta sección procedemos a examinar la distribución individual de las principales variables socioeconómicas, demográficas y de estructura productiva obtenidas tras el acondicionamiento del conjunto de datos. El objetivo central de este análisis univariante es caracterizar el comportamiento estadístico de cada magnitud —evaluando su tendencia central, grado de dispersión, presencia de asimetrías y colas pesadas— antes de abordar las relaciones bivariantes.

A partir del dataset unificado `df_completo` (resultante del cruce de las tablas de datos socioeconómicos y laborales), seleccionamos y derivamos las variables cuantitativas continuas organizadas en cuatro dimensiones:

- **Dimensión de Renta y Riqueza Macro vs. Micro:**
  - `PIB_per_capita`: Producto Interior Bruto provincial por habitante (€/hab). Mide la producción agregada regional.
  - `RentaBrutaMedia`: Renta bruta media disponible por persona (€/hab). Funciona como *proxy* del poder adquisitivo real percibido.
- **Dimensión del Mercado Inmobiliario:**
  - `Precio_m2_libre`: valor medio del m² de vivienda libre (€/m²), media anual de los cuatro trimestres.
  - `Precio_m2_libre`: lo mismo para vivienda protegida.
- **Dimensión Demográfica y Ciclo Vital:**
  - `Edad_Media_Maternidad`: Edad media de las madres al nacimiento del primer hijo (años).
  - `Migracion_Interior`: Saldo migratorio neto interprovincial en la cohorte joven de 19 a 35 años (número neto de personas).
  - `Habitantes`: Población provincial total residente (personas).
- **Dimensión de Estructura Productiva (Métricas Derivadas):**
  - `% Ocupados (Primario, Secundario, Terciario)`: Porcentaje de personas ocupadas en cada sector sobre el total provincial (%).
  - `% VAB (Primario, Secundario, Terciario)`: Porcentaje del Valor Añadido Bruto aportado por cada sector sobre el VAB total (%).

Para caracterizar formalmente la distribución de cada variable X, evaluamos la media muestral ($\bar{x}$), la mediana ($\tilde{x}$), la desviación típica muestral (s), los valores extremos ($\min(X)$, $\max(X)$) y el coeficiente de asimetría de Fisher (γ_1)[cite: 11]:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \quad s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}, \quad \gamma_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{3/2}}$$

Donde $n = 364$ representa el volumen total de observaciones del panel.

Table 3. Estadísticos de posición y dispersión del panel provincial (52 provincias, 2015–2021).

Variable	N	Media	Mediana	Desv. típ.	CV (%)	Mín.	Máx.
PIB per cápita (€)	364	23.266	21.993	4.884	21,0	16.255	38.711
Renta bruta media (€)	364	13.525	13.252	2.303	17,0	9.304	20.471
Precio m² vivienda (€)	364	1.162,5	1.100,8	289,0	24,9	760,1	2.140,8
Edad media maternidad (años)	364	32,13	32,20	0,63	2,0	29,63	33,38
Saldo migratorio 19-35 años (pers.)	364	0	-220	1.787	–	-2.156	15.116
Habitantes	364	902.029	607.127	1.168.472	129,5	83.517	6.779.888
Ocupados primario (%)	364	7,0	5,2	5,6	80,0	0,1	29,3
Ocupados secundario (%)	364	21,2	21,4	6,5	30,6	3,8	34,6
Ocupados terciario (%)	364	71,8	70,7	7,3	10,2	57,8	94,5
VAB primario (%)	364	4,8	4,0	3,9	81,0	0,0	18,2
VAB secundario (%)	364	31,9	32,0	10,9	34,0	8,5	56,0
VAB terciario (%)	364	63,2	62,2	11,3	17,8	42,0	91,4

Table 4. Cuartiles, forma de la distribución (asimetría y exceso de curtosis de Fisher) y porcentaje de la varianza total debido a diferencias entre provincias.

Variable	Q1	Q3	RIC	Asimetría	Curtosis	% var. entre prov.
PIB per cápita (€)	19.328	26.985	7.658	0,80	-0,02	93,7
Renta bruta media (€)	11.809	14.976	3.167	0,61	0,00	74,1
Precio m² vivienda (€)	950,0	1.243,7	293,7	1,23	1,10	98,4
Edad media maternidad (años)	31,76	32,56	0,80	-0,68	0,64	85,4
Saldo migratorio 19-35 años (pers.)	-535	118	653	5,62	37,86	76,2
Habitantes	322.714	1.024.161	701.446	3,53	13,27	100,0
Ocupados primario (%)	2,9	10,0	7,1	1,41	2,46	82,1
Ocupados secundario (%)	17,3	25,6	8,3	-0,35	-0,10	95,7
Ocupados terciario (%)	66,6	75,4	8,9	0,81	0,38	87,9
VAB primario (%)	1,9	6,7	4,8	1,16	1,19	97,2
VAB secundario (%)	24,3	39,4	15,1	-0,04	-0,61	97,8
VAB terciario (%)	55,2	69,1	13,9	0,56	-0,13	98,0

Table 5. Mediana provincial de cada variable por año.

Variable	2015	2016	2017	2018	2019	2020	2021
PIB per cápita (€)	20.214	20.686	21.641	22.094	23.116	21.037	23.488
Renta bruta media (€)	11.910	12.157	12.617	13.188	13.838	14.269	15.330
Precio m² vivienda (€)	1.089,5	1.100,3	1.096,3	1.097,6	1.100,7	1.104,3	1.115,1
Edad media maternidad (años)	32,01	32,04	32,19	32,21	32,29	32,33	32,51
Saldo migratorio 19-35 años (pers.)	-348	-301	-298	-267	-308	-27	-90
Habitantes	612.828	611.426	611.764	609.164	607.321	608.486	607.127
Ocupados primario (%)	5,5	5,7	5,4	5,1	4,9	5,0	5,5
Ocupados secundario (%)	21,3	21,1	21,6	22,1	22,4	22,6	21,6

Variable	2015	2016	2017	2018	2019	2020	2021
Ocupados terciario (%)	70,9	70,7	70,7	69,8	70,7	70,8	70,5
VAB primario (%)	4,2	4,1	3,5	3,9	3,7	4,3	4,6
VAB secundario (%)	32,7	32,4	31,4	31,6	32,0	29,8	34,7
VAB terciario (%)	62,3	62,5	62,3	62,6	63,0	63,9	61,4

Table 6. Coeficiente de variación (%) entre provincias por año (no definido para el saldo migratorio, que toma valores negativos).

Variable	2015	2016	2017	2018	2019	2020	2021
PIB per cápita (€)	21,1	21,4	21,1	20,8	20,6	20,3	19,5
Renta bruta media (€)	15,3	16,2	15,8	15,6	15,0	14,7	14,3
Precio m² vivienda (€)	22,6	24,0	24,1	25,2	26,2	26,2	26,5
Edad media maternidad (años)	2,1	2,0	1,9	1,9	1,9	1,7	1,7
Saldo migratorio 19-35 años (pers.)	–	–	–	–	–	–	–
Habitantes	128,6	129,3	130,0	130,7	131,4	132,3	131,9
Ocupados primario (%)	72,4	86,1	83,0	78,1	76,5	78,0	82,9
Ocupados secundario (%)	32,3	31,4	32,7	31,0	29,3	29,7	28,9
Ocupados terciario (%)	10,7	9,9	10,6	10,8	10,2	9,9	10,0
VAB primario (%)	82,2	78,2	85,3	79,8	81,0	82,5	81,6
VAB secundario (%)	33,5	33,4	35,8	35,9	35,0	34,3	31,7
VAB terciario (%)	17,8	17,8	18,4	18,3	17,9	17,4	18,1

Comentarios sobre las distribuciones obtenidas (simetría, sesgos, concentración de datos).

5.2. 5.2 Análisis Bivariante y Multivariante

En esta sección cruzamos las variables para dar respuesta a las preguntas planteadas en la introducción. Para ello, fijamos el análisis en el año 2018.

Aproximamos el salario medio mediante la renta bruta media y englobamos los datos de hostelería y turismo en el sector terciario. Calculamos el esfuerzo inmobiliario, el peso de cada sector, la densidad poblacional y normalizamos la migración joven (20-35 años) por cada 1.000 habitantes.

```
Anyo <- 2018

# Superficie provincial a partir de mapSpain (para la densidad)
areas_prov <- esp_get_prov() %>%
  mutate(area_km2 = as.numeric(st_area(geometry)) / 1e6) %>%
  st_drop_geometry() %>%
  select(id_prov = cpro, area_km2)

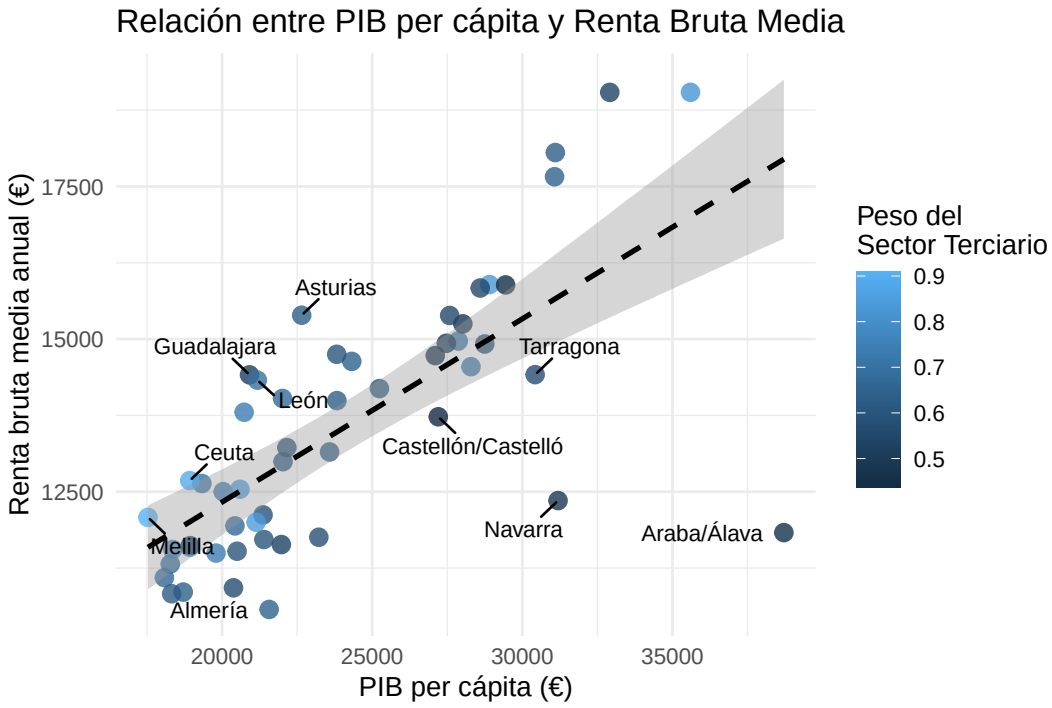
df_completo <- df_completo %>%
  left_join(ine_provincias, by = c("Provincia" = "Provincia_clean")) %>%
  left_join(areas_prov, by = "id_prov") %>%
  mutate(
    peso_primario     = VAB_Primario   / (VAB_Primario+VAB_Secundario+VAB_Terciari
    peso_secundario   = VAB_Secundario / (VAB_Primario+VAB_Secundario+VAB_Terciari
    peso_terciario    = VAB_Terciario  / (VAB_Primario+VAB_Secundario+VAB_Terciari
    emp_terciario     = Personas_Ocupadas_Terciario /(Personas_Ocupadas_Primario+P
    # Años de renta bruta media necesarios para una vivienda de 80 m2
    esfuerzo_vivienda = (Precio_m2 * 80) / RentaBrutaMedia,
```

```
    mig_joven_1000    = (Migracion_Interior / Habitantes) * 1000,
    log_densidad      = log10(Habitantes / area_km2)
  ) %>%
  group_by(Periodo) %>%
  mutate(
    # Brecha: si es >1, la provincia genera más PIB que renta percibe vs la media
    brecha_pib_renta = (PIB_per_capita / mean(PIB_per_capita, na.rm = TRUE)) /
                       (RentaBrutaMedia / mean(RentaBrutaMedia, na.rm = TRUE))
  ) %>%
  ungroup() %>%
  mutate(
    nivel_terciarizacion = case_when(
      peso_terciario < 0.65 ~ "Baja (<65%)",
      peso_terciario >= 0.65 & peso_terciario <= 0.75 ~ "Media (65-75%)",
      peso_terciario > 0.75 ~ "Alta (>75%)"
    ),
    nivel_terciarizacion = factor(nivel_terciarizacion,
                                  levels = c("Baja (<65%)", "Media (65-75%)", "Alt
  )

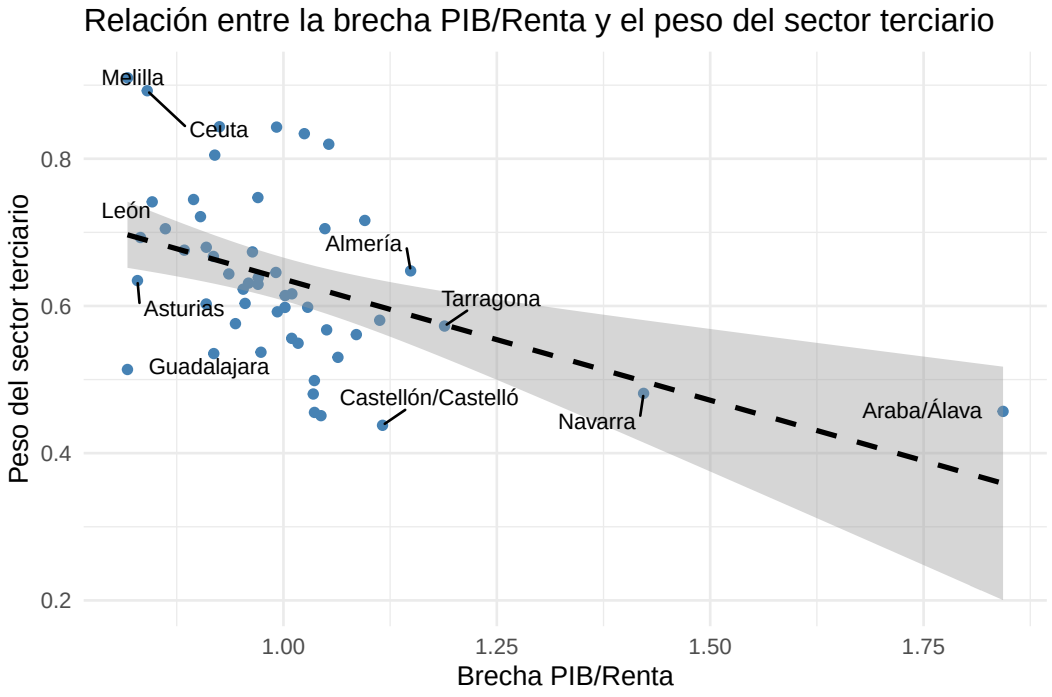
df_anio <- df_completo %>%
  filter(Periodo == Anyo) %>%
  mutate(
    # Filtramos el top 5 por arriba y por abajo para la Brecha PIB/Renta
    label_pib = ifelse(
      rank(brecha_pib_renta, ties.method = "first") <= 5 | rank(desc(brecha_pib_re
      as.character(Provincia),
      NA
    ),
    # Filtramos el top 5 por arriba y por abajo para el Esfuerzo Inmobiliario
    label_trampa = ifelse(
      rank(esfuerzo_vivienda, ties.method = "first") <= 5 | rank(desc(esfuerzo_viv
      as.character(Provincia),
      NA
    )
  )
```

5.2.1. El espejismo del PIB

Analizamos la relación entre la riqueza generada (PIB per cápita) y la percibida (Renta Bruta Media), así como la influencia del sector terciario en la brecha entre ambas.

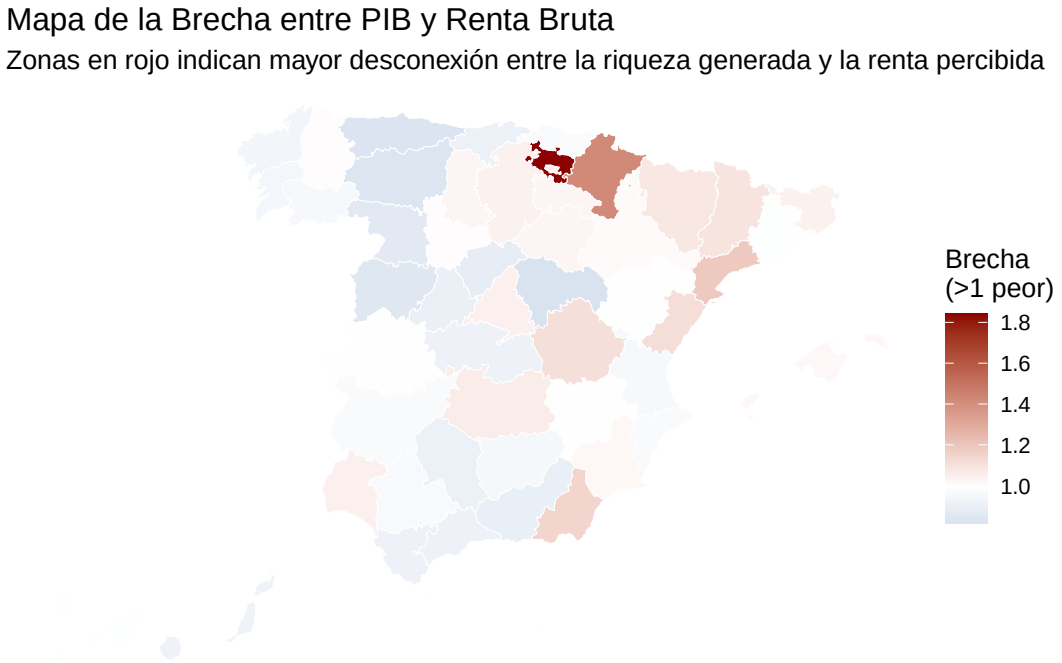



```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$brecha_pib_renta and df_anio$peso_terciario
## t = -3.5715, df = 50, p-value = 0.0007961
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.6444506 -0.2029036
## sample estimates:
##       cor
## -0.4508398
```



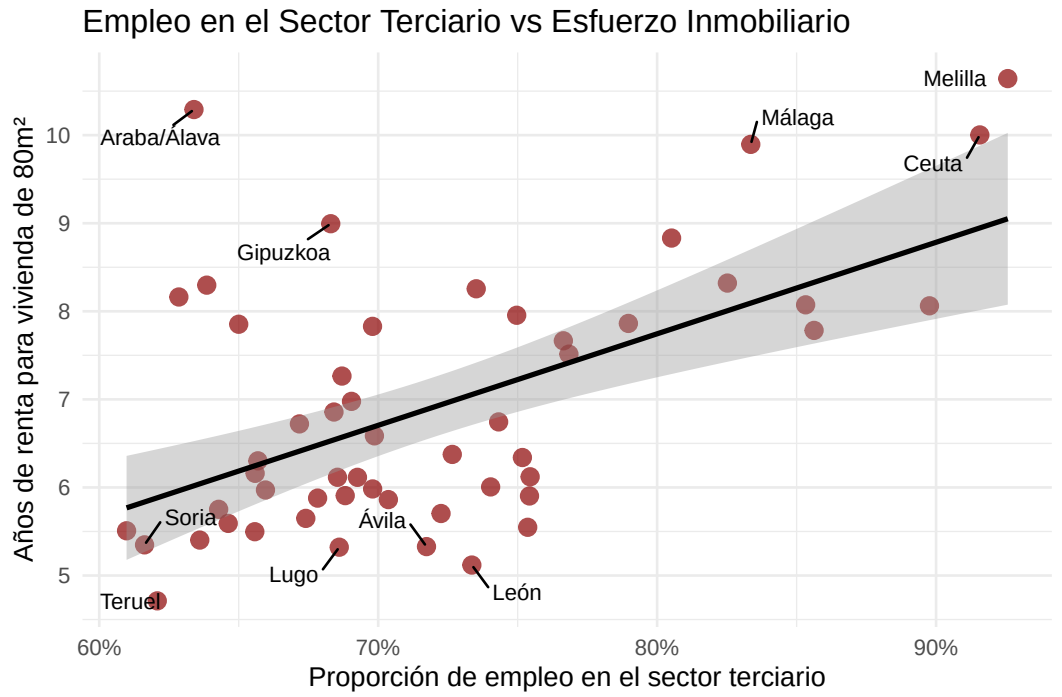
Interpretación: Observamos si las provincias que quedan por debajo de la línea de tendencia (mayor brecha, perciben menos renta de la que producen) coinciden con altos porcentajes del sector terciario. El contraste de hipótesis evalúa la significancia estadística de esta correlación.

Para visualizar geográficamente dónde se concentra esta brecha (dónde se produce más de lo que repercute en el salario de los trabajadores), representamos los datos en un mapa a nivel provincial.



5.2.2. La trampa del sector servicios

Evaluamos cómo la dependencia del sector terciario presiona el coste de la vivienda y cómo afecta a la expulsión de población joven.

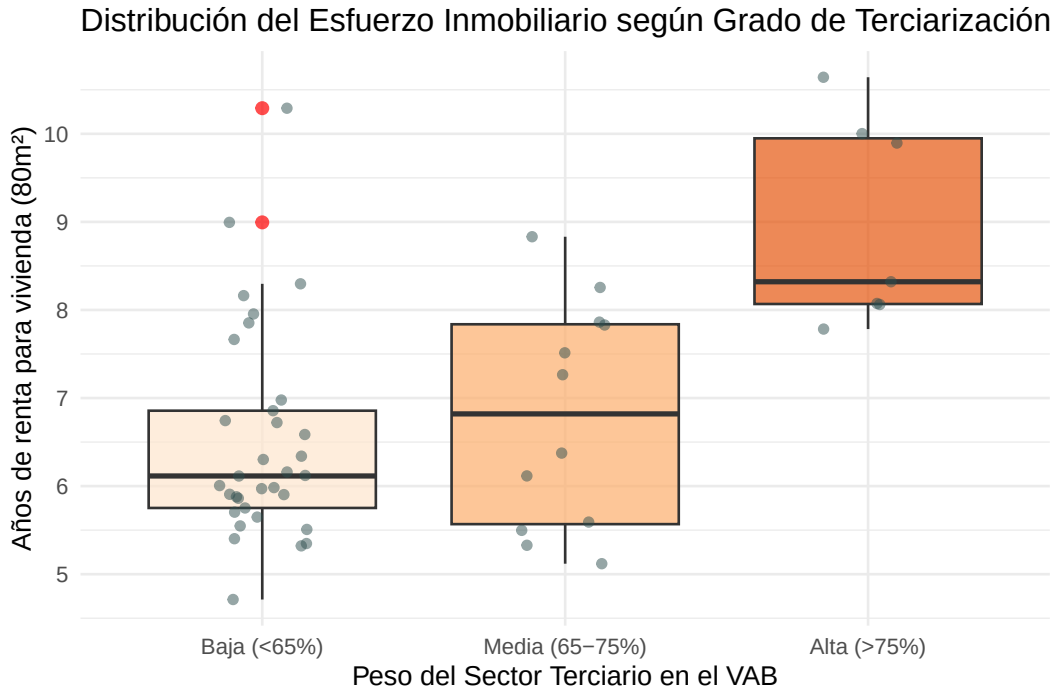


##

```
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$esfuerzo_vivienda
## t = 4.7199, df = 50, p-value = 1.94e-05
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.3326822 0.7191252
## sample estimates:
##       cor
## 0.5551784

##
##  Pearson's product-moment correlation
##
## data:  df_anio$emp_terciario and df_anio$mig_joven_1000
## t = 2.0277, df = 50, p-value = 0.04793
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.002979316 0.510177011
## sample estimates:
##       cor
## 0.2756555
```

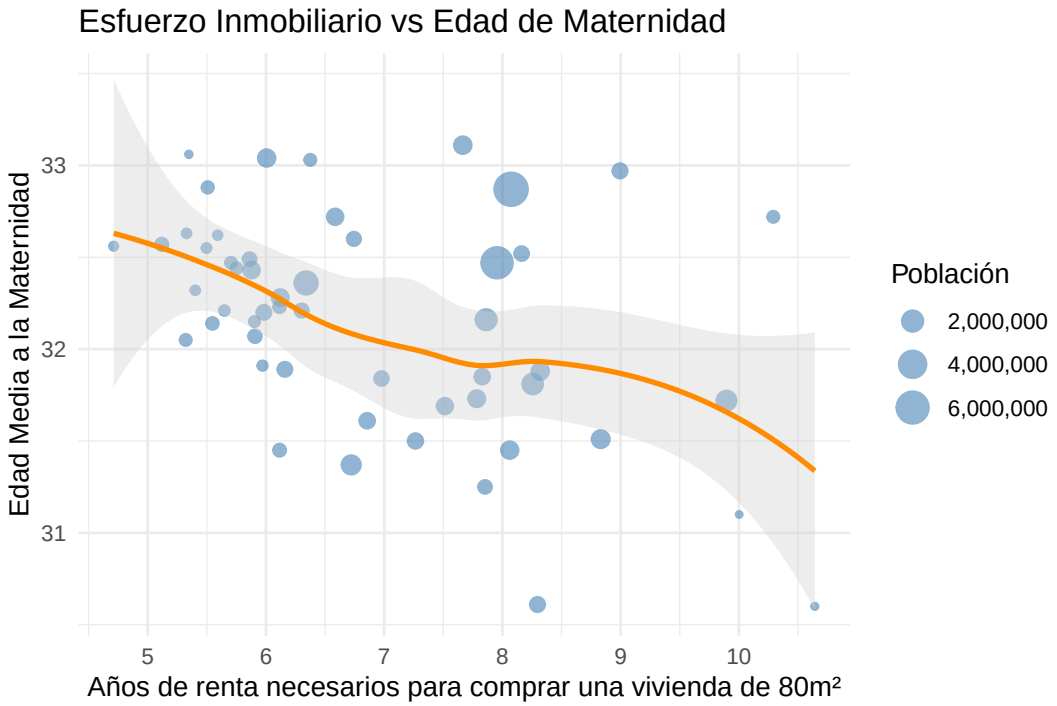
Para contrastar de forma más robusta si el modelo productivo discrimina el acceso a la vivienda, agrupamos las provincias por su sector económico predominante mediante un boxplot.



Interpretación: Este diagrama de cajas nos permite evaluar si las provincias fuertemente terciarizadas tienen una mediana de esfuerzo inmobiliario significativamente superior frente a aquellas sostenidas por el sector primario o secundario, así como detectar provincias atípicas (outliers).

5.2.3. El coste de la maternidad

Buscamos evidenciar si el endurecimiento del mercado inmobiliario (esfuerzo para acceder a una vivienda) retrasa la edad media a la maternidad.

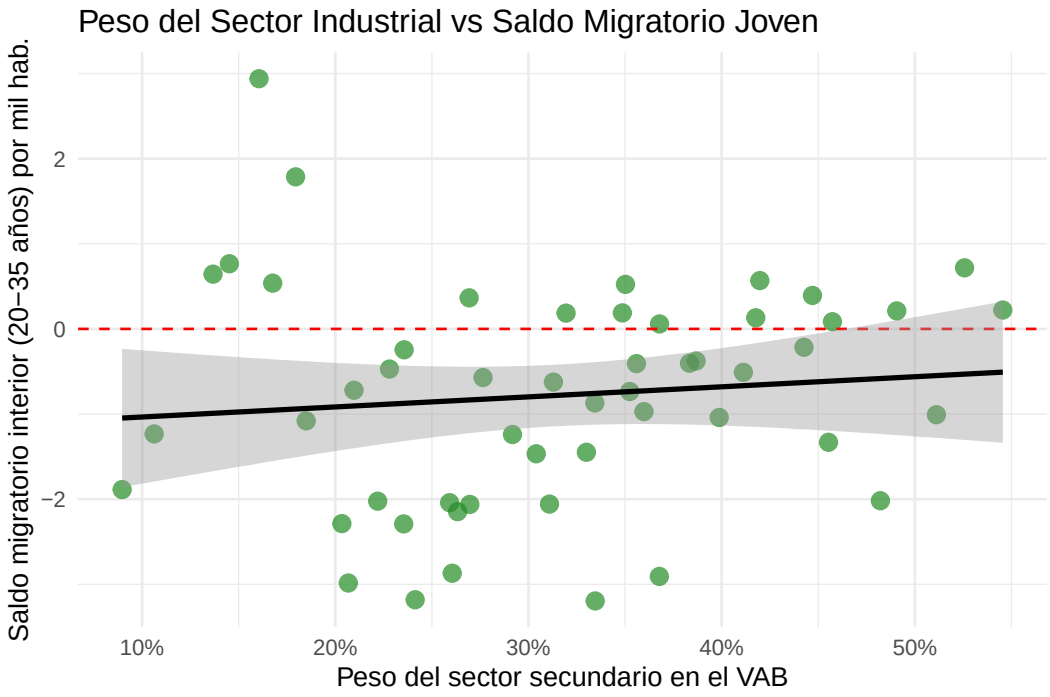



```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$esfuerzo_vivienda and df_anio$Edad_Media_Maternidad
## t = -3.5079, df = 50, p-value = 0.0009649
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.6397237 -0.1951795
## sample estimates:
##       cor
## -0.4444086
```

Interpretación: La curva de ajuste local (LOESS) permite observar si existe un crecimiento no lineal o un umbral crítico de esfuerzo inmobiliario a partir del cual la edad de maternidad se dispara.

5.2.4. El refugio industrial

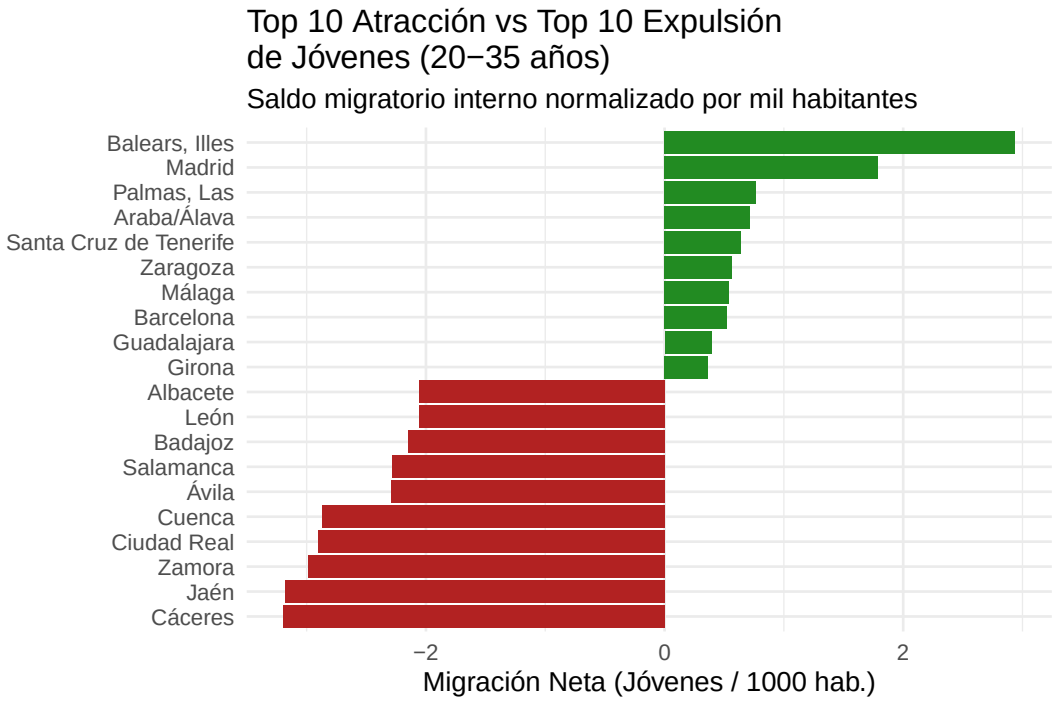
Comprobamos si el tejido industrial funciona como fijador de población joven y si se correlaciona con una densidad demográfica más equilibrada.




```
##
##  Pearson's product-moment correlation
##
## data:  df_anio$peso_secundario and df_anio$mig_joven_1000
## t = 0.73447, df = 50, p-value = 0.4661
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.1745068  0.3658977
## sample estimates:
##       cor
## 0.1033137

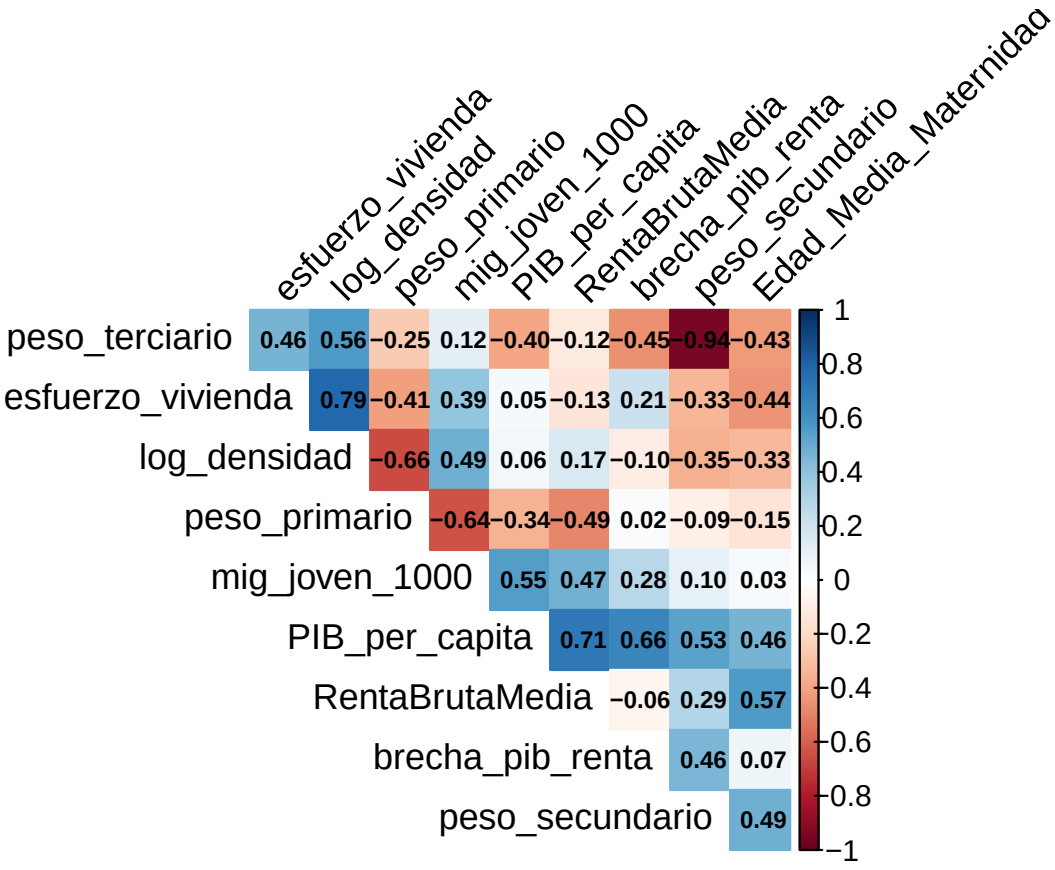
##
##  Pearson's product-moment correlation
##
## data:  df_anio$peso_secundario and df_anio$log_densidad
## t = -2.6481, df = 50, p-value = 0.0108
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.5691432 -0.0860515
## sample estimates:
##       cor
## -0.3507158
```

Para observar con claridad cuáles son las provincias que lideran la atracción y expulsión de jóvenes, generamos un barplot divergente aislando el top 10 y bottom 10.

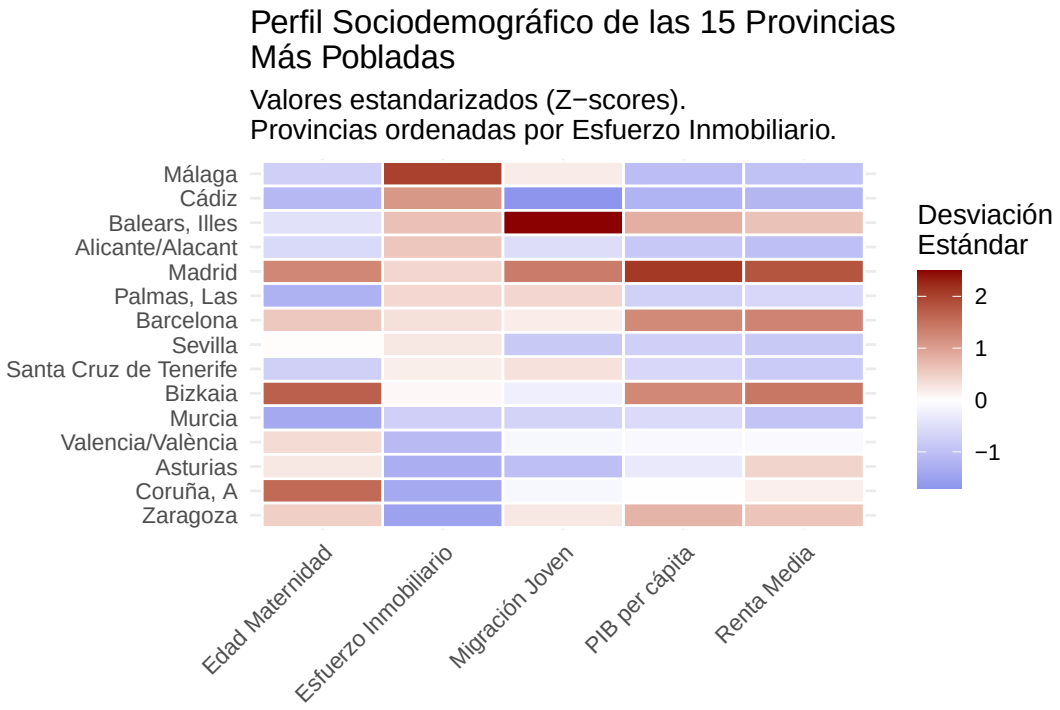


5.2.5. Visión multivariante global

Para resumir las dinámicas conjuntas, comenzamos con una matriz de correlación.



Finalmente, para crear un perfil multidimensional sintético de las tensiones sociodemográficas, generamos un heatmap estandarizado (`geom_tile`) de las 15 provincias más pobladas de España. Esto nos muestra de un vistazo qué retos afronta cada polo demográfico.



Explicación detallada de los gráficos mostrados. "Contar la historia" que revelan los datos. ¿Se confirman las hipótesis iniciales?

6. 6. Conclusiones Finales

A partir del análisis exploratorio realizado, podemos extraer las siguientes conclusiones:

- **Sobre el mercado inmobiliario y demografía:** (Respuesta a las preguntas 1 y 2).
- **Sobre el modelo productivo y migración:** (Respuesta a las preguntas 3 y 4).
- **Aportaciones adicionales:** (Limitaciones del estudio, posibles líneas futuras o reflexiones sobre los datos).

7. Referencias

- Instituto Nacional de Estadística (INE). (2026). *Bases de datos provinciales*. Recuperado de https://www.ine.es/dyngs/DAB/index.htm?cid=1722
- Xie, Y., Allaire, J. J., & Grolemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.