Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Luis Molina Villar[1], Rubén Sánchez Munuera[1], Pablo Gallart Carbonell[1,*]

[1] Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos evalúa la homogeneidad de los indicadores socioeconómicos de España y sus relaciones.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) y del Ministerio de Vivienda y Agenda Urbana (MIVAU) para analizar distintos indicadores socioeconómicos, sus relaciones y su homogeneidad a lo largo de España. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía

1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es realizar un análisis exploratorio de distintos indicadores socioeconómicos a nivel provincial en España, y sus posibles relaciones. En particular, los indicadores estudiados corresponden al modelo productivo de las diferentes provincias, sus mercados laborales e inmobiliarios, y el ciclo vital y demográfico de sus habitantes. A partir del cruce de datos, nos planteamos responder a la siguiente pregunta: ¿Cómo se relacionan la estructura productiva de cada provincia y los principales indicadores socioeconómicos?¿Lo hacen de manera homogénea o heterogénea a nivel nacional?

Para responder a la pregunta hemos considerado que los datos más indicados corresponden a las siguientes variables, organizadas en cuatro dimensiones:

1. **Dimensión de Renta y Riqueza:**
   - `PIB per cápita`: Producto Interior Bruto provincial por habitante (€/hab). Este indicador mide el valor monetario de todos los bienes y servicios finales producidos en un periodo en una región.
   - `Renta bruta media`: Renta bruta media por persona (€/hab). El concepto de renta bruta corresponde al conjunto total de ingresos que percibe una persona durante un periodo determinado, antes de aplicar ningún tipo de impuesto.
2. **Dimensión del Mercado Inmobiliario:**
   - `Precio del metro cuadrado`: Valor medio del metro cuadrado de las operaciones de compra/venta de vivienda (€/m²).
3. **Dimensión Demográfica y Ciclo Vital:**
   - `Edad media de maternidad`: Edad media de las madres al nacimiento de un hijo/a, considerando todos los órdenes de nacimiento (primer hijo/a, segundo hijo/a,...) (años).
   - `Migracion Interior`: Saldo migratorio neto interprovincial (personas que pasan de vivir de una provincia a otra) en el rango de edad de 19 a 35 años (número neto de personas).
   - `Habitantes`: Población provincial total residente (personas).

Citation: Molina Villar, L.; Sánchez Munuera, R.; Gallart Carbonell, P. Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Journal Not Specified* **2026**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

4. **Dimensión de Estructura Productiva:**
    - `Personas ocupadas por sector (Primario, Secundario, Terciario)`: Número de personas ocupadas en cada gran sector económico.
    - `VAB por sector (Primario, Secundario, Terciario)`: El valor bruto añadido (VAB) mide el valor económico total que genera una empresa, sector, región o país durante un periodo de tiempo determinado.

Para la realización del informe se han recopilado todos los datos existentes de dichos registros en el INE y, para el precio de la vivienda, en el MIVAU (entre todas las variables hay registros desde 1975 a 2026). En particular, solamente hay registros de todas las variables en el periodo 2015-2021, y por cuestiones de espacio, en el informe solamente se muestra un análisis exploratorio de los datos correspondientes al año 2019, elegido ya que siendo uno de los años con más datos disponibles, es justamente previo a la pandemia de COVID-19, por lo que este análisis puede ser usado para estudiar los efectos de la pandemia en los factores estudiados.

2. Importación y Acondicionamiento de Datos

El primer paso para el análisis es cargar los conjuntos de datos obtenidos del INE y del MIVAU. Los ficheros originales se encuentran almacenados en la carpeta local `data/raw`.

La fuente de datos no proporciona los datos estrictamente adecuados para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas). Por lo tanto, el primer paso es acondicionar los datos obtenidos para llegar a un conjunto de datos que contenga los datos que nos interesan. Uno de los factores principales a tener en cuenta es que los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Los datos han sido importados a `R` usando una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas, usando la función `locale`.

```
leer_archivo_ine <- function(fichero, separador, decimal = ",", grouping = ".") {
  readr::read_delim(
    file = fichero,
    delim = separador,
    locale = locale(decimal_mark=decimal, grouping_mark= grouping),
    na = c("", "NA", "null",".."),
    name_repair = "minimal",
    show_col_types = FALSE,
    progress = FALSE
  )
}
```

El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera. Los principales pasos que han sido necesarios para el acondicionamiento de los datos ha requerido han sido:

- Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- En el conjunto de datos que queremos estudiar cada instancia es una provincia en cierto año. Para unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros de los datos originales, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`).

```r
# Función para generar el ID único
crear_id_provincia_anio <- function(df, col_anyo, col_prov) {
  df %>% mutate(
    id = paste0(
      as.numeric({{ col_anyo }}),
      "_",
      str_pad(as.character({{ col_prov }}), width = 2, side = "left", pad = "0")
    )
  )
}
```

- El INE ofrece algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como estas variables escapan del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, se han agregado los datos, usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).
- En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino.

```r
# En las comunidades uniprovinciales, el fichero incluye filas regionales
# (CPRO vacio) cuyo valor coincide con el de la provincia. Las incorporamos
# usando el codigo de comunidad autonoma antes de eliminar CODAUTO.
codigos_uniprov_coste <- c(
  "03" = "33", # Asturias
  "04" = "07", # Illes Balears
  "06" = "39", # Cantabria
  "13" = "28", # Madrid
  "14" = "30", # Murcia
  "15" = "31", # Navarra
  "17" = "26", # La Rioja
  "18" = "51", # Ceuta
  "19" = "52"  # Melilla
)

coste_vivienda <- coste_vivienda %>%
  mutate(
    codigo_ccaa = str_pad(as.character(.data[["CODAUTO"]]), width = 2, side = "lef
    codigo_ccaa = case_when(
      str_detect(str_to_lower(Comunidad_Autonoma), "astur") ~ "03",
      str_detect(str_to_lower(Comunidad_Autonoma), "balear") ~ "04",
      str_detect(str_to_lower(Comunidad_Autonoma), "cantabr") ~ "06",
      str_detect(str_to_lower(Comunidad_Autonoma), "madrid") ~ "13",
      str_detect(str_to_lower(Comunidad_Autonoma), "murcia") ~ "14",
      str_detect(str_to_lower(Comunidad_Autonoma), "navarr") ~ "15",
      str_detect(str_to_lower(Comunidad_Autonoma), "rioja") ~ "17",
      str_detect(str_to_lower(Comunidad_Autonoma), "ceuta") ~ "18",
      str_detect(str_to_lower(Comunidad_Autonoma), "melilla") ~ "19",
      TRUE ~ codigo_ccaa
    ),
    CPRO = if_else(
      is.na(CPRO),
```

```
      unname(codigos_uniprov_coste[codigo_ccaa]),
      as.character(CPRO)
    )
  ) %>%
  select(-codigo_ccaa)
```

- Para extraer únicamente el valor de las provincias (ni el total nacional ni niveles autonómicos), filtramos usando la lista oficial de provincias del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. Análisis Exploratorio de Datos (EDA)

3.1. Análisis de Datos Perdidos

Ahora que tenemos un conjunto de datos con todas las variables de interés, y las instancias adecuadamente identificadas, podemos proceder al análisis exploratorio propiamente dicho. Para empezar observamos en qué variables hay valores faltantes.

Table 1. Valores perdidos por variable

	Valores Perdidos
Renta_bruta_media	12
Personas_Ocupadas_Primario	7

Por suerte, hay pocos valores perdidos, por lo que podemos visualizar sus instancias correspondientes antes de decidir qué hacer con ellos.

Table 2. Instancias con valores faltantes

Provincia	Periodo	Renta_bruta_media	Personas_Ocupadas_Primario
Araba/Álava	2015	NaN	2.350
Araba/Álava	2016	NaN	3.475
Araba/Álava	2017	NaN	3.850
Araba/Álava	2018	NaN	3.225
Araba/Álava	2019	NaN	2.825
Ceuta	2016	11988	NaN
Ceuta	2017	12094	NaN
Ceuta	2020	13718	NaN
Ceuta	2021	14499	NaN
Gipuzkoa	2015	NaN	2.700
Melilla	2015	11151	NaN
Melilla	2016	11377	NaN
Melilla	2019	12676	NaN
Navarra	2015	NaN	9.525
Navarra	2016	NaN	9.575
Navarra	2017	NaN	11.025
Navarra	2018	NaN	11.800
Navarra	2019	NaN	10.225
Navarra	2020	NaN	9.425

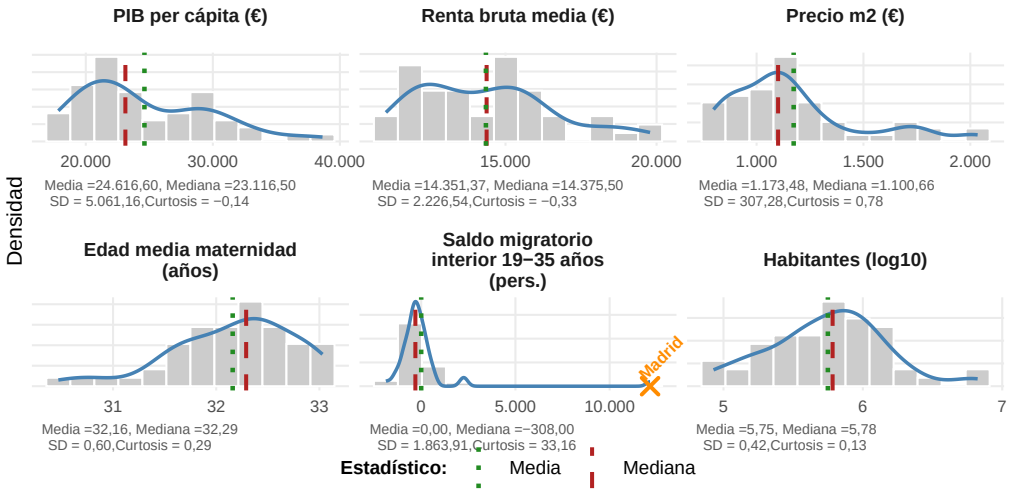
Observamos que los valores faltantes afectan solamente a 5 provincias, además, cada instancia tiene como mucho un valor faltante, las variables afectadas son series temporales de valores numéricos (valores anuales de 2015 a 2021), y en todos los casos tenemos al menos un registro de toda la serie, por lo que la decisión sobre los valores faltantes es imputarlos siguiendo la siguiente norma:

Se imputan los valores faltantes con la media del primer valor anterior no faltante, y el primer valor posterior no faltante. En caso de no haber valores anteriores o posteriores no faltantes, se imputará el dato usando el primer dato posterior o respectivamente anterior no faltante.

3.2. *Análisis Univariante*

En esta sección procedemos a examinar la distribución individual de las variables recopiladas. El objetivo central de este análisis univariante es caracterizar el comportamiento estadístico de cada magnitud —evaluando su tendencia central, grado de dispersión, presencia de asimetrías y valores atípicos, antes de abordar las relaciones multivariantes. Para las variables laborales (VAB y ocupación por sectores), no usaremos los datos originales (valores totales) si no el porcentaje sobre el total nacional.

Visualizamos los histogramas de los datos:



Las marcas naranjas indican valores atípicos (Alejados de la media más de 3 desviaciones típicas)

En los histogramas observamos la media y la mediana de cada variable, así como los valores atípicos según la regla de la desviación típica. La edad media de maternidad, la renta bruta media y el logaritmo de la población son las variables más próximas a la simetría (media y mediana casi coinciden), mientras que el PIB per cápita y el precio del metro cuadrado presentan asimetría positiva, con la media por encima de la mediana por la cola de provincias de renta y precios altos. El caso más extremo es el del saldo migratorio: su media es nula (como cabe esperar al tratarse de saldos netos entre provincias) pero su mediana es negativa (-308 personas), es decir, la mayoría de provincias pierde población joven y Madrid, único valor atípico según este criterio, concentra las ganancias, lo que explica en buena medida una curtosis de 33,16.

Para complementar el análisis, representamos también diagramas de caja y detectamos los valores atípicos usando la regla del rango intercuartílico.

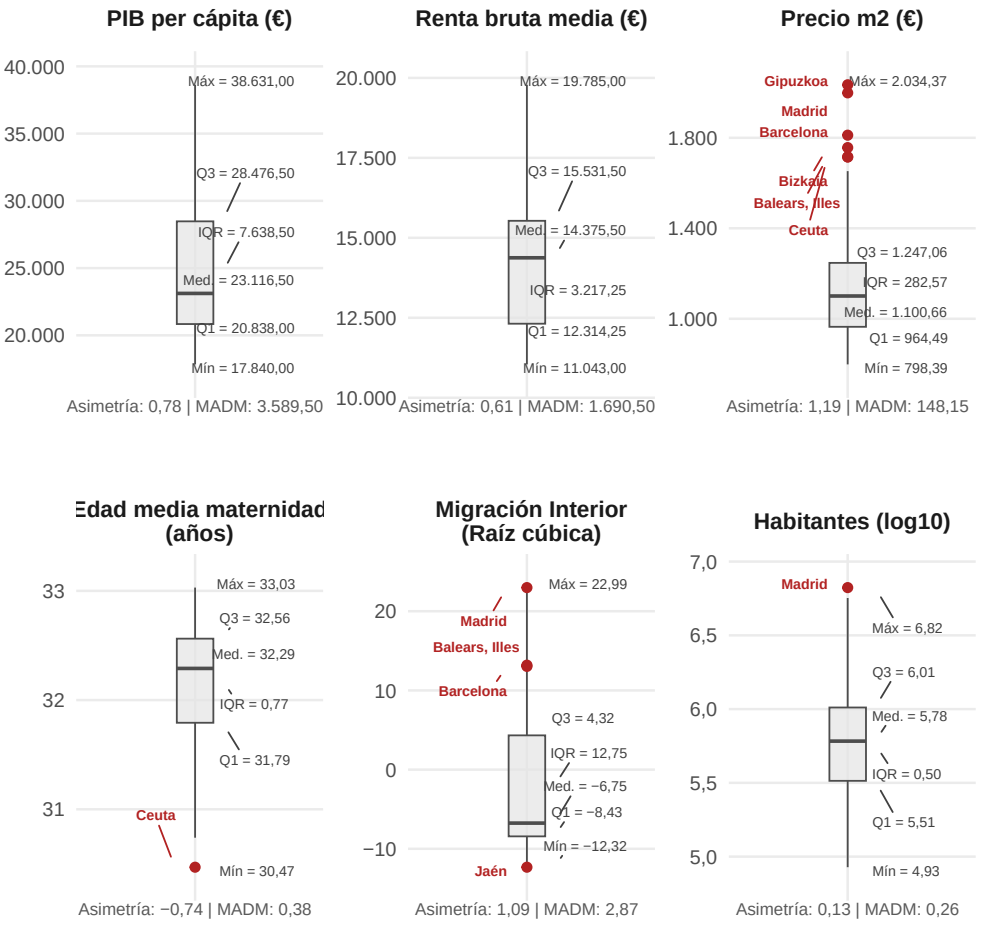
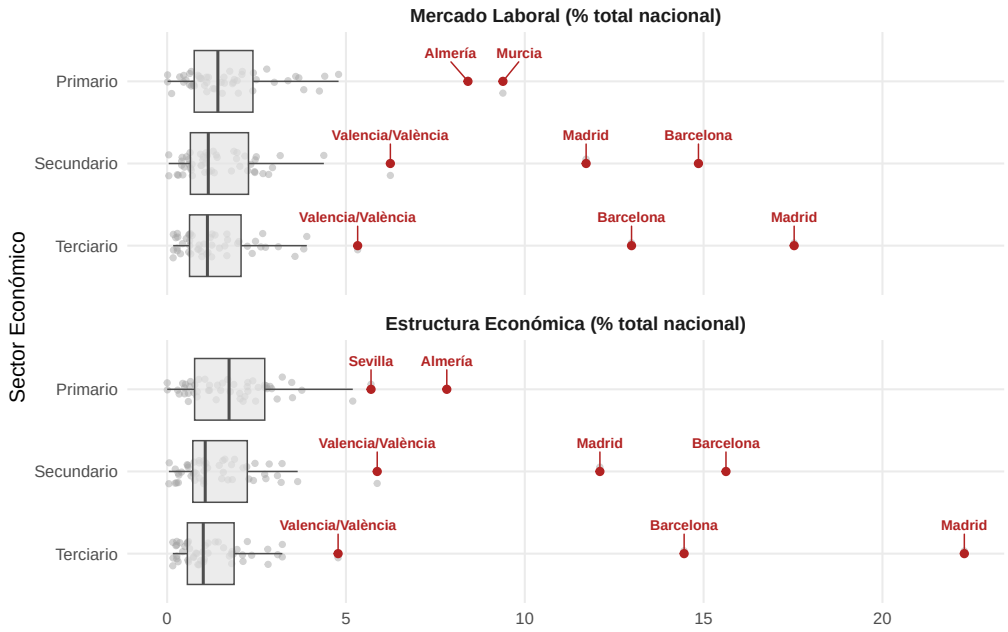


Figure 1. Distribución de las variables socioeconómicas.

Con el criterio del rango intercuartílico aparecen más valores atípicos que con la regla de las tres desviaciones, al ser un criterio más sensible a las colas. El precio del metro cuadrado destaca por varios atípicos por encima del bigote superior (entre ellos Gipuzkoa, Madrid, Barcelona, Bizkaia e Illes Balears), lo que refleja la tensión del mercado inmobiliario en las provincias más pobladas y en del País Vasco. En la migración interior destacan Madrid, Illes Balears y Barcelona como receptoras y Jaén como la provincia con mayor pérdida, mientras que en la edad de maternidad el único atípico es Ceuta, con la edad más baja (30,47 años).

Para visualizar la distribución de las variables laborales, hacemos uso de diagramas de cajas para comparar por sector cada una de las variables.



Los puntos rojos indican valores atípicos evaluados mediante la regla IQR (±1.5) calculada por sector.

Podemos observar de nuevo datos muy heterogéneos y valores extremos muy altos. En los sectores secundario y terciario los atípicos son siempre las mismas provincias de gran tamaño (Madrid, Barcelona y Valencia/València), que concentran una parte desproporcionada del empleo y del valor añadido nacional (Madrid supera el 20 % del VAB terciario), mientras que en el sector primario destacan Almería y Murcia en empleo, y Sevilla y Almería en VAB, provincias de agricultura intensiva. Al expresar estas variables como porcentaje del total nacional, su magnitud depende en gran medida del tamaño de la provincia, algo que condiciona la lectura de las correlaciones posteriores.

3.3. Análisis Bivariante y Multivariante

Una vez constatada la heteroregeidad de los datos en el análisis univariante, en esta sección buscamos cruzar las variables para dar respuesta a las preguntas planteadas en la introducción. Para sintetizar las múltiples interacciones entre distintas variables, hacemos uso de la matriz de correlación. Como hemos visto en el análisis univariante, las distribuciones presentan asimetrías, colas pesadas, y en varios casos outliers. Para que esto no afecte de manera significativa a las correlaciones, en algunos casos usaremos medidas derivadas de los datos.

1. La densidad de población en lugar del número de habitantes,es decir

$$Densidad_Pobl. = \frac{Num_Habitantes}{Superficie_Provincia}.$$

2. El esfuerzo de compra la vivienda, caclulada como el número de años de renta bruta media que se requieren para alcanzar el valor de una casa de $90m^2$.

$$Esf_Vivienda = \frac{90 * Precio\ m^2}{Renta\ Bruta\ Media}.$$

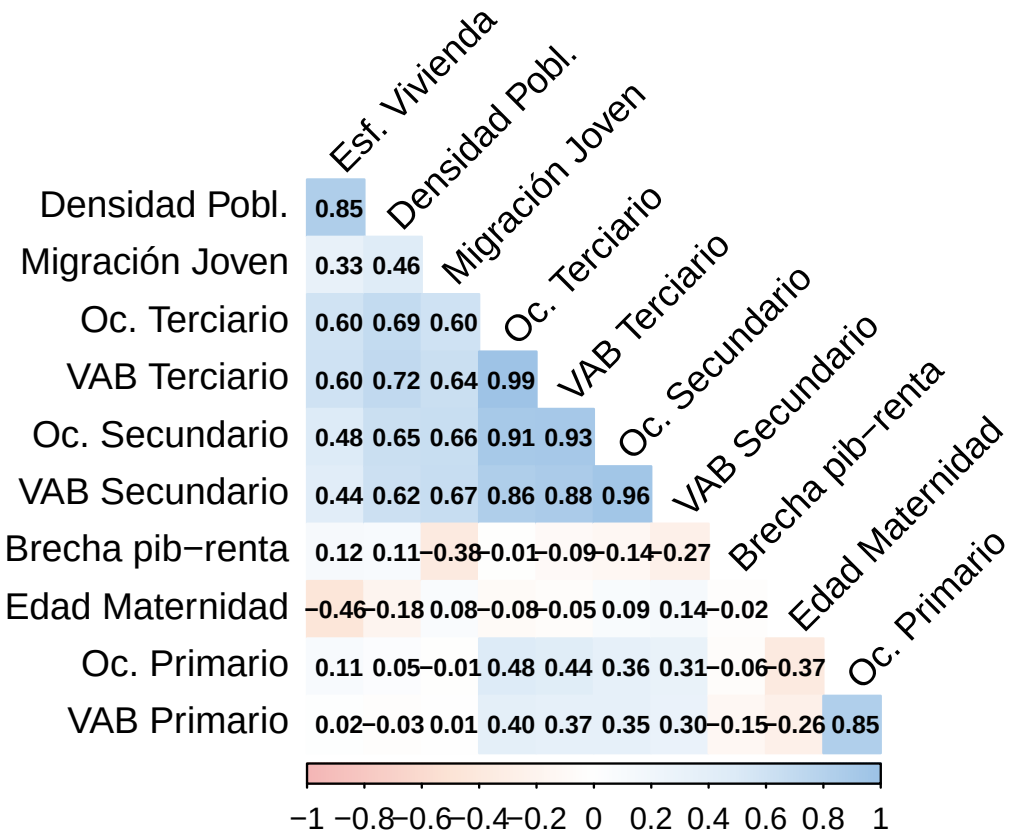
3. La brecha renta/PIB. Es decir, la magnitud de la renta bruta media con respecto al PIB per cápita.

$$Brecha\ Renta/PIB = \frac{Renta\ Bruta\ Media}{PIB\ per\ capita}.$$

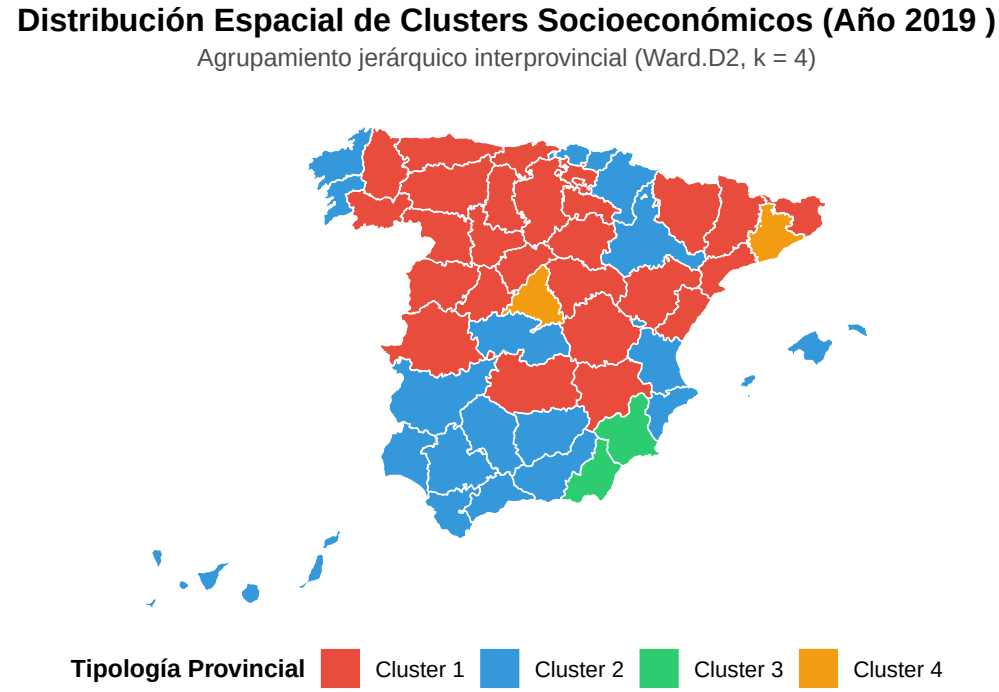
4. La migración joven por cada 1.000 habitantes:

$$Mig_Joven = \frac{Migracion_Interior}{Num_Habitantes} \cdot 1000.$$

Usamos la correlación de Spearman, ya que al aplicar estas transformaciones no lineales, la correlación de Pearson se distorsiona.



Observamos valores de correlaciones muy variados, algunos esperados como la correlación entre el porcentaje de ocupación el VAB en cada uno de los sectores. Hay otros que llaman la atención, como la correlación entre la densidad de población y el esfuerzo de acceso a la vivienda. Sin embargo, como hemos visto en el análisis univariante de los datos, tenemos datos muy heterogéneos con valores extremos, y distribuciones asimétricas. Para responder a la pregunta sobre si las relaciones entre los distintos indicadores ocurren de manera homogénea, realizamos un cluster de las provincias para separarlas en 4 grupos (clustering jerárquico) con características socioeconómicas similares de manera que se minimize la varianza de los datos en cada uno, para observar si cambian las dinámicas entre estas, o por el contratio no se alteran a pesar de la heterogeneidad de los datos. En el siguiente mapa podemos observar un mapa con las provincias divididas en los grupos correspondientes.



Por el mapa nos podemos hacer una idea de las características por las que se ha formado cada grupo. Calculamos los valores promedios de cada variable por grupo para observar las características de cada grupo.

Table 3. Perfil socioeconómico por Cluster

Cluster	Num_Provincias	brecha_pib_renta	esfuerzo_vivienda	Edad_Media_Maternidad	mig_joven_1000	Densidad
Cluster 1	26	0.58	6.32	32.34	-1.02	45.95
Cluster 2	20	0.60	8.07	32.11	-0.36	182.92
Cluster 3	2	0.53	8.10	31.16	-0.59	106.89
Cluster 4	2	0.55	9.08	32.75	1.11	782.32

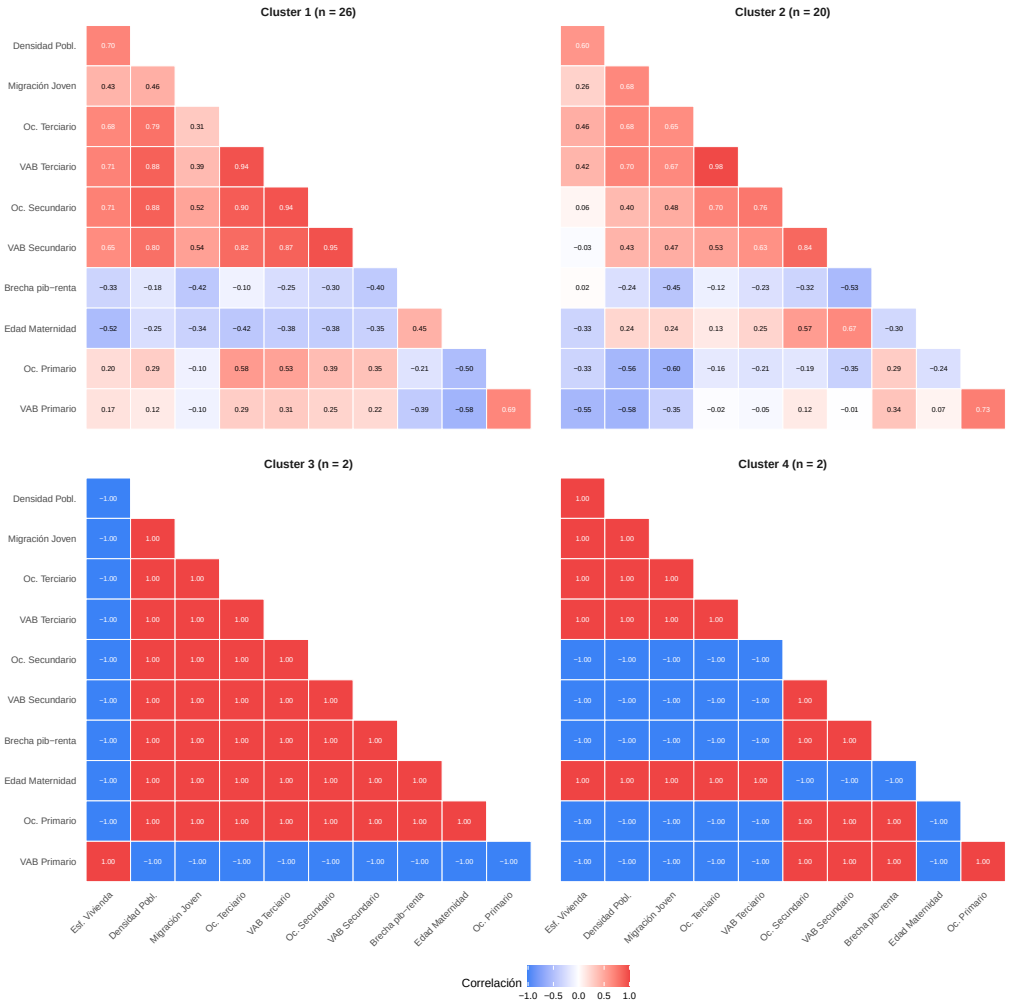
Table 4. Perfil de estructura productiva por Cluster

Cluster	Num_Provincias	pct_Ocupados_Primario	pct_Ocupados_Secundario	pct_Ocupados_Terciario	pct_VAB_Primario	pct_VAB_Secundario	pct_VAB_Terciario
Cluster 1	26	1.19	0.95	0.74	1.37	0.99	0.71
Cluster 2	20	2.48	2.24	2.29	2.40	2.12	2.04
Cluster 3	2	8.90	1.92	2.00	6.51	2.06	1.75
Cluster 4	2	0.85	13.29	15.26	1.68	13.86	18.37

Podemos decir, que tenemos 4 clusters con perfiles diferentes, en los que destacan:

1. El primer cluster está formado por provincias con baja densidad, que no destacan en ningún sector en particular, que no aportan de manera significativa al total nacional, y de las que muchos jóvenes se van.
2. El segundo cluster está formado por provincias que también pierden población joven, pero tienen bastante más densidad. Tampoco destacan en ningún sector, pero aportan más al total nacional que las del primer cluster.
3. El tercer cluster está formado por provincias que también pierden población joven, con una densidad intermedia, y especialmente dedicadas al sector primario.
4. El cuarto cluster lo forman las provincias con áreas urbanas muy densas que reciben grandes cantidades de jóvenes de las otras partes del país, y concentran una parte importante de la actividad y el valor añadido de los sectores secundario y terciario.

Por último, calculamos las correlaciones por cluster, para determinar si las relaciones son heterogéneas o no.



Estas nuevas matrices de correlación poco tienen que ver con la original. Observamos valores de correlación bastante altos que antes no aparecían. En los grupos 3 y 4 al estar formados por dos elementos la correlación entre dos de sus variables cualesquiera será 1 o -1 siempre, por lo que cualquier interpretación que se haga sobre estos valores debe cogerse con pinzas. Aún así, haciendo uso de las matrices de correlación de los dos primeros clusters podemos dar respuesta a la pregunta, y afirmar que las relaciones entre los distintos indicadores socioeconómicos no son homogéneas a lo largo del país. Por ejemplo, podemos descatar que en el primer cluster la brecha renta/PIB contribuye positivamente a la edad de maternidad, mientras que en el segundo la relación es inversa.

4. Conclusiones Finales

El análisis provincial de España (2019) revela que la relación entre estructura productiva e indicadores socioeconómicos es heterogénea. La matriz global oculta realidades territoriales distintas que exigen dividir el país en grupos en los que las dinámicas socioeconómicas son similares, para poder responder preguntas más profundas sobre estas.

Destacan tres hallazgos clave:

1. Peso de los valores atípicos: Una minoría de provincias (Madrid, Barcelona, Illes Balears, País Vasco) concentra los máximos demográficos y económicos, distorsionando las medias nacionales y forzando la creación de clústeres exclusivos (3 y 4) para aislar estos extremos.

2. Vivienda vs. Migración: El esfuerzo inmobiliario crece drásticamente con la densidad poblacional (correlación 0,85). Pese a esta barrera, solo los grandes núcleos (Clúster 4: Madrid y Barcelona) logran atraer migración joven.

3. Estabilidad demográfica: La edad media de maternidad es la variable más homogénea del país y la menos condicionada por la estructura productiva.

Estas asociaciones no causales reflejan en gran medida el tamaño absoluto de las provincias. Para futuros estudios, se sugiere medir la estructura productiva a nivel interno (para evitar sesgos de tamaño) y ampliar el análisis al periodo 2015-2021.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.