MDPI

Article

Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España

Luis Molina Villar[1], Rubén Sánchez Munuera[1], Pablo Gallart Carbonell[1]

[1] Universitat de València (UV), España.;
* Correspondence:

Simple Summary: Este proyecto de Análisis Exploratorio de Datos evalúa la hmogeneidad de los indicadores socioeconómicos de España y sus relaciones.

Abstract: El presente trabajo desarrolla un Análisis Exploratorio de Datos (AED) cruzando dimensiones económicas, inmobiliarias y sociodemográficas a nivel provincial en España. Se emplean datos del Instituto Nacional de Estadística (INE) para analizar distintos indicadores socioeconómicos, sus relaciones y su homogeneidad a lo largo de España. El análisis cubre la importación y limpieza de datos, el tratamiento de valores perdidos, y un análisis univariante y bivariante para dar respuesta a las preguntas planteadas.

Keywords: Análisis Exploratorio de Datos; Demografía

1. Introducción y Planteamiento de Preguntas

El objetivo de este proyecto es realizar un análisis exploratorio de distintos indicadores socioeconómicos a nivel provincial en España, y sus posibles relaciones. En particular, los indicadores estudiados corresponden a el modelo productivo de las diferentes provincias, sus mercados laborales e inmobiliarios, y el ciclo vital y demográfico de sus habitantes. A partir del cruce de datos, nos planteamos responder a la siguiente pregunta: ¿Cómo se relacionan la estructura productiva de cada provincia y los principales indicadores socioeconómicos?¿Lo hacen de manera homogénea o heterogénea a nivel nacional?

Para responder a la pregunta hemos considerado que los datos más indicados corresponden a las siguientes variables, organizadas en cuatro dimensiones:

1. **Dimensión de Renta y Riqueza:**
   - `PIB per cápita`: Producto Interior Bruto provincial por habitante (€/hab). Este indicador mide el valor monetario de todos los bienes y servicios finales producidos en un periodo en una región.
   - `Renta bruta media`: Renta bruta media por persona (€/hab). El concepto de renta bruta corresponde, el conjunto total de ingresos que percibe una persona durante un periodo determinado, antes de aplicar ningún tipo de impuesto.
2. **Dimensión del Mercado Inmobiliario:**
   - `Precio del metro cuadrado`: Valor medio del metro cuadrado de la vivienda (€/m²).
3. **Dimensión Demográfica y Ciclo Vital:**
   - `Edad media de maternidad`: Edad media de las madres al nacimiento de un hijo/a, considerando todos los órdenes de nacimiento (primer hijo/a, segundo hijo/a,...) (años).

Citation: Estructura Productiva, Presión Inmobiliaria y su Impacto en el Ciclo Vital y Migratorio en España. *Journal Not Specified* **2023**, *1*, 0. https://doi.org/

Received:
Revised:
Accepted:
Published:

Copyright: © 2026 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (https://creativecommons.org/licenses/by/4.0/).

- `Migracion Interior`: Saldo migratorio neto interprovincial (personas que pasan de vivir de una provincia a otra) en el rango de edad de 19 a 35 años (número neto de personas).
- `Habitantes`: Población provincial total residente (personas).

4. **Dimensión de Estructura Productiva:**

- `Personas ocupadas por sector (Primario, Secundario, Terciario)`: Número de personas ocupadas en cada gran sector económico.
- `VAB por sector (Primario, Secundario, Terciario)`: El valor bruto añadido (VAB) mide el valor económico total que genera una empresa, sector, región o país durante un periodo de tiempo determinado.

Para la realización del informe se han recopilado todos los datos existentes de dichos registros en el INE (entre todas las variables hay registros desde 1975 a 2026). En particular, solamente hay registros de todas las variables en el periodo 2015-2021, y por cuestiones de espacio, en el informe solamente se muestra un análisis exploratorio de los datos correspondientes al año 2019, elegido ya que siendo uno de los años con más datos disponibles, es justamente previo a la pandemia de COVID-19, por lo que este análisis puede ser usado para estudiar los efectos de la pandemia en los factores estudiados.

2. Importación y Acondicionamiento de Datos

El primer paso para el análisis es cargar los conjuntos de datos obtenidos del INE. Los ficheros originales se encuentran almacenados en la carpeta local `data/raw`.

La fuente de datos no proporciona los datos estrictamente adecuados para el análisis que queremos realizar (buscamos un análisis anual a nivel provincial de ciertas variables socioeconómicas). Por lo tanto, el primer paso es acondicionar los datos obtenidos para llegar a un conjunto de datos que contenga los datos que nos interesan. Uno de los factores principales a tener en cuenta es que los datos han sido tomados y guardados en español, por lo que hemos de tener cuidado con el indicador de millares y decimales en los datos numéricos. Los datos han sido importados a `R` usando una función basada en `read_delim` de `readr` para tratar adecuadamente las variables numéricas, usando la función `locale`.

El proceso de preparación de los datos se hace siguiendo la filosofía tidy. Al ser un proceso mecánico y repetitivo, no se explicitarán todos y cada uno de los pasos hechos en el informe, aunque se pueden consultar en el script que lo genera. Los principales pasos que han sido necesarios para el acondicionamiento de los datos ha requerido han sido:

- Acondicionamiento de nombres de variables para evitar errores de compilación, como `Año` que pasa a ser `Periodo` o `Comunidad Autónoma` a `Comunidad_Autonoma`.
- Es una práctica común en el INE incluir la variable `Provincias` que tiene la forma `xx Nombre_Provincia`, siendo `XX` el código de provincia oficial (asignados por orden alfabético, del 01 al 50, siendo Ceuta el 51 y Melilla el 52). Nosotros hemos separado esa variable en código provincial `cod_prov` y nombre provincial (`Provincia`).
- En el conjunto de datos que queremos estudiar cada instancia es una provincia en cierto año. Para unir instancias de distintas tablas, hemos asignado un identificador único (en el sentido de que cada provincia tiene uno por año) a todos los registros de los datos originales, usando el formato `yyyy_xx`, año (`yyyy`) y código provincial (`xx`).
- El INE ofrece algunos datasets con los valores disgregados por variables como sexo,nacionalidad,edad, o valores trimestrales en lugar de anuales. Como estas

variables escapan del objetivo del análisis, en los casos en los que también se ofrecía el valor total, se ha seleccionado este, y en los que no, usando el identificador único, se han agregado los datos, usando la medida adecuada (media para obtener el promedio anual de valores trimestrales, y suma para obtener el total por sexos, edades o nacionalidades).

- En el INE los datos aparecen en un dataset construido específicamente para ellos, por lo que la variable que nos interesa suele llevar el nombre `Valor` o `Total`. Lo cambiamos para identificar correctamente el nombre de la variable de interés en nuestro dataset.
- A veces el INE entrega los datos a nivel provincial y regional en el mismo archivo, pero para las regiones uniprovinciales da el valor de la región, por lo que en estos casos se transforma adecuadamente el código y nombre de la región al de la provincia correspondiente para extraer correctamente los datos, y no perder valores por el camino.
- Para extraer únicamente el valor de las provincias (ni el total nacional ni niveles autonómicos), filtramos usando la lista oficial de provincias del INE.

Una vez tenemos los datos tratados, los juntamos haciendo uso del identificador único. Para evitar que se generen muchos valores perdidos, para la unión solamente tomaremos las instancias comunes a todos.

3. Análisis Exploratorio de Datos (EDA)

3.1. Análisis de Datos Perdidos

Ahora que tenemos un conjunto de datos con todas las variables de interés, y las instancias adecuadamente identificadas, podemos proceder al análisis exploratorio propiamente dicho. Para empezar observamos en qué variables hay valores faltantes.

Table 1. Valores perdidos por variable

	Valores Perdidos
Renta_bruta_media	12
Personas_Ocupadas_Primario	7

Por suerte, hay pocos valores perdidos, por lo que podemos visualizar sus instancias correspondientes antes de decidir qué hacer con ellos.

Table 2. Instancias con valores faltantes

Provincia	Periodo	Renta_bruta_media	Personas_Ocupadas_Primario
Araba/Álava	2015	NaN	2.350
Araba/Álava	2016	NaN	3.475
Araba/Álava	2017	NaN	3.850
Araba/Álava	2018	NaN	3.225
Araba/Álava	2019	NaN	2.825
Ceuta	2016	11988	NaN
Ceuta	2017	12094	NaN
Ceuta	2020	13718	NaN
Ceuta	2021	14499	NaN
Gipuzkoa	2015	NaN	2.700
Melilla	2015	11151	NaN
Melilla	2016	11377	NaN
Melilla	2019	12676	NaN

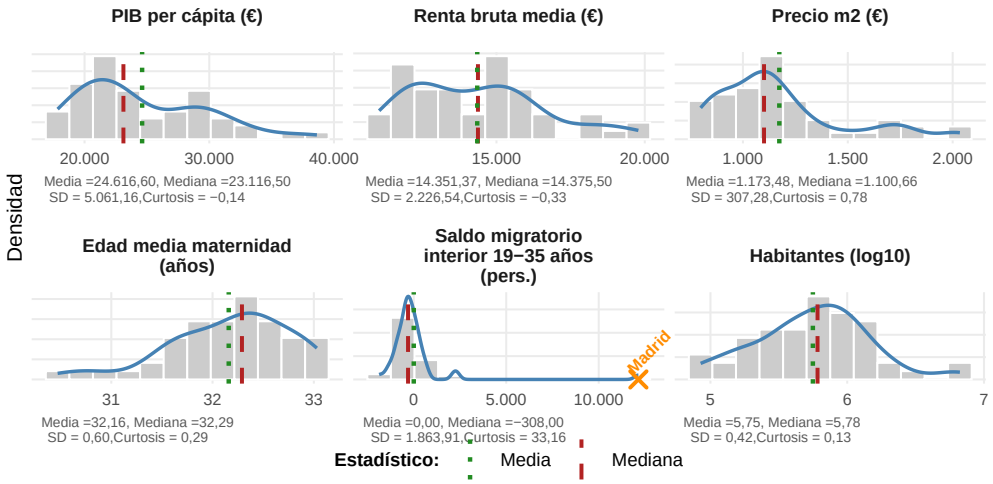
Provincia	Periodo	Renta_bruta_media	Personas_Ocupadas_Primario
Navarra	2015	NaN	9.525
Navarra	2016	NaN	9.575
Navarra	2017	NaN	11.025
Navarra	2018	NaN	11.800
Navarra	2019	NaN	10.225
Navarra	2020	NaN	9.425

Observamos que los valores faltantes afectan solamente a 5 provincias, además, cada instancia tiene como mucho un valor faltante, las variables afectadas son series temporales de valores numéricos (valores anuales de 2015 a 2021), y en todos los casos tenemos al menos un registro de toda la serie, por lo que la decisión sobre los valores faltantes es imputarlos siguiendo la siguiente norma. Se imputan los valores faltantes con la media del primer valor anterior no faltante, y el primer valor posterior no faltante. En caso de no haber valores anteriores o posteriores faltantes, se imputará el dato usando el primer dato posterior o respectivamente anterior no faltante.

3.2. Análisis Univariante

En esta sección procedemos a examinar la distribución individual de las variables recopiladas. El objetivo central de este análisis univariante es caracterizar el comportamiento estadístico de cada magnitud —evaluando su tendencia central, grado de dispersión, presencia de asimetrías y valores atípicos, antes de abordar las relaciones multivariantes. Para las variables laborales (VAB y ocupación por sectores), no usaremos los datos originales (valores totales) si no el porcentaje sobre el total nacional.

Visualizamos los histogramas de los datos:



Las marcas naranjas indican valores atípicos (Alejados de la media más de 3 desviaciones típicas)

En los histogramas podemos observar la media, y mediana de cada variable, al igual que los outliers usando la regla de la desviación típica. Tal y como se esperaba, ninguna distribución es simétrica, siendo el caso más extremo el del saldo migratorio, en el que se concentra la mayoría de provincias por debajo de 0, mientras que Madrid es un valor atípico. En conjunto, las distribuciones muestran una heterogeneidad moderada y, en muchos casos, asimetría positiva. La edad media de maternidad presenta una dispersión reducida, mientras que la migración interior y la población concentran

valores atípicos más marcados. Estas características se incorporan directamente en los histogramas y diagramas de caja mediante sus estadísticos descriptivos.

Para complementar el análisis, representamos también diagramas de caja y detectamos los valores atípicos usando la regla del rango intercuartílico.

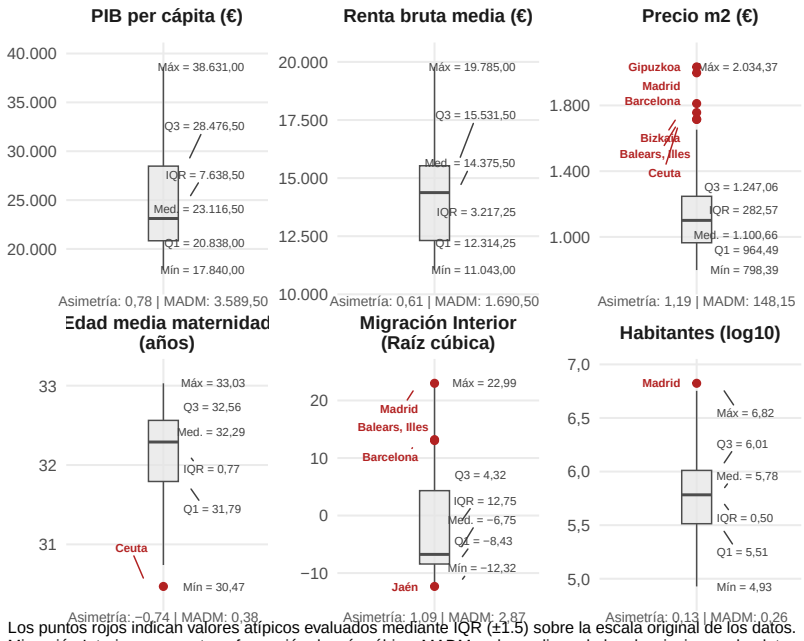
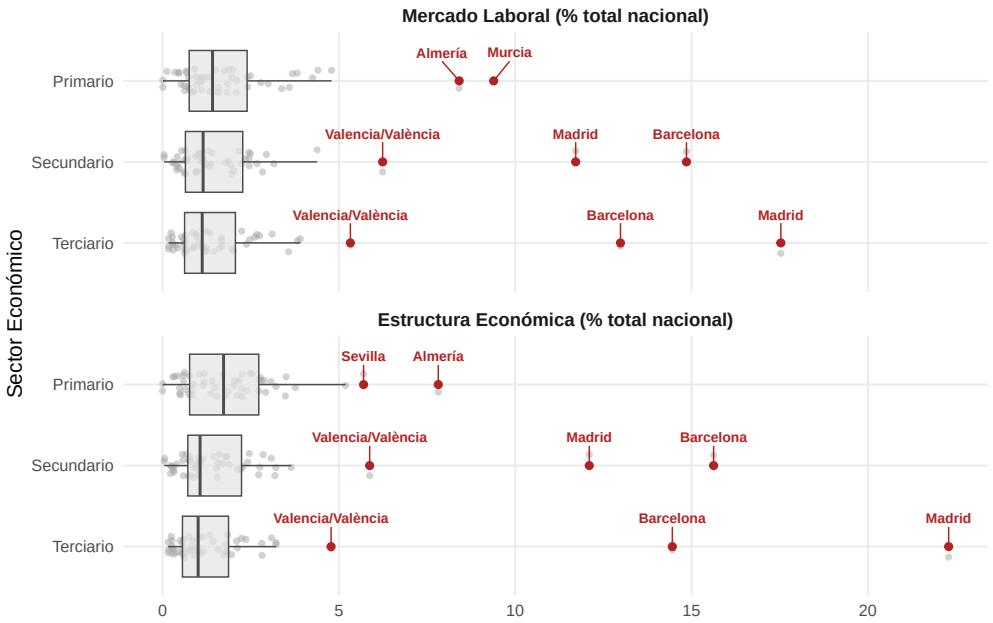


Figure 1. Distribución de las variables socioeconómicas.

Haciendo uso de esta representación, podemos observar de manera más clara la asimetría de los datos, apareciendo una mayor cantidad de outliers. En la mayoría de casos los bigotes de los diagramas son significativamente más grandes que las cajas, lo que indica más valores agrupados en los extremos que entorno a medidas centrales como la mediana.

Para visualizar la distribución de las variables laborales, hacemos uso de diagramas de cajas para comparar por sector cada una de las variables.



Los puntos rojos indican valores atípicos evaluados mediante la regla IQR (±1.5) calculada por sector.

Podemos observar de nuevo datos muy heterogéneos, y valores extremos muy altos.

3.3. Análisis Bivariante y Multivariante

Una vez constatada la heteroregeidad de los datos en el análisis univariante, en esta sección buscamos cruzar las variables para dar respuesta a las preguntas planteadas en la introducción. Para sintetizar las múltiples interacciones entre distintas variables, hacemos uso de la matriz de correlación. Como hemos visto en el análisis univariante, las distribuciones presentan asimetrías, colas pesadas, y en varios casos outliers. Para que esto no afecte de manera significativa a las correlaciones, en algunos casos usaremos medidas derivadas de los datos.

1. La densidad de población en lugar del número de habitantes,es decir

$$Densidad_Pobl. = \frac{Num_Habitantes}{Superficie_Provincia}.$$

2. El esfuerzo de compra la vivienda, caclulada como el número de años de renta bruta media que se requieren para alcanzar el valor de una casa de $90m^2$.

$$Esf_Vivienda = \frac{90 * Precio\ m^2}{Renta\ Bruta\ Media}.$$

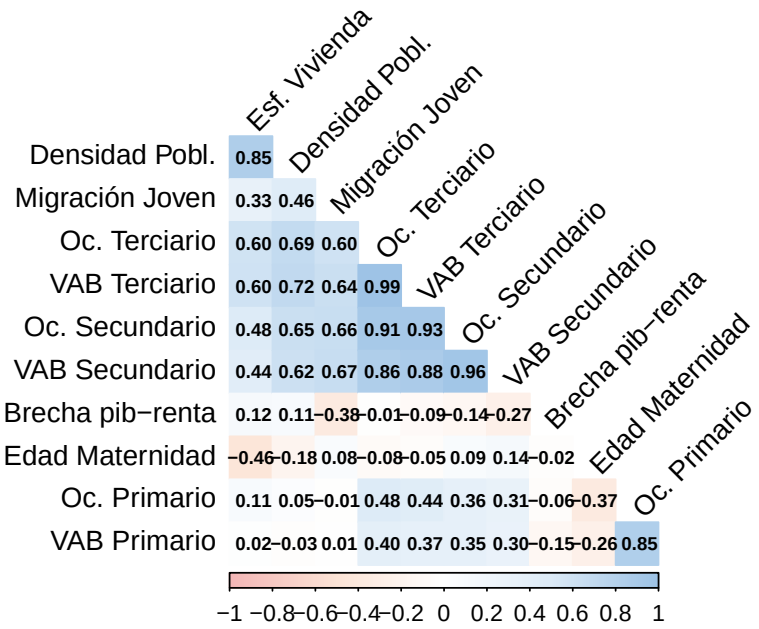
3. La brecha renta/PIB. Es decir, la magnitud de la renta bruta media con respecto al PIB per cápita.

$$Brecha\ Renta/PIB = \frac{Renta\ Bruta\ Media}{PIB\ per\ cpita}.$$

4. La migración joven por cada 1.000 habitantes:

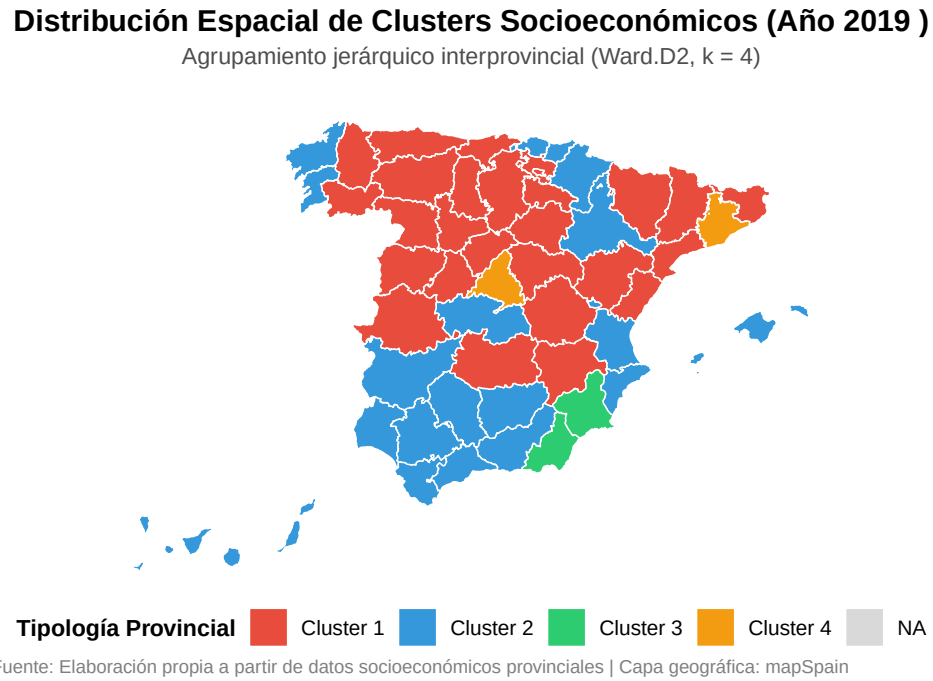
$$Mig_Joven = \frac{Migracion_Interior}{Num_Habitantes} \cdot 1000.$$

Usamos la correlación de Spearman, ya que al aplicar estas transformaciones no lineales, la correlación de Pearson se distorsiona.



Observamos valores de correlaciones muy variados, algunos esperados como la correlación entre el porcentaje de ocupación el VAB en cada uno de los sectores. Hay otros que llaman la atención, como la correlación entre la densidad de población y el esfuerzo de acceso a la vivienda. Sin embargo, como hemos visto en el análisis univariante de los datos, tenemos datos muy heterogéneos con valores extremos, y distribuciones asimétricas, por lo que para estudiar con más exactitud las relaciones entre los distintos indicadores realizamos un cluster de las provincias para separarlas en 4 grupos con características socioeconómicas similares, para que se reflejen de manera más clara las dinámicas entre estas, y no se contaminen por la heterogeneidad de los datos.

Representamos los grupos en un mapa



Por el mapa nos podemos hacer una idea de las características por las que se ha formado cada grupo. Calculamos los valores promedios de cada variable por grupo para observar las características de cada grupo.

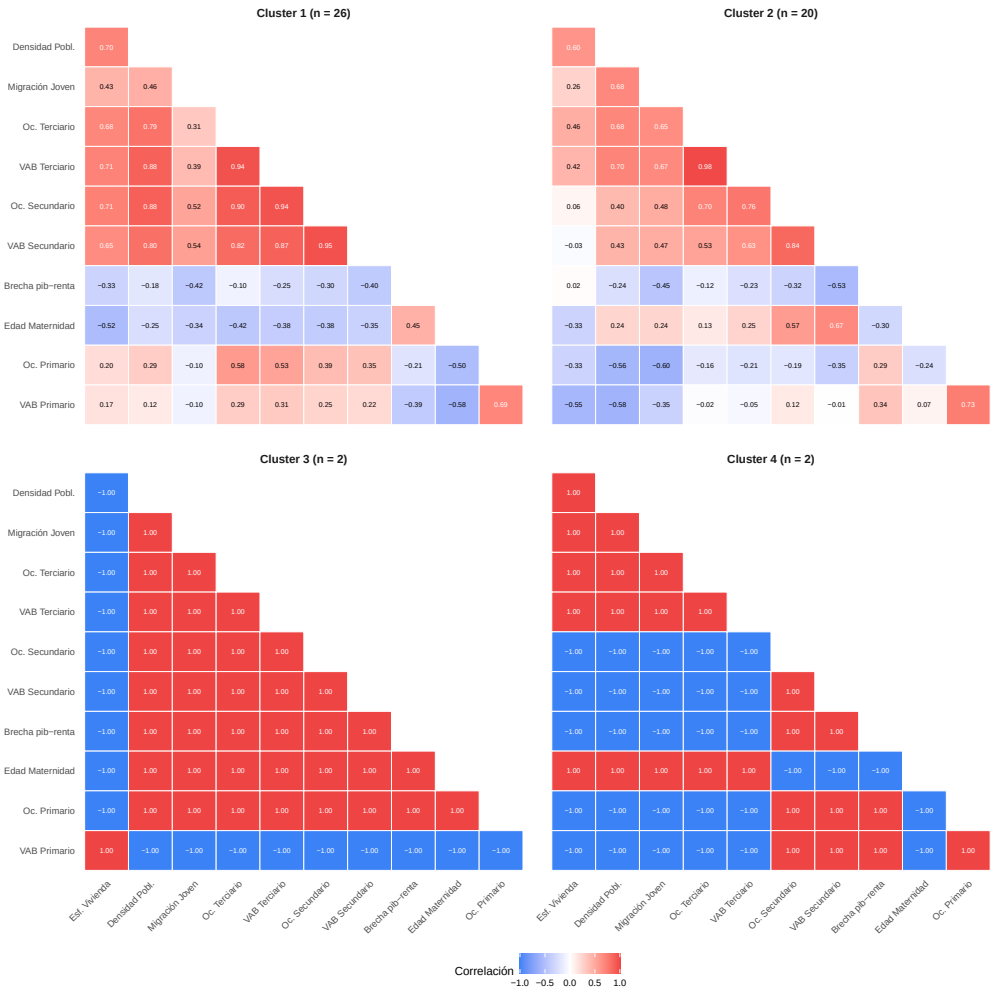
Table 3. Perfil socioeconómico por Cluster

Cluster	Num_Provincias	brecha_pib_renta	esfuerzo_vivienda	Edad_Media_Maternidad	mig_joven_1000	Densidad
Cluster 1	26	0.58	6.32	32.34	-1.02	45.95
Cluster 2	20	0.60	8.07	32.11	-0.36	182.92
Cluster 3	2	0.53	8.10	31.16	-0.59	106.89
Cluster 4	2	0.55	9.08	32.75	1.11	782.32

Table 4. Perfil de estructura productiva por Cluster

Cluster	Num_Provincias	pct_Ocupados_Primario	pct_Ocupados_Secundario	pct_Ocupados_Terciario	pct_VAB_Primario	pct_VAB_Secundario
Cluster 1	26	1.19	0.95	0.74	1.37	0.99
Cluster 2	20	2.48	2.24	2.29	2.40	2.12
Cluster 3	2	8.90	1.92	2.00	6.51	2.06
Cluster 4	2	0.85	13.29	15.26	1.68	13.86

Ahora calculamos las correlaciones por cluster.



Estas nuevas matrices de correlación poco tienen que ver con la original. Observamos valores de correlación bastante altos que antes no aparecían. En el grupo 4 al estar formado por dos elementos la correlación entre dos de sus variables cualesquiera será 1 o -1 siempre, por lo que la información que nos aporta no es de gran utilidad.

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.